



А/В-тестирование

Модуль 1: Введение в А/В-тестирование

2025



План модуля

Введение в A/B-тестирование

1. Основы A/B-тестирования
2. Статистические основы
3. Полный цикл тестирования

План занятия

Основы A/B-тестирования

Введение

1. Определение и область применения A/B-тестов
2. Структура теста: метрики, группы, гипотезы пр.
3. Ошибки I и II рода, статистическая мощность

Ответы на вопросы

Введение

Постановка задачи: Есть варианты, нужно выбрать лучший

Любые виды деятельности и процессы нуждаются в постоянном улучшении/изменении.
Откуда приходят идеи улучшений/изменений? – рынок, поведение пользователей, потребности, видение...



Как проверить наиболее подходящую идею?

Как выбрать успешные идеи достоверно и с минимальными затратами?

- Здравый смысл?
- Опросы?
- Фокус-группы?
- Экспертиза?
- Интуиция?
- Ритуалы и оккультные практики?

Какой подход должен позволить сделать верный вывод?



1. Определение и область применения A/B-тестов

Что такое A/B-тест?

A/B-тест — это эксперимент, в котором две или более версии какой либо сущности (например, веб-страницы, приложения, рекламного письма, лекарства, метода и пр.) показываются разным группам пользователей* для того, чтобы статистически определить, какая версия лучше достигает поставленной цели (увеличивает конверсию, кликабельность, вовлеченность, излечимость и т.д.)

Тестировать можно практически всё:

- Внешний вид (вкус, запах, тембр, пр.)
- Алгоритмы и их влияние
- Новая функциональность
- Пользовательский опыт
- Эффективность лекарства
- Влияние
- ...
- Упрощения
- Ухудшения



* Пользователями могут выступать люди, животные, растения, алгоритмы, машины и т.д., и т.п.

2. Структура теста: метрики, группы, гипотезы и пр.

Структура A/B-теста



Планирование:

- описание теста
- группировка участников теста
- продолжительность
- пр.

Проверка гипотез

2. Структура теста: метрики, группы, гипотезы и пр.



Метрики

Прежде чем начать тестирование, необходимо определиться с бизнес показателями по которым мы будем ориентироваться при принятии решений.

Что должно значимо улучшиться?

Например, “количество заказов”, “количество денег”, “число отказов” и т.д., и т.п..

Есть ли какие-то проблемы с такими метриками?

Как их корректно рассчитать?

Виды метрик:

- Предварительные метрики (до эксперимента)
- Экспериментальные
- Бизнес-метрики

Что делать если бизнес-метрики недоступны?

Proху – метрики:

достаточно чувствительны и хорошо согласуются с бизнес-показателями



Пример: число уникальных пользователей или репостов в социальных сетях на сайте яхт-клуба

2. Структура теста: метрики, группы, гипотезы и пр.

Метрики

Релевантность метрик
Объясняет ли фича конверсию?

VS.



2. Структура теста: метрики, группы, гипотезы и пр.

Метрики

Тестирование на исторических данных

Пример:

Есть сайт пиццерии, на сайте есть регистрация, пользователи идентифицируются достаточно точно. Имеется также довольно внушительная история заказов пользователей, а также существующий алгоритм выдачи предложений по “сопутствующим товарам”, исходя из того, что заказывает пользователь. Допустим мы думаем над внедрением нового алгоритма.



Какие показатели стоит измерить на исторических данных?

2. Структура теста: метрики, группы, гипотезы и пр.



Дизайн эксперимента

- **Как правильно выбрать пользователей?**
 - Стратификация – снижаем дисперсию
 - Рандомизация – обеспечиваем репрезентативность
- **Какие будут получены артефакты?**
- **А что если мы хотим провести несколько экспериментов одновременно?**
 - Как оценить ошибку теста?

2. Структура теста: метрики, группы, гипотезы и пр.

Дизайн эксперимента

А что если мы хотим провести несколько экспериментов одновременно?

- Обычно лучше разбить на непересекающиеся группы
- Не проводить взаимоисключающие эксперименты
- В связанных экспериментах продумывать последовательность вариантов
- Подождать завершения другого эксперимента
- Хорошо подумать над влиянием фичей друг на друга, оценить связанность метрик и запустить эксперимент на свой страх и риск

Скоринг (что не нужно тестировать)

- ROI
- Видение продукта
- Запросы обратной связи (исторические данные)
- Гигиена (фича у всех есть но нам не нужна)
- Wow-фактор
- Сложность внедрения и поддержки

2. Структура теста: метрики, группы, гипотезы и пр.

Устойчивость

- Видеть значимые изменения где они есть
- Не видеть значимых изменений где их нет

2. Структура теста: метрики, группы, гипотезы и пр.

Устойчивость

UC Berkeley case	Мужчины			Женщины		
	Факультет	Поступало	Поступило	%	Поступало	Поступило
	А	825	512	62,1	108	89
	В	560	353	63	25	17
	С	325	120	36,9	593	202
	Д	417	138	33,1	375	131
	Е	191	53	27,8	393	94
	F	272	16	5,9	341	24
	Итого	2590	1192	46	1835	557

2. Структура теста: метрики, группы, гипотезы и пр.

Устойчивость

		Пятница	Суббота	Всего
А	Пользователи	990 000	500 000	1 490 000
	Конверсии	20 000	5 000	25 000
	%	2.02	1.00	1.68
В	Пользователи	10 000	500 000	510 000
	Конверсии	230	6 000	6 230
	%	2.30	1.20	1.22

2. Структура теста: метрики, группы, гипотезы и пр.

Устойчивость


Обратный эксперимент: часть пользователей не видит изменений



2. Структура теста: метрики, группы, гипотезы и пр.

Устойчивость


Перекрестный эксперимент: группы пользователей чередуются



2. Структура теста: метрики, группы, гипотезы и пр.

Устойчивость

АА-тест: АВ-тест, но разным группам демонстрируется одно и то же решение



2. Структура теста: метрики, группы, гипотезы и пр.

Устойчивость

АА-тест: использование ЦПТ (пост-стратификация)



2. Структура теста: метрики, группы, гипотезы и пр.

Устойчивость

ААВ-тест: совмещенный АА и АВ-тесты



2. Структура теста: метрики, группы, гипотезы и пр.

Проведение эксперимента

Это фаза **точной технической реализации** дизайна эксперимента, в ходе которой система аккуратно собирает сырые данные для последующего анализа.

Цель этапа: Получить **чистый, полный и неискаженный** массив данных, который объективно отражает поведение пользователей в контрольной и тестовой группах в течение всего времени эксперимента

2. Структура теста: метрики, группы, гипотезы и пр.

Анализ данных эксперимента

- Анализ собранных данных
- Подготовка статистических выводов с использованием релевантных методов анализа
- Принятие решения о завершении или продолжении теста

3. Ошибки I и II рода, статистическая мощность



Ошибки I и II рода

Прежде чем что-то сравнивать выдвигают конструктивную гипотезу, которую хочется проверить.

Например,

- препараты X и Y по-разному влияют на кровяное давление больных
- продолжительность лекции влияет на успеваемость студента
- постановка вопроса влияет на ответ респондента

На полученных данных мы пытаемся делать выводы об истинности или ложности выдвигаемой гипотезы

Нужно помнить, что проверка статистической гипотезы имеет вероятностный характер.

Точно также, мы не можем быть уверены на все 100, что параметр, оцениваемый по конечной выборке, совпадает с реальным значением параметра в генеральной совокупности

3. Ошибки I и II рода, статистическая мощность

Ошибки I и II рода

		Верная гипотеза	
		H_0	H_1
Ответ теста	H_0	H_0 принята	H_0 неверно принята (ошибка 2-ого рода, β): вероятность получить имеющиеся данные довольно высока при истинности H_0
	H_1	H_0 неверно отвергнута (ошибка 1-ого рода, α): вероятность получить имеющиеся данные при истинности H_0 слишком мала	H_0 отвергнута

3. Ошибки I и II рода, статистическая мощность

Ошибки I и II рода

Статистическая гипотеза — предположение о виде распределения и свойствах случайной величины, которое можно подтвердить или опровергнуть применением статистических методов к данным выборки

Ошибка 1-ого рода критичнее

Вероятность ошибки первого рода $P(H_0 \text{ отвергается} | H_0 \text{ верна})$ жестко ограничивается

$$P(H_0 \text{ отвергнута} | H_0 \text{ верна}) = P(p \leq \alpha | H_0) \leq \alpha$$

Вероятность ошибки второго рода $P(H_0 \text{ принимаем} | H_1 \text{ вер.})$ мягко минимизируется

$$\text{pow} = P(H_0 \text{ отвергнута} | H_1 \text{ верна}) = 1 - P(H_0 \text{ принимаем} | H_1 \text{ верна})$$


$\mu_1 - \mu_0$ размер эффекта

α ошибка первого рода (или уровень значимости)

β ошибка второго рода

$1 - \beta$ мощность критерия

c порог принятия решения



3. Ошибки I и II рода, статистическая мощность



Ошибки I и II рода

Пример базовой и альтернативной гипотез:

H_0 : Реальная разность между средними значениями давлений в двух группах равна 0 ($\mu_0 - \mu_1 = 0$)

H_1 : Реальная разность между средними значениями давлений в двух группах не равна 0 ($\mu_0 - \mu_1 \neq 0$)

3. Ошибки I и II рода, статистическая мощность



Статистическая мощность. Определение

Статистическая мощность (Statistical Power) в контексте A/B-тестирования — это вероятность **обнаружить разницу между вариантами, если она на самом деле существует**

Проще говоря, это **шанс вашего теста не пропустить эффект**. Мощность измеряется в процентах

Мощность 80% означает, что если изменение (Вариант B) действительно работает лучше, чем контроль (Вариант A), то у вас есть 80% шанс это обнаружить и подтвердить статистически. И, соответственно, 20% шанс пропустить этот эффект (сделать ложноотрицательный вывод)

Статистическая мощность — это мера "зоркости" A/B-теста

3. Ошибки I и II рода, статистическая мощность



Статистическая мощность. Взаимосвязанные составляющие

Минимально детектируемый эффект (minimum detectable effect, mde)

Что показывает: Насколько заметная разница между группами ожидается в значении метрики. Насколько видно, что Вариант В лучше Варианта А?

Влияние: Чем больше ожидаемый эффект (например, увеличение конверсии на 20% против 2%), тем легче его обнаружить, и тем выше мощность при прочих равных.

Размер выборки (Sample Size)

Что показывает: Количество пользователей* (размер выборки) в каждой группе теста.

Влияние: Это самый главный рычаг управления мощностью. Чем больше пользователей* участвует в тесте, тем точнее данные и тем выше мощность

Достигаемый уровень значимости (Alpha, α , p-value)

Что показывает: Вероятность при справедливости нулевой гипотезы H_0 получить такое же значение статистики, как в эксперименте, или ещё более экстремальное. Обычно устанавливается на уровне 5% (или 0.05)

Влияние: Чем ниже достигаемый уровень значимости (чем строже мы к результатам), тем сложнее обнаружить эффект, и тем ниже мощность. Между строгостью теста и его способностью находить эффекты есть компромисс

Дисперсия (Variability, σ^2)

Что показывает: Насколько "разбросаны" измеряемые данные. Например, конверсия может быть очень стабильной (все пользователи ведут себя похоже) или очень разной (поведение сильно отличается).

Влияние: Чем больше разброс, тем больше "шума" в данных и тем сложнее обнаружить "сигнал" (эффект), а значит, мощность ниже

* Пользователями могут выступать люди, животные, растения, алгоритмы, машины и т.д., и т.п.

3. Ошибки I и II рода, статистическая мощность

Статистическая мощность, p-value

p-value - это вероятность при справедливости нулевой гипотезы H_0 получить такое же значение статистики, как в эксперименте, или ещё более экстремальное

Чем ниже **p-value** тем сильнее данные свидетельствуют против H_0 в пользу H_1


$$T(X) = t$$

$$p = \mathbb{P}(T \geq t | H_0)$$




$$p = T_{N(0,1)}(z)$$

$$H_1: \mu < \mu_0$$




$$p = 1 - T_{N(0,1)}(z)$$

$$H_1: \mu > \mu_0$$



$$p = 2 * (1 - T_{N(0,1)}(|z|))$$

$$H_1: \mu \neq \mu_0$$



Мы научились

1. Понимать принципы A/B-тестирования
2. Формулировать гипотезы
3. Различать типы статистических ошибок

Отвѣты на вопросы



Статистические основы А/В-тестирования

1. Статистические критерии
2. t-тесты (одно и двухвыборочный)
3. Проверка нормальности распределения
4. Интерпретация p-value и доверительных интервалов

Ответы на вопросы

1. Статистические критерии

Важно понимать, что именно оценивается!

Для среднего:

- Данные распределены нормально? **Известна дисперсия** → **z-критерий**
- **Дисперсия неизвестна** → **t-критерий** (при большом количестве данных можно использовать квантили нормального распределения)

Для частоты:

- Критерий согласия Пирсона (**Хи-квадрат**)

Для дисперсии:

- **Среднее известно** → критерий **Хи-квадрат**
- **Среднее неизвестно** → критерий **Фишера** (z-критерий)

2. t-тесты (одно- и двухвыборочный)

Суть t-теста

t-тест — это статистический тест, который используется для определения того, **есть ли статистически значимая разница** между средними значениями двух групп. Он отвечает на вопрос: "Вероятно ли, что разница, которую я вижу между этими средними, возникла просто случайно, или она реально существует?»

Ключевая идея: мы сравниваем не сами средние значения, а соотношение разницы между ними к величине случайной вариации (разбросу) в данных. Это соотношение называется **t-статистикой**

$t = (\text{разница между средними}) / (\text{вариабельность в данных})$


Чем больше значение t-статистики (по модулю), тем меньше вероятность, что разница случайна

2. t-тесты (одно- и двухвыборочный)

Одновыборочный критерий Стьюдента

Сравнение непрерывных величин
Среднее/Медиана/Мода, σ^2 – известна

Выборка:	$X_n = (X_1, \dots, X_n),$ $X \sim \mathcal{N}(\mu, \sigma^2)$
Нулевая гипотеза: Альтернатива:	$H_0: \mu = \mu_0$ $H_1: \mu < \neq > \mu_0$
Статистика:	$Z(X_n) = \frac{X_i - \mu_0}{\sigma/\sqrt{n}}$
Нулевое распределение:	$Z(X_n) = N(0,1)$




2. t-тесты (одно- и двухвыборочный)

Одновыборочный критерий Стьюдента

Сравнение непрерывных величин
Среднее/Медиана/Мода, σ^2 – неизвестна

Выборка:	$X_n = (X_1, \dots, X_n),$ $X \sim \mathcal{N}(\mu, \sigma^2)$
Нулевая гипотеза: Альтернатива:	$H_0: \mu = \mu_0$ $H_1: \mu < \neq > \mu_0$
Статистика:	$T(X_n) = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$
Нулевое распределение:	$T(X_n) \sim St(n - 1)$




2. t-тесты (одно- и двухвыборочный)

Двухвыборочный критерий Стьюдента

Независимые выборки, Z - критерий

Выборки:	$\mathbf{X}_1^{n_1} = (X_{11}, \dots, X_{1n_1}),$ $\mathbf{X}_2^{n_2} = (X_{21}, \dots, X_{2n_2})$ $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$
Нулевая гипотеза:	$H_0: \mu_1 = \mu_2$
Альтернатива:	$H_1: \mu_1 < \neq > \mu_2$
Статистика:	$Z(\mathbf{X}_1^{n_1}, \mathbf{X}_2^{n_2}) = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$
Нулевое распределение:	$Z(\mathbf{X}_1^{n_1}, \mathbf{X}_2^{n_2}) = N(0,1)$



t-тесты (одно- и двухвыборочный)

Двухвыборочный критерий Стьюдента

Независимые выборки, t - критерий

Выборки:	$X_1^{n_1} = (X_{11}, \dots, X_{1n_1}),$ $X_2^{n_2} = (X_{21}, \dots, X_{2n_2})$ $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$
Нулевая гипотеза: Альтернатива:	$H_0: \mu_1 = \mu_2$ $H_1: \mu_1 < \neq > \mu_2$
Статистика:	$T(X_1^{n_1}, X_2^{n_2}) = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$
Нулевое распределение:	$T(X_1^{n_1}, X_2^{n_2}) \approx \sim St(v) *$

* $S_1^2 < S_2^2$
 $n_1 < n_2$




2. t-тесты (одно- и двухвыборочный)

Двухвыборочный критерий Стьюдента

Зависимые выборки, t - критерий

Выборки:	$X_1^n = (X_{11}, \dots, X_{1n}),$ $X_2^n = (X_{21}, \dots, X_{2n})$ $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2), X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$
Нулевая гипотеза: Альтернатива:	$H_0: \mu_1 = \mu_2$ $H_1: \mu_1 < \neq > \mu_2$
Статистика:	$T(X_1^n, X_2^n) = \frac{\bar{X}_1 - \bar{X}_2}{S/\sqrt{n}} \quad *$
Нулевое распределение:	$T(X_1^n, X_2^n) \sim St(n-1)$



$$* S = \sqrt{\frac{\sum_{i=1}^n (D_i - \bar{D})^2}{n-1}}, D_i = X_{1i} - X_{2i}$$

2. t-тесты (одно- и двухвыборочный)

Сравнение долей

Сравнение дискретных величин

Критерий согласия Пирсона χ^2

Выборки:

$$X_1, X_2 \dots X_n \sim N(\mu, \sigma^2) \rightarrow X^n (X_1, X_2 \dots X_n)$$

Нулевая гипотеза:

$$H_0: \mu_1 = \mu_2$$

Альтернатива:


$$H_1: \mu_1 < \neq > \mu_2$$

Статистика:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Нулевое
распределение:

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \Rightarrow \chi_{n-1}^2$$



3. Проверка нормальности распределения

Зачем проверять нормальность?

- **Нормальное распределение (Гауссово)** — фундаментальное понятие в статистике.
- **Предпосылка для параметрических тестов:** Многие мощные статистические методы (t-тест, ANOVA, линейная регрессия) требуют, чтобы данные были распределены нормально или хотя бы приближались к этому.
- **Корректность выводов:** Нарушение предпосылки о нормальности может привести к неверным статистическим выводам.

Три основных подхода к проверке на нормальность

- **Графические методы** (Визуальная оценка)
- **Аналитические методы** (Статистические критерии)
- **Числовые методы** (Оценочные)

3. Проверка нормальности распределения

Графические методы (Визуальная оценка)

Гистограмма с кривой нормального распределения:

- **Суть:** Строится гистограмма частот данных и на нее накладывается теоретическая кривая нормального распределения с теми же средним и стандартным отклонением.
- **Интерпретация:** Визуально оцениваем, насколько форма гистограммы совпадает с кривой.
- **Плюсы:** Простота и интуитивная понятность.
- **Минусы:** Субъективность. При небольшом объеме данных сложно сделать однозначный вывод.

Гистограмма и плотность нормального распределения





График Quantile-Quantile (Q-Q plot):

- **Суть:** Сравниваются квантили наших данных с квантилями теоретического нормального распределения.
- **Интерпретация:** Если точки лежат на диагональной линии или близко к ней — распределение нормальное. Сильные отклонения точек от линии (например, S-образная форма) указывают на ненормальность.
- **Плюсы:** Более надежен, чем гистограмма. Позволяет определить характер отклонения (скошенность, тяжелые хвосты).
- **Минусы:** Субъективность.

QQ-plot нормального распределения



3. Проверка нормальности распределения

Аналитические методы (Статистические критерии)

Суть: Формальные статистические тесты, которые проверяют **нулевую гипотезу (H_0)** о том, что данные распределены нормально.

Ключевой принцип: Если **p-value (уровень значимости) > 0.05** , у нас нет оснований отвергнуть H_0 , и мы можем допустить нормальность распределения. Если **p-value < 0.05** , то отвергаем H_0 в пользу альтернативы — распределение **не является нормальным**.

Примеры аналитических методов:

Тест Шапиро-Уилка (Shapiro-Wilk test):

- **Применение:** Считается одним из самых мощных тестов, особенно для выборок небольшого и среднего размера ($n < 50$).
- Рекомендуется к использованию по умолчанию.

Тест Колмогорова-Смирнова (с поправкой Лиллиефорса) (Kolmogorov-Smirnov test, с Lilliefors correction):

- **Применение:** Менее мощный, чем Шапиро-Уилка, особенно для малых выборок. Чаще используется для проверки соответствия любым распределениям, а не только нормальному.
- **Важно:** Базовый тест Колмогорова-Смирнова без поправки не рекомендуется для проверки нормальности.

3. Проверка нормальности распределения

Числовые методы (Оценочные)


Коэффициент асимметрии (Skewness):

- Показывает степень скошенности распределения.
- Для нормального распределения ≈ 0 .
- Положительное значение — длинный хвост справа, отрицательное — слева.

Коэффициент эксцесса (Kurtosis):

- Показывает «крутость» и «тяжесть хвостов» по сравнению с нормальным распределением.
- Для нормального распределения ≈ 0 (иногда 3, зависит от реализации в программе).
- Положительное значение — тяжелые хвосты (островершинное), отрицательное — легкие хвосты (плосковершинное).

Интерпретация: Часто используется эмпирическое правило: если $|\text{Skewness}| < 2$ и $|\text{Kurtosis}| < 4$, распределение можно считать приближенно нормальным. Но это грубая оценка.



3. Проверка нормальности распределения

Практический алгоритм проверки нормальности распределения

1. Построение графиков

- **Q-Q Plot:** Это главный инструмент. Точки должны лечь на диагональную линию. Допустимы небольшие отклонения на концах.
- **Гистограмма:** Форма должна быть похожа на колокол (симметричная, с одним пиком).

2. Анализ числовых параметров

Значения Скошенности и Крутизны: $|Skewness| < 2$ и $|Kurtosis| < 4$.

Тест Шапиро-Уилка (p-value) или другой аналитический тест:

$p > 0.05$ — нормальность не отвергается.

$p \leq 0.05$ — данные не нормальны.

3. Принятие решения о нормальности

Если...	То...
График выглядит нормально И $p\text{-value} > 0.05$ (или $N > 50$)	ИСПОЛЬЗУЙТЕ t-тест, ANOVA, Pearson
График сильно отклоняется ИЛИ $p\text{-value} \leq 0.05$	ВЫБИРАЙТЕ Непараметрические тесты: U-тест, Вилкоксон, Крускал-Уоллис

Важно! Для больших выборок ($N > 50$) больше доверяйте графику, а не p-value.

4. Интерпретация p-value и доверительных интервалов

GitVerse

[Откройте ссылку gitverse.ru](https://gitverse.ru)

Мы научились

1. Проверять нормальность выборок средствами Python
2. Сравнивать группы с помощью t-теста

Отвѣты на вопросы



План занятия

Полный цикл тестирования

1. Алгоритм проверки гипотез
 2. Определение MDE (минимального детектируемого эффекта)
 3. Этические аспекты тестирования
- Ответы на вопросы

1. Алгоритм проверки гипотез

Гипотеза - данные - вывод

Прежде чем что-то сравнивать **выдвигают конструктивную гипотезу**, которую хочется проверить.

Например,

- препараты X и Y по-разному влияют на кровяное давление больных
- продолжительность лекции влияет на успеваемость студента
- постановка вопроса влияет на ответ респондента

На полученных **данных** мы пытаемся делать **выводы** об истинности или ложности выдвигаемой гипотезы

Нужно помнить, что проверка статистической гипотезы имеет **вероятностный характер**.

Точно также, мы **не можем** быть **уверены** на все **100%**, что параметр, оцениваемый по конечной выборке совпадает с реальным значением параметра в генеральной совокупности (вспоминаем доверительные интервалы).

1. Алгоритм проверки гипотез

Гипотеза

Статистическая гипотеза — предположение о виде распределения и свойствах случайной величины, которое можно подтвердить или опровергнуть применением статистических методов к данным выборки.

Пусть в эксперименте наблюдается случайная величина X , распределение которой P полностью или частично неизвестно. Любое утверждение относительно P называют статистической гипотезой.

Гипотезы бывают простые и сложные.

- Если гипотеза однозначно определяет P , т.е. **$H: \{P = P_0\}$** , где P_0 это какой-то конкретный закон (например, нормальное распределение с параметрами 0 и 1), то **гипотеза простая**.
- Если же гипотеза утверждает, что P относится к **семейству распределений**, то **гипотеза сложная** (например, гипотеза о том, что данные распределены нормально, без фиксации параметров).

1. Алгоритм проверки гипотез

Общий фреймворк проверки гипотез: шаг 1

Формулировка основной гипотезы H_0 и конкурирующей гипотезы H_1 .

1. Алгоритм проверки гипотез

Общий фреймворк проверки гипотез: шаг 2

Задание уровня значимости α (или p-value), на котором в дальнейшем и будет сделан вывод о справедливости гипотезы. Он равен вероятности допустить ошибку первого рода H_0

1. Алгоритм проверки гипотез

Общий фреймворк проверки гипотез: шаг 3


Расчёт статистики φ критерия такой, что:

- её величина зависит от исходной выборки $\mathbf{X}_n = (X_1, \dots, X_n)$ $\varphi = \varphi(X_1, \dots, X_n)$
- по её значению можно делать выводы об истинности гипотезы $\mathbf{H}_0$
- статистика φ , как функция случайной величины $\mathbf{X}$, также является случайной величиной и подчиняется какому-то закону распределения

1. Алгоритм проверки гипотез

Общий фреймворк проверки гипотез: шаг 4

Построение критической области. Из области значений φ выделяется подмножество C таких значений, по которым можно судить о существенных расхождениях с предположением. Его размер выбирается таким образом, чтобы выполнялось равенство $P(\varphi \in C) = \alpha$. Это множество C и называется критической областью.



1. Алгоритм проверки гипотез

Общий фреймворк проверки гипотез: шаг 5

Вывод об истинности гипотезы. Наблюдаемые значения выборки подставляются в статистику φ и по попаданию (или не попаданию) в критическую область C выносится решение об отвержении (или принятии) выдвинутой гипотезы H_0 .

Далее математически вывод трансформируется в вывод по сути изначальной задачи

1. Алгоритм проверки гипотез

Подведем итоги

Выборка:	$X^n = (X_1, \dots, X_n), \quad X \sim P \rightarrow \omega$
Нулевая гипотеза:	$H_0: P \in \omega$
Альтернатива:	$H_1: P \notin \omega$
Статистика:	$T(X_n), \quad \begin{array}{l} T(X_n) \sim F(x) \text{ при } H_0 \\ T(X_n) \not\sim F(x) \text{ при } H_1 \end{array}$

2. Определение MDE (минимального детектируемого эффекта)

Размер эффекта

p-value:

Какова вероятность верного предсказания?

Насколько различаются суммы в чеках?

и т.д.

p-value зависит от размера эффекта и размера выборки

На **малых выборках** эффект менее заметен, **H_0 не отвергается**

Важно:

Выборка данных формируется случайно

Оценка размера эффекта по выборке это случайная величина

p-value показывает вероятность случайного получения такой оценки

2. Определение MDE (минимального детектируемого эффекта)

Расчет MDE

Минимальный размер эффекта **mde** = **p*эффект**, где p вероятность совершения целевого действия, эффект - %-изменение целевого параметра

Задача:

При конверсии магазина **10%** (один из десяти посетителей совершает покупку), нужно найти объем выборки **N** для фиксации эффекта 7% (в результате мер по повышению конверсии ожидается увеличения числа покупок на 7% по отношению к совершаемым сейчас покупкам). $\alpha = 0.05$

1. Данные имею распределение Бернулли и при этом распределение нескошенное → Можно преобразовать данное распределение в нормальное (ЦПТ). **$\mu = p$, $\sigma^2 = (1-p)$**
2. При доверительном уровне значимости 0.05 используем интервал **$\pm 2\sigma$ ($z = 1.96$)**

$$N = \frac{p(1-p)*z^2}{mde^2} = \frac{0.1(1-0.1)*1.96^2}{(0.1*0.07)^2} = 7056$$

2. Определение MDE (минимального детектируемого эффекта)

Расчет MDE для двух выборок

$$\text{MDE} = (t_{\alpha} + t_{\beta}) \times \sqrt{(\sigma_1^2/n_1 + \sigma_2^2/n_2)}$$

Где:

t_{α} - t-критическое значение для уровня значимости α (двусторонний тест)

Двусторонний: $t_{1-\alpha/2}$ (α делится пополам)

Односторонний: $t_{1-\alpha}$ или t_{α} (α используется целиком)

$t_{1-\beta}$ - t-критическое значение для мощности теста ($1-\beta$)

σ_1^2, σ_2^2 - дисперсии первой и второй выборок, $\sigma_1^2 < \sigma_2^2$

n_1, n_2 - размеры первой и второй выборок

3. Этические аспекты тестирования

Почему этика важна в А/В-тестировании?

А/В-тестирование — это не просто "технический" процесс. Оно напрямую влияет на:

Пользовательский опыт: Неудачные тесты могут ухудшить взаимодействие с продуктом.

Доверие пользователей: Манипуляции или скрытые эксперименты подрывают доверие.

Репутацию компании: Этические провалы могут привести к скандалам и финансовым потерям.

Благополучие пользователей: В некоторых случаях (финансы, здоровье) тесты могут иметь серьезные последствия.

Этика — это не ограничение, а основа для долгосрочного и устойчивого роста.

3. Этические аспекты тестирования

Ключевые этические принципы

Информированное согласие (где это применимо): Пользователи должны знать, что участвуют в эксперименте, если тест затрагивает их конфиденциальность или безопасность.

Минимизация вреда: Версия В не должна наносить значительный ущерб пользователям (финансовый, эмоциональный, репутационный).

Прозрачность: Компания должна иметь внутреннюю политику проведения тестов и быть готовой к объяснению своих методов.

Конфиденциальность данных: Строгое соблюдение законодательства о защите данных (например, 152-ФЗ).

3. Этические аспекты тестирования

Центральная дилемма: Статистическая vs. Практическая значимость

Статистическая значимость ($p\text{-value} < 0.05$): Ответ на вопрос: "С какой вероятностью разница между группами А и В является реальной, а не случайной?"

- Пример: "Мы на 95% уверены, что новая кнопка действительно приводит к большему числу кликов.»

Практическая значимость (Эффект размера): Ответ на вопрос: "Насколько эта разница велика и имеет значение для бизнеса и пользователей?"

- Пример: "Новая кнопка увеличила конверсию на 0.001%.»

Возникает вопрос: Что делать, если результат статистически значим, но практически бесполезен (или наоборот)?

GitVerse

[Откройте ссылку gitverse.ru](https://gitverse.ru)

3. Этические аспекты тестирования

Комплиментарность значимостей: Почему они должны работать вместе

Статистическая и практическая значимость не противоречат, а дополняют друг друга. Принятие этического решения требует оценки обеих.

Статистическая значимость без практической: Запуск такого изменения может быть **неэтичным**.

- **Риск:** Вы тратите engineering- и product-ресурсы на внедрение изменений, которые не приносят реальной ценности. Это нерациональное использование усилий компании. Может ухудшить UX из-за "метания" пользователей между незначительными изменениями.

Практическая значимость без статистической: Запуск такого изменения **опасно и неэтично**.

- **Риск:** Вы принимаете решение на основе "шума" в данных. Эффект может быть случайным и не воспроизведется в будущем. Это введение в заблуждение стейкхолдеров и потенциальный вред для пользователей, если изменение окажется негативным в долгосрочной перспективе.

3. Этические аспекты тестирования

Пример этической ошибки: Погоня за статистикой

Сценарий: Тестируется новый, более агрессивный поп-ап для подписки на рассылку.

Результат: Версия В показывает статистически значимый рост подписок на 0.5%.

Практическая значимость: Ничтожна. Но при этом...

Скрытый вред (Этический аспект):

- Пользовательский опыт резко ухудшился из-за навязчивости.
- Вырос показатель отказов (bounce rate).
- Доверие к бренду падает.

Этичное решение: Не запускать версию В, несмотря на статистическую значимость, потому что практический вред перевешивает мнимую выгоду.

3. Этические аспекты тестирования

Как принимать этические решения? Практические шаги

На этапе планирования:

- Определите **минимальный эффект интереса (Minimum Detectable Effect - MDE)**. Какой размер эффекта оправдывает затраты и потенциальные риски?
- Проведите **оценку потенциального вреда** для каждой гипотезы.

После получения результатов:

- Всегда смотрите и на **p-value**, и на **размер эффекта**.
- Спросите: "Имеет ли это изменение реальное значение для наших пользователей и для бизнеса?"
- Если результат статистически значим, но эффект мал, — скорее всего, от него стоит отказаться.

Внедрите "Этический чек-лист" для утверждения гипотез перед запуском.

3. Этические аспекты тестирования

Ответственность за данные

A/B-тестирование — это не игра в угадывание, а инструмент принятия ответственных решений.

Статистическая значимость говорит нам о надежности результата.

Практическая значимость говорит нам о его ценности и последствиях.

Этика — это рамка, которая заставляет нас рассматривать их вместе, чтобы наши решения были не только прибыльными, но и правильными по отношению к пользователям.

Конечная цель — создавать лучшие продукты, уважая тех, для кого мы это делаем.

Мы научились

1. Использовать алгоритм проверки гипотез
2. Определять MDE
3. Учитывать этические аспекты при планировании тестов

Отвѣты на вопросы



**Спасибо
за внимание!**

