



А/В-тестирование

Модуль 2: Погружение в А/В-тестирование



План модуля

Погружение A/B-тестирования

1. Дискретные метрики
2. Непараметрические методы
3. Множественные сравнения

План занятия

Дискретные метрики

1. Z-тест для пропорций
 2. Анализ конверсий и бинарных метрик
 3. Поправки для малых выборок
- Ответы на вопросы

1. Дискретные метрики

Что такое дискретные метрики?

Дискретные метрики (бинарные, категориальные или метрики конверсии) — это метрики, которые могут принимать только определенное, **ограниченное число** значений. Чаще всего они отвечают на вопросы "Да" или "Нет»

Ключевая характеристика: Результат для каждого пользователя — это одно из двух (или нескольких) **взаимоисключающих** событий

Ключевой вопрос: Как определить, является ли разница между долями (процентами) **статистически значимой** или она вызвана случайностью?

1. Дискретные метрики

Область применения

Что тестируем? Гипотезы об одной доле (*one-sample z-test*) или о равенстве двух долей (*two-sample z-test*).

Критические предпосылки для проведения теста:

Бинарные данные: Каждый элемент выборки может быть отнесен только к одной из двух категорий (успех/неудача, да/нет, кликнул/не кликнул).

Независимость наблюдений: Результаты одного наблюдения не влияют на результаты другого.


Распределение: Статистика теста (доля) при выполнении условий аппроксимируется нормальным распределением (**Центральная Предельная Теорема**)*.

Условия на объем выборки:

Для **одной выборки**: $n * p_0 \geq 10$ и $n * (1 - p_0) \geq 10$

Для **двух выборок**: $n_1 * \hat{p}_1 \geq 5$, $n_1 * (1 - \hat{p}_1) \geq 5$, $n_2 * \hat{p}_2 \geq 5$, $n_2 * (1 - \hat{p}_2) \geq 5$
(где p_0 — гипотетическая доля, $\hat{p}$ — выборочная доля)

*справедливо для нескошенных распределений



1. Дискретные метрики

Две конкурирующие гипотезы:

- **Нулевая гипотеза (H_0):** Предположение об отсутствии эффекта или разницы.
 - Для одной пропорции: $H_0: p = p_0$ (доля равна гипотетическому значению)
 - Для двух пропорций: $H_0: p_1 = p_2$ (доли в двух группах равны)
- **Альтернативная гипотеза (H_1):** Предположение, которое мы хотим доказать.
 - **Двусторонняя:** $H_1: p \neq p_0$ (или $p_1 \neq p_2$) — доля отличается.
 - **Односторонняя (правосторонняя):** $H_1: p > p_0$ (или $p_1 > p_2$) — доля больше.
 - **Односторонняя (левосторонняя):** $H_1: p < p_0$ (или $p_1 < p_2$) — доля меньше.

1. Дискретные метрики

Z-статистика (для одной выборки)

Доля успехов (p_0):

- $p_0 = x / n$

Пояснение: Это общая оценка доли "успехов" в группе при условии, что H_0 верна.

Расчет Z-статистики:

- $Z = (p - p_0) / \sqrt{(p_0 * (1 - p_0) * (1/n))}$
- Где:
 - p — выборочная доля в группе.
 - p_0 — выборочные доли в исходной группе.
 - n — объем группы.

Интерпретация: Z-статистика показывает, на сколько стандартных ошибок отличаются значения выборочной доли.

Интервальная оценка:

```
from statsmodels.stats.proportion import proportion_confint  
n_interval = proportion_confint(sum(selected_samples), len(selected_samples), method='normal')  
w_interval = proportion_confint(sum(selected_samples), len(selected_samples), method='wilson')
```

ДИ можно управлять:

```
from statsmodels.stats.proportion import samplesize_confint_proportion  
n_samples = int(samplesize_confint_proportion(samples.mean(), required_confidence_interval))
```

1. Дискретные метрики

Z-статистика (для двух выборок)*

Объединенная доля ($\hat{p}$):

- $\hat{p} = (x_1 + x_2) / (n_1 + n_2)$

Пояснение: Это общая оценка доли "успехов" в обеих группах при условии, что H_0 верна.

Расчет Z-статистики:

- $Z = (\hat{p}_1 - \hat{p}_2) / \sqrt{(\hat{p} * (1 - \hat{p}) * (1/n_1 + 1/n_2))}$
- Где:
 - $\hat{p}_1, \hat{p}_2$ — выборочные доли в первой и второй группе.
 - n_1, n_2 — объемы выборок.
 - x_1, x_2 — количество "успехов" в каждой группе.

Интерпретация: Z-статистика показывает, на сколько стандартных ошибок различаются выборочные доли.

*справедливо для несильно скошенных распределений

GitVerse

[Откройте ссылку gitverse.ru](https://gitverse.ru)

1. Дискретные метрики

Доверительный интервал для разности пропорций

Дополнительный метод:

Вместо проверки гипотезы можно построить доверительный интервал (ДИ) для разности долей ($p_1 - p_2$).

Формула (приближенная):

- $(\hat{p}_1 - \hat{p}_2) \pm Z_{\text{крит}} * \sqrt{(\hat{p}_1(1-\hat{p}_1)/n_1) + (\hat{p}_2(1-\hat{p}_2)/n_2)}$

Интерпретация:

- Если ДИ **не содержит 0** → разница **статистически значима** (отвергаем H_0).
- Если ДИ **содержит 0** → разница **не является статистически значимой**.

Преимущество:

ДИ не только показывает значимость, но и оценивает величину эффекта.

2. Анализ конверсий и бинарных метрик

Что такое конверсия и бинарные метрики?

Бинарная метрика (Binary Metric): Событие, которое либо произошло, либо нет.

- Примеры: Клик/не клик, покупка/отказ, подписка/уход

Конверсия (Conversion): Частный случай бинарной метрики — целевое, желаемое действие пользователя.

- Примеры: Успешная регистрация, оплата заказа, переход по рекламе.

Измеряется как доля (Proportion) или процент:

- **Формула:** Конверсия = (Количество успехов) / (Общее количество случаев)
- **Пример:** 50 покупок с 1000 посетителей = конверсия 5%.

Почему это важно?

- Прямо измеряют эффективность бизнеса и продукта.
- Понятны для не-технических специалистов (менеджмент, маркетинг).
- Являются ключевыми KPI (Key Performance Indicator).

Области применения:

- **Маркетинг:** Эффективность рекламных кампаний, email-рассылок.
- **Продукт (Product):** Улучшение юзабилити, воронки продаж.
- **UX/UI:** Тестирование дизайнов, кнопок призыва к действию (CTA).
- **Data Science:** Целевая переменная в задачах бинарной классификации.

2. Анализ конверсий и бинарных метрик

Подводные камни и лучшие практики

Подводные камни:

- **Маленькие выборки:** Высокий риск ложных результатов (шум побеждает сигнал).
- **Множественное тестирование (Peeking):** Если постоянно "подглядывать" на результаты теста, растет вероятность найти ложноположительный результат.
- **Статистическая vs Практическая значимость:** Разница может быть статистически значимой ($p\text{-value} < 0.0001$), но составлять 0.1%, что для бизнеса несущественно.

Лучшие практики:

- **Рассчитывайте мощность теста (Power Analysis)** перед стартом, чтобы определить необходимый размер выборки.
- **Определите MDE (Minimum Detectable Effect)** — минимальный эффект, который имеет для вас бизнес-смысл.
- **Проводите тест до конца**, не останавливая раньше времени.

2. Анализ конверсий и бинарных метрик

Пример использование Критерия Хи-квадрат (Chi-Squared)

Что это? Статистический тест, проверяющий связь между двумя категориальными переменными.

Как применить? Строим таблицу сопряженности (Contingency Table):

Группа	Конвертировались	Не конвертировались	Всего
A (Тест)	a	b	a+b
B (Контроль)	c	d	c+d
Всего	a+c	b+d	N

Результат: p-value.

Интерпретация: Если $p\text{-value} < \alpha$ (обычно 0.05), отвергаем H_0 . Разница **статистически значима**.

GitVerse

[Откройте ссылку gitverse.ru](https://gitverse.ru)

3. Поправки для малых выборок

Проблема малых выборок

Ключевой вопрос: Почему стандартные статистические методы дают сбой при малом N ?

Основные проблемы:

- **Неустойчивость оценок:** Одна-две аномальные точки могут радикально изменить среднее значение и дисперсию.
- **Низкая мощность тестов:** Высокий риск совершить ошибку II рода (не обнаружить существующий эффект).
- **Нарушение предпосылок:** Критические предположения, особенно о нормальности распределения и равенстве дисперсий, проверить практически невозможно.
- **Смещенность оценок:** Выборочная дисперсия является смещенной оценкой генеральной дисперсии.

Когда мы сталкиваемся с малыми выборками?

Области применения:

- Медицинские исследования (редкие заболевания)
- Дорогостоящие или сложные эксперименты
- Пилотные исследования (А/В-тесты на начальном этапе)
- Исследования рынка нишевых продуктов
- Качественный анализ с количественной проверкой

Что считать "малым"?

- Нет универсального числа. Обычно $n < 30$, а часто $n < 15-20$.
- Зависит от задачи: для многомерного анализа "мало" – это когда $n < 10p$ (p - число параметров).

3. Поправки для малых выборок

Поправка 1. Распределение Стьюдента (Т-распределение)


Проблема: При малом n выборочное стандартное отклонение (s) – ненадежная оценка генерального (σ).
Использование нормального распределения (z-критерий) занижает неопределенность.

Решение: Использовать t-распределение.

- Имеет более тяжелые "хвосты".
- Учитывает дополнительную неопределенность через параметр степени свободы ($df = n - 1$).
- Чем меньше n , тем **"тяжелее" хвосты t-распределения**.

Когда использовать: Построение доверительных интервалов и проверка гипотез для среднего значения.

Сравнение распределения Стьюдента для разных степеней свободы



3. Поправки для малых выборок

Поправка 2. Коррекция поправки на смещенность (n-1)

Проблема: Стандартная формула выборочной дисперсии $\Sigma(x - \bar{x})^2 / n$ дает смещенную оценку.

Решение: Использование исправленной (несмещенной) дисперсии:

$$s^2 = \frac{\Sigma(x - \bar{x})^2}{(n - 1)}$$

Интуиция: Деление на **(n-1)** учитывает тот факт, что мы используем саму выборку для оценки среднего ($\bar{x}$), что "съедает" одну степень свободы. Это базовая, но критически важная поправка.

3. Поправки для малых выборок

Поправка 3. Точные тесты (на примере Фишера)

Проблема: Критерий Хи-квадрат ненадежен, когда ожидаемые частоты в таблицах сопряженности малы (<5).

Решение: Точный критерий Фишера (Fisher's Exact Test).

- Рассчитывает точную вероятность наблюдаемой комбинации частот (и всех более крайних) при условии справедливости нулевой гипотезы.
- Не полагается на асимптотическое приближение.

Когда использовать: Анализ таблиц 2x2 (и более) с малыми ожидаемыми частотами.

Контекст: Исследуется эффективность нового препарата против редкого заболевания. Из-за редкости болезни удалось набрать только небольшую группу пациентов.

Данные:

Группа лечения: 12 пациентов получили новый препарат

Группа контроля: 8 пациентов получили плацебо

Результат: Выздоровление через 2 недели

[Откройте ссылку gitverse.ru](https://gitverse.ru)




ТАБЛИЦА СОПРЯЖЕННОСТИ

Группа	Выздоровели	Не выздоровели
Лечение (n=12)	9	3
Контроль (n=8)	2	6

Отношение шансов: 9.00

p-значение: 0.0648

3. Поправки для малых выборок

Поправка 4. Bootstrap (Метод Монте-Карло)



Суть: "Вытягивание самого себя за шнурки ботинок".

Алгоритм:

- Из исходной малой выборки **с возвращением** извлекается множество (например, 10000) псевдовыборок того же размера n .
- Для каждой псевдовыборки вычисляется интересующая статистика (среднее, медиана, коэффициент).
- Эмпирическое распределение этих статистик используется для построения доверительных интервалов и проверки гипотез.

Преимущество: Позволяет оценить ошибку и распределение статистики, не делая строгих предположений о генеральной совокупности

[Откройте ссылку gitverse.ru](https://gitverse.ru)



3. Поправки для малых выборок

Поправка 4. Bootstrap (Метод Монте-Карло)





Исходная выборка: 15 наблюдений

Выборочное среднее: 49.25

Выборочное стандартное отклонение: 10.63


Генерируем 10000 bootstrap-выборок...

ПРОЦЕСС BOOTSTRAP: Извлечение псевдовыборок с возвращением



3. Поправки для малых выборок

Поправка 4. Bootstrap (Метод Монте-Карло)



3. Поправки для малых выборок

Практические рекомендации и предостережения

План действий:

- Всегда используйте t-распределение вместо z для малых n .
- Визуализируйте данные (ящик с усами, точечная диаграмма) для выявления аномалий.
- Если есть сомнения в нормальности – применяйте непараметрические тесты.
- Для таблиц сопряженности с малыми частотами – используйте точный тест Фишера.
- Используйте bootstrap для сложных статистик.

Главное предостережение: Даже с поправками, выводы по малым выборкам остаются **ненадежными**. Интерпретируйте их с крайней осторожностью! Небольшие эффекты невозможно обнаружить, а найденные эффекты могут быть сильно преувеличены.

Мы научились

1. Тестировать бинарные метрики
2. Применять поправки для точных результатов
3. Интерпретировать разницы в пропорциях

Отвѣты на вопросы



План занятия

Непараметрические методы

1. Критерии Манна-Уитни и Вилкоксона
 2. Работа с ненормальными данными
 3. Сравнение методов
- Ответы на вопросы

1. Критерии Манна-Уитни и Вилкоксона

Критерии Манна-Уитни, Вилкоксона

Проблема: Невозможно надежно проверить нормальность распределения.

Решение: Методы, не зависящие от предположения о форме распределения.

- **Знаковый тест / Критерий Вилкоксона (Wilcoxon signed-rank test):** Аналог t-теста для одной выборки или парных наблюдений.
- **Ранговый критерий Манна-Уитни (Mann-Whitney U test):** Аналог t-теста для двух независимых выборок.
- **Преимущества:** Робастность к выбросам, не требуют нормальности.
- **Недостатки:** Обычно менее мощные, чем параметрические аналоги

1. Критерии Манна-Уитни и Вилкоксона

Ограничения параметрических методов

Т-критерий Стьюдента — "золотой стандарт" для сравнения средних значений.

Но он требует соблюдения строгих условий:

- Данные должны иметь **нормальное распределение** (проверяется, например, критерием Шапиро-Уилка).
- Данные должны быть измерены **в интервальной шкале** или шкале отношений.
- Желательна **одинаковая дисперсия** (гомогенность) в группах.

Проблема: Что делать, если эти условия нарушены? (Например, данные имеют скошенное распределение, есть выбросы, или это данные порядковой шкалы — "баллы", "ранги").

1. Критерии Манна-Уитни и Вилкоксона

Непараметрическая статистика как решение

Непараметрические критерии не делают строгих предположений о распределении генеральной совокупности. Они работают не с самими значениями, а с их **рангами** (порядковыми номерами).

Преимущества:

- Робастность (устойчивость) к выбросам.
- Применимость к данным, измеренным в порядковой шкале.
- Можно использовать на малых выборках.

Недостаток: Меньшая мощность (вероятность обнаружить существующий эффект) по сравнению с параметрическими аналогами при выполнении всех их условий.

1. Критерии Манна-Уитни и Вилкоксона

Суть и назначение критерия Манна-Уитни



Назначение: Сравнение **двух НЕЗАВИСИМЫХ** выборок.

Аналог: Независимый t-критерий для двух выборок.

Исследуемый вопрос: "Различаются ли две независимые группы по уровню какого-либо признака?"

Нулевая гипотеза (H_0): Распределения признака в двух группах **одинаковы**.

Альтернативная гипотеза (H_1): Распределения признака в двух группах **различаются** (двусторонняя), или что одна группа "сдвинута" относительно другой (односторонняя).



1. Критерии Манна-Уитни и Вилкоксона

Как работает критерий? (Алгоритм)

Объединить данные из обеих выборок в один ряд.

Проранжировать все значения от меньшего к большему (присвоить ранги от 1 до N, где N — общее количество наблюдений).

Разделить ранжированные данные по двум исходным группам.

Рассчитать сумму рангов для каждой группы (R_1 и R_2).

Вычислить U-статистику для каждой группы:

- $U_1 = n_1 * n_2 + (n_1(n_1+1))/2 - R_1$
- $U_2 = n_1 * n_2 + (n_2(n_2+1))/2 - R_2$
- Где n_1 и n_2 — объемы выборок

За расчетную U-статистику принимается **наименьшая** из U_1 и U_2 .

Рассчитанное значение **U-статистики** сравнивается с **критическим значением U** из специальной таблицы для данных n_1 и n_2 .

Если $U_{\text{расч.}} \leq U_{\text{кр.}}$ → Нулевая гипотеза (H_0) отвергается. Распределения в группах статистически значимо различаются.

Если $U_{\text{расч.}} > U_{\text{кр.}}$ → Нет оснований отвергать H_0 .

Для больших выборок ($n > 30$): Распределение U-статистики приближается к нормальному, и считается **z-статистика** с последующим расчетом **p-value**.

Ключевой вывод: Критерий проверяет, является ли сдвиг в рангах между группами статистически значимым.

GitVerse

[Откройте ссылку gitverse.ru](https://gitverse.ru)

1. Критерии Манна-Уитни и Вилкоксона

Суть и назначение критерия Вилкоксона

Назначение: Сравнение **двух ЗАВИСИМЫХ** (связанных) выборок.

Аналог: Парный t-критерий.

Типичные случаи применения:

- Измерения "до" и "после" воздействия на одной и той же группе.
- Сравнение двух методов измерения на одних и тех же объектах (например, левая и правая рука).
- Сравнение двух условий у совпадающих пар испытуемых.

Нулевая гипотеза (H_0): Распределение разностей между парами измерений симметрично относительно нуля.

Альтернативная гипотеза (H_1): Распределение разностей сдвинуто относительно нуля.

Как работает критерий? (Алгоритм)

Для каждой пары измерений вычислить **разность**.

Ранжировать абсолютные значения разностей (по модулю), игнорируя знак.

Присвоить знаки разностей соответствующим рангам.

Разделить ранги на две группы: с положительными знаками и с отрицательными знаками.

Рассчитать T-статистику: это **меньшая** из двух сумм рангов (суммы положительных или суммы отрицательных рангов).

1. Критерии Манна-Уитни и Вилкоксона

Интерпретация результата теста Вилкоксона

Рассчитанное значение **Т-статистики** сравнивается с **критическим значением Т** из таблицы Вилкоксона.

Если $T_{\text{расч.}} \leq T_{\text{кр.}}$ → Нулевая гипотеза (H_0) отвергается. Сдвиг между парными измерениями статистически значим.

Если $T_{\text{расч.}} > T_{\text{кр.}}$ → Нет оснований отвергать H_0 .

Ключевой вывод: Критерий проверяет, является ли систематический сдвиг в парных измерениях статистически значимым.



GitVerse

[Откройте ссылку gitverse.ru](https://gitverse.ru)

1. Критерии Манна-Уитни и Вилкоксона

Сравнение критериев Манна-Уитни и Вилкоксона

Характеристика	Критерий Манна-Уитни	Критерий Вилкоксона
Тип выборки	Независимые	Зависимые (связанные, парные)
Аналог	Независимый t-критерий	Парный t-критерий
Что сравнивает?	Уровень признака в двух разных группах	Сдвиг признака в одной группе до/после
Основная статистика	U-статистика	T-статистика

2. Работа с ненормальными данными

Данные бывают разными

Тезис: Идеально "чистых" данных не существует. Реальный мир — это шум, выбросы и аномалии.

Ключевые понятия:

- **Аномалия (Anomaly / Outlier)** — объект данных, который значительно отличается от большинства других объектов.
- **"Ненормальность" :**
 - **Ошибка:** Сбой датчика, опечатка, сбой в передаче данных.
 - **Случайное, но реальное событие:** Пиковый спрос во время распродажи.
 - **Важное событие:** Мошенническая операция по кредитной карте, поломка промышленного оборудования.

Почему это проблема?

Тезис: Аномалии могут катастрофически влиять на результаты анализа и моделирования.

Визуализация:

- График: Красивая линейная зависимость.
- График: Та же зависимость с одним выбросом, который полностью меняет линию регрессии.

Последствия:

- **Искажение статистик:** Среднее значение, стандартное отклонение.
- **Снижение качества моделей ML:** Особенно моделей, чувствительных к масштабу (линейная регрессия, k-NN, SVM).
- **Ложные выводы и решения.**

2. Работа с ненормальными данными

Детектирование - Как найти аномалии?

Тезис: Не существует одного "лучшего" метода. Выбор зависит от данных, домена и задач.

Подход 1: Статистические методы

- **Правило 3-х сигм (Z-score):** Для нормально распределенных данных. $|Z\text{-score}| > 3$.
- **Метод межквартильного размаха (IQR):** Устойчив к ненормальности.
 - Нижняя граница = $Q1 - 1.5 * IQR$
 - Верхняя граница = $Q3 + 1.5 * IQR$
- **Плюсы:** Простота, интерпретируемость.
- **Минусы:** Предполагают определенное распределение, плохо работают в многомерном пространстве.

Подход 2: Методы машинного обучения

- **Изолирующий лес (Isolation Forest):** Эффективный алгоритм, который "изолирует" аномалии. Быстрый и хорошо работает с большими наборами данных.
- **Кластеризация (DBSCAN):** Точки, не попавшие в кластеры (шум), считаются аномалиями.
- **One-Class SVM:** Обучает модель на "нормальных" данных и определяет отклонения от нее.
- **Плюсы:** Работают с многомерными данными, не требуют строгих предположений о распределении.
- **Минусы:** Сложнее в настройке и интерпретации.

2. Работа с ненормальными данными

Стратегии обработки

Удаление (Dropping):

Когда применять:

- Аномалия — это однозначно ошибка (например, возраст человека = 200).
- Количество аномалий очень мало и не повлияет на обучение модели.

Риски: Вы можете удалить ценную информацию (например, редкое, но важное событие)

Трансформация:

- **Логарифмирование / Квадратный корень:** Сжимает большой разброс значений.
- **Биннинг (Binning):** Группировка данных в интервалы (например, по возрасту: 0-18, 19-35, 36-60, 60+).
- **Winsorization:** "Обрезка" данных. Замена крайних значений на определенный перцентиль (например, 5-й и 95-й).

Плюсы: Сохраняют все наблюдения.

Минусы: Искажают исходное распределение и связи.

Импутация (Imputation):

- **Медиана / Усеченное среднее:** Более робастные меры центральной тенденции.
- **Прогнозирующие модели:** Использовать другие переменные, чтобы предсказать "нормальное" значение для аномальной точки.

Важно: Не маскируйте настоящие, важные аномалии (например, мошенничество).

2. Работа с ненормальными данными

Модели, устойчивые к аномалиям

- **Деревья решений и ансамбли (Random Forest, Gradient Boosting):** Разбивают пространство признаков, основываясь на рангах, а не на абсолютных значениях.
- **Метрики, устойчивые к выбросам:** Например, MAE (Mean Absolute Error) вместо MSE (Mean Squared Error) в регрессии, т.к. MSE сильнее штрафует за большие ошибки.

2. Работа с ненормальными данными

Практический пайплайн работы

- **Понимание домена:** Поговорите с экспертом. Это ошибка или ценная аномалия?
- **Визуализация:** Постройте графики (Boxplot, Scatter plot, Histogram).
- **Детектирование:** Примените подходящие методы (IQR, Isolation Forest).
- **Анализ:** Изучите природу найденных аномалий.
- **Обработка / Моделирование:** Выберите стратегию (удалить, трансформировать, импутировать) или использовать робастную модель.
- **Валидация:** Оцените качество модели на тестовой выборке. Сравните результаты до и после обработки.



3. Сравнение методов

Сравнительная таблица методов

Критерий	Манна-Уитни	Вилкоксон (парный)	Бутстрап
Тип данных	Порядковые, непрерывные	Порядковые, непрерывные	Любые
Тип выборок	Независимые	Зависимые (парные)	Любые
Что сравнивает	Распределения / ранги	Ранги разностей	Распределение любой статистики
Устойчивость к выбросам	Высокая	Высокая	Высокая
Вычислительная сложность	Низкая	Низкая	Высокая (требуется множество итераций)

3. Сравнение методов

Практический пример: Сравнение среднего чека (AOV)



Сценарий: Сравниваем две промо-акции. Распределение чеков имеет длинный хвост (немного очень крупных покупок).

Проблема t-теста: Выбросы сильно влияют на среднее и оценку дисперсии, что может исказить результат.

Применяем методы:

- **Манна-Уитни:** Сравниваем, является ли распределение сумм в группе В "стохастически больше", чем в А. *Результат: $p\text{-value} = 0.04$.*
- **Бутстрап:** Строим 10 000 бутстрап-выборок для среднего чека в каждой группе, строим доверительные интервалы и смотрим на их перекрытие. Результат: 95% ДИ для разности средних не включает ноль.

Вывод: Оба непараметрических метода согласованно показывают статистически значимый эффект, в то время как t-тест мог дать ненадежный результат.

[Откройте ссылку gitverse.ru](https://gitverse.ru)

3. Сравнение методов

Ключевые выводы и рекомендации

Непараметрические методы — это не "волшебная таблетка", а инструмент для конкретных задач.

Выбор метода зависит от:

- **Типа данных:** Непрерывные vs. порядковые.
- **Типа выборок:** Независимые vs. зависимые.
- **Анализируемой метрики:** Среднее vs. Медиана vs. Другая сложная статистика.

Практический пайплайн анализа:

- Всегда начинайте с визуализации данных (гистограммы, box-plots).
- Проверяйте предпосылки параметрических тестов (нормальность, гомогенность дисперсий).
- Если предпосылки нарушены — используйте непараметрический аналог.
- Для сложных метрик по умолчанию используйте **бутстрап**.

Итог: Использование непараметрических методов повышает надежность и достоверность ваших А/В-тестов в реальных, "неидеальных" условиях.

План занятия

Непараметрические методы

1. Проблема множественного тестирования
 2. Поправки Бонферрони и Холма
 3. Стратегии минимизации ошибок
- Ответы на вопросы

1. Проблема множественного тестирования

Что такое проблема множественного тестирования?

Суть проблемы:

- При проведении множественных проверок (A/A-тестов или A/B-тестов многих гипотез) вероятность получить ложноположительный результат (ошибку I рода) растет → **Family-wise error rate, FWER**
- Мы считаем результат "статистически значимым", когда $p\text{-value} < 0.05$. Это означает **5%-ный шанс обнаружить эффект, которого на самом деле нет.**

Простая аналогия:

- Бросок монетки: Вероятность выпадения "орла" 10 раз подряд мала.
- Но если 1000 человек бросят монетку 10 раз, очень вероятно, что у кого-то выпадет 10 "орлов" подряд.
- Так и в A/B-тестах: чем больше тестов/метрик, тем выше шанс "найти" несуществующее улучшение.

Ключевая формула:

- Вероятность хотя бы одной ложноположительной находки $FWER = 1 - (1 - \alpha)^n$
- Где α = уровень значимости (0.05), n = количество проверок.
- Пример: При 20 независимых тестах вероятность хотя бы одной ложной находки = **$1 - (0.95)^{20} \approx 64\%$** (а не 5%!).

1. Проблема множественного тестирования

Что такое проблема множественного тестирования?

```
[20]: import random
import pandas as pd

# Упрощенная версия для поиска только случаев с одними орлами
experiments_with_all_heads = []
experiment_count = 0

print("Поиск экспериментов, где все 10 результатов - 'Орёл':")
print("-" * 50)
N = 1000

while experiment_count < N:
    experiment_count += 1

    # Генерируем 10 бросков
    tosses = ['Орёл' if random.randint(0, 1) == 0 else 'Решка' for _ in range(10)]

    # Проверяем, все ли результаты - орлы
    if all(toss == 'Орёл' for toss in tosses):
        experiments_with_all_heads.append({
            'Номер': experiment_count,
            'Результаты': ''.join(tosses)
        })

# Выводим результаты
if experiments_with_all_heads:
    print(f"Найдено {len(experiments_with_all_heads)} случаев:\n")
    for exp in experiments_with_all_heads:
        print(f"Эксперимент №{exp['Номер']}: {exp['Результаты']}")
else:
    print("Не найдено ни одного случая, где все 10 результатов - 'Орёл'")

print(f"\nВероятность: {len(experiments_with_all_heads)}/{N} = "
      f"{len(experiments_with_all_heads)/N:.4%}")
```

Поиск экспериментов, где все 10 результатов - 'Орёл':

Найдено 2 случая:

Эксперимент №177: Орёл Орёл Орёл Орёл Орёл Орёл Орёл Орёл Орёл Орёл
Эксперимент №684: Орёл Орёл Орёл Орёл Орёл Орёл Орёл Орёл Орёл Орёл

Вероятность: 2/1000= 0.2000%

```
[32]: import random
N = 10000
def simple_simulation():
    print("Поиск экспериментов, где все {N} результатов одинаковые")
    print("-" * 50)
    matching_experiments = []
    n_match = 6
    for exp_num in range(1, N+1):
        # Генерируем 10 бросков кубика
        rolls = [random.randint(1, 6) for _ in range(n_match)]
        # Проверяем, все ли значения одинаковые
        first_roll = rolls[0]
        all_same = True
        for roll in rolls:
            if roll != first_roll:
                all_same = False
                break
        if all_same:
            matching_experiments.append({
                'experiment': exp_num,
                'digit': first_roll,
                'rolls': rolls
            })
    # Выводим результаты
    if matching_experiments:
        print(f"Найдено {len(matching_experiments)} экспериментов с одинаковыми результатами:\n")
        # Группируем по цифре
        by_digit = {}
        for exp in matching_experiments:
            digit = exp['digit']
            if digit not in by_digit:
                by_digit[digit] = []
            by_digit[digit].append(exp)
        # Выводим сгруппированные результаты
        for digit in sorted(by_digit.keys()):
            print(f"Цифра {digit} ({len(by_digit[digit])} случаев):")
            for exp in by_digit[digit]:
                rolls_str = ''.join(str(x) for x in exp['rolls'])
                print(f"Эксперимент {exp['experiment']}: {rolls_str}")
            print(f"Общая вероятность: {len(matching_experiments)}/{N} = {len(matching_experiments)/1000:.6%}")
    else:
        print("Не найдено ни одного эксперимента, где все результаты одинаковые.")
        print("Это соответствует теоретической вероятности (очень мала).")
    return matching_experiments
```

results = simple_simulation()

Поиск экспериментов, где все {N} результатов одинаковые
=====

Найдено 2 экспериментов с одинаковыми результатами:


Цифра 2 (1 случаев):
Эксперимент 1510: 2 2 2 2 2 2

Цифра 5 (1 случаев):
Эксперимент 7668: 5 5 5 5 5 5

Так ли редки «редкие» события?

1. Проблема множественного тестирования

Что такое проблема множественного тестирования?



1. Проблема множественного тестирования

Проявления проблемы в A/B-тестировании

Тестирование множества гипотез одновременно:

- Сравниваем не одну версию B с A, а сразу B, C, D...
- Каждое сравнение (A/B, A/C, A/D) — это отдельная проверка, увеличивающая общий шанс ошибки.

Отслеживание множества метрик:

- В одном тесте мы смотрим на конверсию, средний чек, отток, глубину просмотра и т.д.
- Проверка каждой метрики на значимость — это отдельный статистический тест.

Пил-эффект (Peeking Problem / Data Dredging):

- Многократная проверка результатов до окончания теста.
- Каждый "взгляд" на данные — это новая проверка гипотезы. Рано или поздно p-value случайно опустится ниже 0.05.

Результат:

- **Ложные открытия:** Мы внедряем изменения, которые не работают.
- **Потеря ресурсов:** Тратим время и деньги на разработку неэффективных фич.
- **Недоверие к данным:** Инструмент A/B-тестирования теряет свою надежность.

1. Проблема множественного тестирования

Примеры методов борьбы с проблемой

Поправка Бонферрони (Bonferroni Correction)

- **Принцип:** Делим уровень значимости α на количество проверок n .
- **Пример:** При 10 метриках новый порог значимости: $\alpha = 0.05 / 10 = 0.005$.
- **Плюсы:** Очень простой и консервативный метод.
- **Минусы:** Слишком строгий, сильно снижает мощность теста (шанс обнаружить реальный эффект).

Выделение одной первичной метрики (Primary Metric)

- **Принцип:** Нужно заранее определить одну главную метрику для принятия решения по тесту. Только для нее применяется стандартный уровень значимости (например, 0.05).
- Все остальные (вторичные) метрики анализируются как исследовательские и требуют более осторожной интерпретации.

Использование более сложных поправок (False Discovery Rate - FDR)

- **Принцип:** Контролируется не вероятность хотя бы одной ошибки, а долю ложноположительных результатов среди всех положительных результатов.
- **Плюсы:** Менее консервативен, чем Бонферрони, сохраняет большую мощность теста.

Планирование и дисциплина:

- **Заранее определять:** гипотезы, основные метрики, длительность теста.
- **Не подглядывать часто** в результаты.
- Использовать **последовательный анализ** (Sequential Testing), если нужно часто проверять данные.

Решение:

- Использовать методы поправки на множественные сравнения для контроля **семейного уровня ошибки (Family-Wise Error Rate, FWER)** — вероятности сделать хотя бы одну ошибку I рода в серии тестов.

1. Проблема множественного тестирования

False Discovery Rate (FDR)

Что такое FDR?

- **Парадигма:** Допускаем, что среди всех гипотез H_1 (объявленных "открытиями") какая-то **доля будет ложной**.
- **Определение:** FDR = Ожидаемая доля ложноположительных результатов среди всех значимых результатов.
- **Интерпретация:** Если мы установили FDR на уровне 0.05 и получили 100 значимых результатов, то ожидаем, что примерно 5 из них — ложные открытия.

Ключевой метод: Benjamini-Hochberg (BH)

Алгоритм:

- Ранжируем p-values по возрастанию: $p_1 \leq p_2 \leq \dots \leq p_m$, где m — общее число тестов.
- Для каждого p-value находим критический уровень: $(i/m) * Q$, где i — ранг, Q — желаемый уровень FDR (например, 0.05).
- Находим наибольшее k , для которого $p_k \leq (k/m) * Q$.
- Все гипотезы с p-value от p_1 до p_k отклоняем.

Области применения: Геномика (поиск дифференциально экспрессируемых генов), нейровизуализация (анализ вокселей), поиск паттернов в больших данных, скрининг, генерация гипотез, поиск наиболее перспективных кандидатов для дальнейшего изучения и т.п.

Когда НЕ использовать: В задачах, где даже одна ошибка критична (например, клинические испытания нового опасного лекарства, проверка безопасности систем).

1. Проблема множественного тестирования

False Discovery Rate (FDR)

fdr_bh - стандартный Benjamini-Hochberg (независимые или положительно коррелированные тесты)

fdr_by - Benjamini-Yekutieli (корректно для любых зависимостей, но более консервативен)

fdr_tsbh - двухступенчатый Benjamini-Hochberg (мощнее для однородных данных)

fdr_tsbky - двухступенчатый Benjamini-Krieger-Yekutieli (для большого числа гипотез)

```
[2]: import numpy as np
import statsmodels.stats.multitest as mt
```

```
# Пример p-values
```

```
p_values = [0.001, 0.008, 0.039, 0.041, 0.12, 0.25, 0.5, 0.9]
```

```
# Метод Бенджамини-Хохберга (стандартный FDR)
```

```
rejected, pvals_corrected, _, _ = mt.multipletests(
```

```
    p_values,
    alpha=0.05, # уровень FDR (q-value)
    method='fdr_bh' # Benjamini-Hochberg
)
```

```
print("Исходные p-values:", p_values)
```

```
print("Отклоняем гипотезы?", rejected)
```

```
print("Скорректированные p-values (q-values):", pvals_corrected)
```

```
print(f"\nПри уровне FDR=0.05 отклоняем {sum(rejected)} гипотез")
```

```
Исходные p-values: [0.001, 0.008, 0.039, 0.041, 0.12, 0.25, 0.5, 0.9]
```

```
Отклоняем гипотезы? [ True  True False False False False False]
```

```
Скорректированные p-values (q-values): [0.008      0.032      0.082      0.082      0.192      0.33333333
0.57142857 0.9      ]
```

```
При уровне FDR=0.05 отклоняем 2 гипотез
```

```
# Разные методы коррекции
methods = ['fdr_bh', 'fdr_by', 'fdr_tsbh', 'fdr_tsbky']

for method in methods:
    rejected, corrected_p, _, _ = mt.multipletests(
        p_values, alpha=0.05, method=method
    )
    print(f"{method}: отклонено {sum(rejected)} из {len(p_values)}")
```

```
fdr_bh: отклонено 2 из 8
```

```
fdr_by: отклонено 1 из 8
```

```
fdr_tsbh: отклонено 2 из 8
```

```
fdr_tsbky: отклонено 2 из 8
```

2. Поправки Бонферрони и Холма

Поправка Бонферрони

Суть метода:

- Новый уровень значимости для каждого отдельного теста вычисляется как: $\alpha^* = \alpha / m$, где m — общее количество статистических тестов.
- Пример: Для $\alpha = 0.05$ и 10 тестов: $\alpha^* = 0.05 / 10 = 0.005$.
- Тест считается значимым, только если его **p-value** $< \alpha^*$.

Преимущества:

- Простота вычисления и понимания.
- Очень строгий контроль над FWER (гарантирует, что $\text{FWER} \leq \alpha$).

Недостатки:

- **Высокий риск ложно-отрицательных ошибок (Ошибка II рода):** Многие реальные эффекты могут быть пропущены.
- Слишком консервативен, особенно при большом количестве тестов (снижает мощность анализа).

```
from statsmodels.sandbox.stats.multicomp import multipletests  
p_adjusted = multipletests(pvals, alpha = FWER, method='bonferroni')
```


2. Поправки Бонферрони и Холма

Поправка Холма (Шаг-вниз метод)

Суть метода (пошагово):

- Упорядочить все p-value по возрастанию: $p(1) \leq p(2) \leq \dots \leq p(m)$.
- Сравнить наименьшее p-value с поправкой Бонферрони: $p(1)$ с α/m .
- Если $p(1) < \alpha/m$, гипотеза отвергается, и мы переходим к следующей.
- Сравнить $p(2)$ с $\alpha/(m-1)$.
- Сравнить $p(3)$ с $\alpha/(m-2)$ и так далее...
- **Процесс останавливается**, как только находится $p(k) \geq \alpha/(m - k + 1)$. Все последующие гипотезы не отвергаются.

Ключевое отличие от Бонферрони:

- Поправка **адаптивная** — для каждого p-value используется свой порог значимости.


Преимущества:

- **Всегда более мощный**, чем поправка Бонферрони (меньше шансов пропустить реальный эффект).
- Так же контролирует FWER на уровне α , но делает это менее грубо.

`p_adjusted = multipletests(pvals, alpha = FWER, method='holm')`

2. Поправки Бонферрони и Холма

Сравнение поправок



2. Поправки Бонферрони и Холма

Сравнение поправок

Критерий	Поправка Бонферрони	Поправка Холма
Сложность	Очень простая	Немного сложнее
Риск ложного срабатывания	Высокая	Умеренная
Мощность	Низкая	Выше, чем у Бонферрони
Процедура	Один порог для всех тестов	Пошаговая, с разными порогами
Когда использовать?	Когда критически важна минимизация ложных срабатываний (например, в клинических испытаниях).	Стандартный выбор для большинства задач, где нужен контроль над FWER. Более сбалансированный подход.

Заключение:

- Обе поправки решают проблему множественных сравнений, контролируя FWER.
- **Бонферрони** — простой, но грубый инструмент.
- **Холм** — более "умный" и мощный метод, рекомендуемый к использованию по умолчанию

3. Стратегии минимизации ошибок

Планирование и инфраструктура

Приоритизация и декомпозиция:

- **Сильная первичная гипотеза:** Четко определите одну главную метрику (Primary Metric) до запуска. Поправки применяются ко всем остальным.
- **Стратификация тестов:** Разделите тесты на независимые "семейства" (например, по функциональным областям: поиск, рекомендации, UI). Применяйте поправки внутри каждого семейства.

Техническая реализация:

- Использование готовых платформ для экспериментов (Google Optimize, VWO, и др.), которые имеют встроенную поддержку поправок МНТ.
- Автоматическое применение поправки при анализе множественных сегментов или метрик.

Культура принятия решений:

- **"Одна история данных":** Все решения основываются на поправленных, а не на "сырых" p-value.
- **Репликация результатов:** Лучший способ проверить результат — повторить тест или провести A/A-тест для проверки системы.

3. Стратегии минимизации ошибок

Ключевые шаги для минимизации ошибок множественного тестирования

На этапе ПЛАНИРОВАНИЯ:

- Сформулируйте 1-2 Primary метрики. Заранее определите, какие метрики и сегменты будут анализироваться.
- Рассчитайте мощность с учетом поправок (увеличьте размер выборки).

На этапе АНАЛИЗА:

- Для Primary метрики можно использовать стандартный уровень значимости.
- Для всех **вторичных метрик, сегментов и множественных групп** обязательно примените поправку.

На этапе ПРИНЯТИЯ РЕШЕНИЯ:

- Основывайте решение на Primary метрике и поправленных значениях для остальных.
- Если эффект есть только в подсегменте, но не в общей популяции, трактуйте это как **гипотезу для следующего теста**, а не как готовое решение к внедрению.

Мы научились

1. Рассчитывать дискретные метрики
2. Использовать непараметрические методы
3. Познакомились с множественными сравнениями

Ответы на вопросы



**Спасибо
за внимание!**

