



A/B-тестирование

Модуль 3: Дизайн эксперимента

План модуля

Дизайн эксперимента

1. Планирование теста
2. Работа с данными
3. Инструменты анализа

План занятия

Планирование теста

1. Расчет размера выборки
 2. Стратификация и рандомизация
 3. Определение длительности
- Ответы на вопросы

1: Расчет размера выборки

Зачем нам считать размер выборки?


Цель: Обнаружить статистически значимый эффект, если он есть и не замечать незначительного эффекта. Т.е. **контролировать Ошибки I и II рода**

Что нужно, чтобы посчитать?

Формула (общий вид): Размер выборки = $f(\alpha, \beta, MDE, \text{Базовая конверсия}, \text{Дисперсия})$

Параметры:

- **Уровень значимости (α):** 0.05 (5%)
- **Статистическая мощность ($1-\beta$):** 0.8 (80%)
- **MDE (Minimum Detectable Effect):** Минимальный интересный нам эффект (например, 5% относительного изменения).
- **Базовая конверсия (p_{control}):** Текущее значение метрики в контрольной группе.
- **Дисперсия (вариабельность) данных.**





1: Расчет размера выборки

Что делать, если данные ненормальны?

Описание проблемы: Стандартные формулы (для долей) не работают. Распределение имеет "длинный хвост".

Решения:

- **Бутстрап:** Многократное случайное ресемплирование имеющихся данных для оценки распределения и мощности. Практическое действие: Использовать библиотеки типа `scipy.bootstrap`.
- **Преобразование данных:** Логарифмирование, преобразование Бокса-Кокса для нормализации распределения перед расчетом. Действие: Применить преобразование, рассчитать размер выборки для преобразованной метрики.
- **Непараметрические тесты (Манна-Уитни):** Менее мощные, требуют больше данных. Расчет размера выборки для них сложнее, часто используется бутстрап.
- **Метрики-показатели (ОЕС):** Перейти с непрерывной метрики на бинарную (например, "доход > 0").



2. Стратификация и рандомизация

Зачем нужна стратификация и рандомизация?

Обеспечиваем честное сравнение

Рандомизация:

- **Что это?** Случайное распределение пользователей в группы А и В.
- **Цель:** Уравнять все известные и неизвестные факторы между группами.

Стратификация:

- **Что это?** Предварительное разделение пользователей на однородные подгруппы (страты) перед рандомизацией.
- **Цель:** Гарантировать, что в группах А и В будет одинаковое соотношение ключевых сегментов.



2. Стратификация и рандомизация



Стратификация: действия при недостатке данных

Описание проблемы: В некоторых стратах (например, "платящие пользователи") м.б. слишком мало пользователей. Это приводит к высокой вариативности внутри страты.

Решения:

- **Укрупнение страт:** Объединить редко встречающиеся страты в более крупные (например, объединить "1 покупку" и "2-3 покупки" в страту "Малоактивные").
- **Использование ковариат* (CUPED):** При анализе результатов использовать стратирующую переменную как ковариату для уменьшения дисперсии. Это позволяет получить точность стратификации без ее жесткого контроля на этапе разделения.
- **Пропорциональное распределение:** Не стратифицировать по редкому признаку, а увеличить общий размер выборки, чтобы редкие пользователи "набрались" естественным путем

РЕШЕНИЕ: Все страты имеют достаточный размер для надежного анализа



2. Стратификация и рандомизация

Примеры ковариат

🎵 **Стриминговый сервис:**

Ковариата: День недели (пятница vs понедельник)

Целевая метрика: Время прослушивания

Эксперимент: Новая рекомендательная система

🛒 **Интернет-магазин:**

Ковариата: Источник трафика (поиск vs социальные сети)

Целевая метрика: Конверсия в покупку

Эксперимент: Новый дизайн корзины

🏠 **Финтех приложение:**

Ковариата: Кредитный рейтинг пользователя

Целевая метрика: Вероятность одобрения заявки

Эксперимент: Новый алгоритм скоринга

🎮 **Игровая платформа:**

Ковариата: Время суток (вечер vs утро)

Целевая метрика: Время в игре

Эксперимент: Новая система достижений

3. Определение длительности

Факторы, влияющие на длительность теста

Формула (основная):

*Длительность = (Размер выборки на группу * 2) / Ежедневный трафик*

Ключевые факторы:

- Рассчитанный размер выборки (главный фактор).
- Ежедневный трафик, попадающий в эксперимент.
- Еженедельная сезонность (например, пики в выходные).

Важное правило: Не проводите тест меньше, чем **полный тестируемый цикл**. Например 1 неделя, чтобы нивелировать эффект "дня недели".

3. Определение длительности

Примеры ежедневного трафика для разных отраслей и сценариев

Электронная коммерция (E-commerce)

Единица трафика: Уникальный посетитель сайта/приложения.

- **Крупный маркетплейс** (Ozon, Wildberries): Миллионы уникальных посетителей в день. Они могут запустить сотни A/B-тестов одновременно, так как трафик позволяет быстро набрать большую выборку.
- **Средний нишевой интернет-магазин** (например, продающий эко-косметику): Тысячи или десятки тысяч уникальных посетителей в день.
- **Маленький локальный магазин:** Сотни посетителей в день. Для них A/B-тест кнопки "Купить" может идти несколько месяцев, что часто бессмысленно.

Мобильные приложения (Mobile Apps)

Единица трафика: Уникальный активный пользователь (Daily Active User - DAU).

- **Супер-приложение (Likee, VK):** Миллионы DAU. Могут тестировать все: от цвета иконки до нового алгоритма ленты.
- **Приложение для трекинга финансов:** Десятки или сотни тысяч DAU.
- **Нишевое приложение для медитации:** Тысячи DAU. Тестирование крупных изменений будет занимать недели.

SaaS (Software as a Service)

Единица трафика: Уникальный активный пользователь или сессия.

- **Крупная B2B платформа** (например, CRM-система): Десятки тысяч активных пользователей в день. Могут тестировать интерфейс для разных ролей пользователей.
- **Стартап B2B-SaaS с подпиской:** Сотни пользователей в день. Трафик ограничен, поэтому тесты часто длятся долго и нацелены на ключевые действия (активация, переход на платный тариф).

3. Определение длительности

Примеры ежедневного трафика для разных отраслей и сценариев

Онлайн-медиа и развлечения

Единица трафика: Уникальный посетитель сайта/зритель.

- **Крупный новостной портал** (RBC, Mail.ru): Миллионы посетителей в день. Легко тестируют заголовки статей, расположение блоков, форму подписки.
- **Нишевой образовательный блог:** Тысячи посетителей в день.

Услуги (Онлайн-запись, доставка еды)

Единица трафика: Уникальный пользователь, совершающий целевое действие.

- **Крупный сервис доставки еды (Yandex Еда, Delivery Club):** Сотни тысяч пользователей, которые ищут рестораны и делают заказы ежедневно.
- **Сервис онлайн-записи к врачу в конкретном городе:** Сотни или тысячи пользователей, просматривающих доступные слоты.

3. Определение длительности

Формула для клинических испытаний

Формула для клинических испытаний

Длительность (в днях) = Период набора + Период наблюдения

Где:

1. Период набора пациентов (Recruitment Period):

Период набора (дни) = (Общий размер выборки) / (Скорость включения пациентов)

Общий размер выборки: (Размер группы × 2) для двух групп (А и В).

Скорость включения пациентов: Количество пациентов, которых удастся **рандомизировать в исследование за один день**. Это аналог "ежедневного трафика", но это очень маленькая и непостоянная величина.

2. Период наблюдения (Follow-up Period):

Это время, в течение которого за каждым пациентом наблюдают, чтобы оценить эффект лечения. Этот период **фиксированный** и определяется протоколом исследования (например, 28 дней, 3 месяца, 1 год). Период наблюдения **не зависит** от скорости набора.

3. Определение длительности

Пример расчета для маленькой группы

Тестируется новое лекарство от редкого заболевания.

Цель: Сравнить новое лекарство (группа А) со стандартным (группа В).

Рассчитанный размер выборки: Из-за редкости болезни и строгих критериев, статистику рассчитали, что нужно **30 человек в каждую группу**. Итого **60 пациентов**.

Скорость включения: В исследовании участвует 10 клиник. В среднем, они вместе находят и включают **2 подходящих пациента в неделю** (~0.285 пациента в день).

Период наблюдения: По протоколу, для оценки основного показателя эффективности нужно наблюдать пациентов **90 дней**.

Расчет:

Период набора:

- 60 пациентов / 2 пациента/неделю = 30 недель.
- **В днях:** 30 недель × 7 дней = 210 дней (~7 месяцев).

Период наблюдения: + 90 дней.

Общая длительность исследования:

210 дней (набор) + 90 дней (наблюдение) = 300 дней (~10 месяцев).

Важный нюанс: Первый пациент, включенный в исследование, завершит его через 210 + 90 = 300 дней, а последний — через 90 дней (так как его период наблюдения начнется в конце периода набора).

3. Определение длительности

Что делать, если данных все равно недостаточно?

Использование адаптивных дизайнов (Adaptive Designs):

- Можно начать с меньшего размера выборки и на промежуточном анализе пересчитать его, используя полученные данные об изменчивости.

Многоцентровые международные исследования (Multi-center Trials):

- Включение в исследование медицинских центров из разных стран и регионов для увеличения пула потенциальных пациентов.

Изменение дизайна исследования:

- **Перекрестный дизайн (Crossover):** Каждый пациент получает и терапию А, и терапию В в разной последовательности. Это позволяет сократить размер выборки, так как каждый пациент является своим собственным контролем.
- **Дизайн "n-of-1":** Индивидуальное тестирование терапии на одном пациенте. Результаты затем агрегируются.

Пересмотр конечных точек:

- Использование более чувствительных или ранних конечных точек (суррогатных маркеров), которые требуют меньшего времени наблюдения и меньшего количества пациентов для достижения статистической мощности.

3. Определение длительности

Эффект новизны и другие искажения


Проблемы:

- **Эффект новизны:** Пользователи временно активно взаимодействуют с новым feature.
- **Эффект обучения:** Пользователям нужно время, чтобы привыкнуть к изменению.
- **Внешние события:** Праздники, рекламные акции, новости.

Важно: Учитывать в длительности теста "период стабилизации".

- **Действие:** Запустить тест и первые 3-5 дней данных считать "адаптационными", не включать их в финальный анализ, либо анализировать отдельно.

□ Динамика метрики во времени: Эффекты обучения, новизны и внешних воздействий



3. Определение длительности

Действия при недостатке трафика или скошенных данных

Проблема 1: Недостаточно трафика для быстрого набора выборки.

- **Решение:** Увеличить длительность, чтобы набрать достаточный размер выборки. Но! Слишком долгий тест (>4 недель) рискован из-за внешних факторов.
- Альтернатива: Пересмотреть MDE — возможно, мы можем детектировать более крупный эффект с меньшей выборкой.


Проблема 2: Данные сильно скошены (например, Revenue).

- **Решение для анализа:** Использовать метрику ARPPL (Average Revenue Per Paying User) вместо ARPU. Это сфокусируется только на платящих пользователях, уменьшив скос.
- **Решение для планирования:** Рассчитывать размер выборки отдельно для двух метрик:
 - Основная метрика: Конверсия в покупку (бинарная, менее скошена).
 - Вторичная метрика: ARPPL (для платящих).


Действие:

Размер выборки будет определяться по метрике, которой требуется большая выборка.

ARPU (Average Revenue Per User)
Сильно скошенное распределение



ARPPL (Average Revenue Per Paying User)
Распределение платящих пользователей



3. Определение длительности

Чек-лист планирования теста

Выбор метрики: Определите главную и второстепенные метрики.

Анализ распределения: Проверьте метрики на нормальность и скос.

Расчет размера выборки: Используйте подходящий метод (t-test, бутстрап) в зависимости от пункта 2.

Стратификация: Определите ключевые страты и план рандомизации.

Определение длительности: Учтите трафик, сезонность и период стабилизации.

План анализа: Заранее решите, как будете обрабатывать выбросы и какие тесты применять.

Мы научились

1. Рассчитывать необходимый размер выборки
2. Проектировать схемы рандомизации
3. Оптимизировать длительность теста

Отвѣты на вопросы



План занятия

Работа с данными

1. EDA для A/B-тестов
 2. Обработка выбросов и пропусков
 3. Проверка баланса групп
- Ответы на вопросы

1. EDA для A/B-тестов

Что такое EDA и зачем оно нужно в A/B-тестах?

Определение: Exploratory Data Analysis (Разведочный анализ данных) — это подход к анализу данных для выявления основных закономерностей, аномалий и проверки гипотез.

Цели в контексте A/B-теста:

Понимание данных: Что представляют собой метрики? (например, Revenue, CTR, Session Duration).

Поиск аномалий: Обнаружение выбросов и пропущенных значений.

Оценка распределений: Являются ли данные нормальными? Есть ли сильное смещение (скос)?

Предварительная проверка гипотезы: Есть ли визуальная разница между группами?

! Рискový подход

Сырые данные

Пропуски, выбросы и несбалансированные группы остаются без внимания



Пропуск EDA

Разведочный анализ данных игнорируется, сразу применяются статистические тесты



Некорректная обработка выбросов

Выбросы либо полностью игнорируются, либо грубо удаляются без анализа их природы



Игнорирование баланса групп

Надежда на случайность распределения, без проверки сходства групп



Ошибочные выводы

Ложные значимости, невалидные результаты, принятие неверных бизнес-решений

✓ Правильный подход

Сырые данные

Систематизированный датасет с пониманием структуры и возможных проблем



Полноценный EDA-анализ

Визуализация распределений, анализ временных рядов, проверка баланса групп



Корректная обработка данных

Винсоризация выбросов, стратегическая импутация пропусков, стратификация



Статистическая проверка баланса

CUPED-коррекция, проверка сходства групп перед анализом результатов



Валидные результаты

Статистически значимые, надежные выводы для принятия бизнес-решений

1. EDA для A/B-тестов



Ключевые методы EDA для A/B-тестов

Описательная статистика: `df.describe()` (агрегатные функции, количественные оценки и пр.), нормальность

Визуализация распределений: Гистограммы / Плотности (KDE), Box-plot.

Визуализация временных трендов: Линейные графики по дням.

1. ОСНОВНЫЕ СТАТИСТИКИ ДОХОДА ПО ГРУППАМ:

	count	mean	std	min	25%	50%	75%	\
group								
A	482.0	24.632249	37.232507	1.262108	10.408785	18.176587	27.766415	
B	518.0	32.736179	56.796414	0.528932	13.263876	21.900560	34.343952	




	max
group	
A	500.398618
B	617.766182

2. ДОПОЛНИТЕЛЬНАЯ СТАТИСТИКА:

	coef_of_variation	skewness	outliers_3std
group			
A	1.511535	8.578428	5
B	1.734974	7.029410	9

3. ПРОВЕРКА НОРМАЛЬНОСТИ (тест Шапиро-Уилка):

Группа A: $W=0.3705$, $p\text{-value}=0.0000$ (не нормальное)
Группа B: $W=0.3408$, $p\text{-value}=0.0000$ (не нормальное)



1. EDA для A/B-тестов

Интерпретация результатов EDA: что делать дальше?

Если данные ненормальные и сильно скошены:


- **Проблема:** Стандартные t-тесты невалидны.
- **Действия:** Бутстрап, непараметрические тесты, преобразования.

Если данных недостаточно:

- **Проблема:** Низкая мощность теста.
- **Действия:** Продолжить тест, пересмотреть метрику.

Если данные зашумлены или неполные:

- **Проблема:** Искажение данных.
- **Действия:** Очистка данных*.



***Следует выполнять с учетом законодательных, нормативных и регуляторных ограничений.**

2. Обработка выбросов и пропусков




Стратегии обработки выбросов

Анализ природы:

Ошибка vs. Реальное значение.

Методы обработки:

- Не трогать
- Винсоризация*
- Удаление.



**Винсоризация - это преобразование статистики путём ограничения экстремальных значений в статистических данных для уменьшения влияния возможных ложных выбросов*

2. Обработка выбросов и пропусков

Пропущенные значения (Missing Data)

Типы пропусков: MCAR, MAR, MNAR.

Обнаружение: `df.isnull().sum()`, визуализация

MCAR (Missing Completely At Random) — полностью случайные пропуски, вероятность пропуска не зависит ни от каких других данных. Например, случайный сбой при записи данных. Такой механизм считается самым желательным для анализа данных, так как не вносит искажений.

MAR (Missing At Random) — пропуски, зависящие от других имеющихся данных. Например, мужчины реже указывают свой вес, чем женщины. Здесь пропуск в «весе» зависит от значения в колонке «пол».

MNAR (Missing Not At Random) — самый сложный случай, пропуск зависит от самого пропущенного значения. Например, люди с очень высоким доходом чаще скрывают эту информацию. При таком механизме просто игнорировать или исключить пропуски уже нельзя, так как это приведёт к значительному искажению распределения статистических свойств выборки.

2. Обработка выбросов и пропусков

Стратегии обработки пропусков


Удаление: Для MCAR и малого % MAR/MNAR.

Импутация: Мода, медиана, среднее, модели

Индикатор пропуска: Для MAR/MNAR.

age	income	education	high_income_indicator
25	50000	Bachelor	0
32	62000	Master	0
NaN	55000	NaN	1
28	NaN	Bachelor	0
45	80000	PhD	1
NaN	48000	Bachelor	0
29	NaN	Master	1
31	52000	NaN	0
NaN	45000	Bachelor	0
35	NaN	Master	1

age	income	education	high_income_indicator
25	50000	Bachelor	0
32	62000	Master	0
31	55000	Master	1
28	52000	Bachelor	0
45	80000	PhD	1
31	48000	Bachelor	0
29	62000	Master	1
31	52000	Bachelor	0
31	45000	Bachelor	0
35	62000	Master	1



3. Проверка баланса групп

Зачем проверять баланс групп?

Идеальная ситуация: Группы А и В идентичны.

Реальная ситуация: Случайный дисбаланс




3. Проверка баланса групп

Методы проверки баланса

Проверка распределения: Демография, поведенческие факторы и т.д..

Статистические тесты: Т-тест, Хи-квадрат тест. (т.е. сделать АВ-тест групп до АВ-теста исследуемого процесса)






3. Проверка баланса групп

Интерпретация результатов: Дисбаланс найден. Что делать?

Проблема: Результаты теста смещены.

Действия: Стратификация, Ковариационная корректировка (CUPED), Перезапуск.....

CUPED КОРРЕКЦИЯ: СНИЖЕНИЕ ДИСПЕРСИИ И ПОВЫШЕНИЕ МОЩНОСТИ А/В ТЕСТА



Мы научились

1. Проводить разведочный анализ
2. Чистить и трансформировать данные
3. Контролировать качество разбиения

Ответы на вопросы



План занятия

Инструменты анализа

1. Автоматизация в Python
 2. Визуализация результатов
 3. Пайплайны анализа
- Ответы на вопросы

1. Автоматизация в Python

Автоматизация в Python: Стандартный алгоритм работы

Почему именно Python:

- Прост в освоении и применении
- Широкий инструментарий по работе с данными
- Огромное сообщество разработчиков
- Возможность использования Vibecoding

Блок-схема:

- **Загрузка данных** (pandas)
- **Предварительный анализ и очистка** -> (точка принятия решений)
- **Проверка распределений и статистических допущений** -> (точка принятия решений)
- **Применение статистического теста** (scipy.stats, statsmodels)
- **Интерпретация результатов (p-value, доверительные интервалы)**

Ключевое сообщение: Автоматизация — это не просто скрипт, это последовательность принятия решений.

1. Автоматизация в Python

Инструменты для работы с нормальными данными

Проверка нормальности:

```
from scipy.stats import shapiro, normaltest, Anderson, kstest
```

Числовые параметры:

```
# Коэффициент асимметрии (skewness)
```

```
skewness = skew(data) #  $\approx 0$  - нормальное,  $> 0$  - правый скос,  $< 0$  - левый скос
```

```
# Эксцесс (kurtosis)
```

```
kurt = kurtosis(data) #  $\approx 0$  - нормальное,  $> 0$  - островершинное,  $< 0$  - плосковершинное
```

Сравнение групп:

```
# Парный t-тест (зависимые выборки)
```

```
t_stat, p_value = ttest_rel(before, after)
```

```
# Односторонний t-тест
```

```
t_stat, p_value = ttest_ind(group_a, group_b, alternative='greater')
```

```
# ANOVA для нескольких групп
```

```
f_stat, p_value = f_oneway(group_a, group_b, group_c)
```

1. Автоматизация в Python

Инструменты для работы с нормальными данными

Точечные оценки:

```
mean = np.mean(data)
std = np.std(data, ddof=1)
```

Несмещенная оценка:

```
variance = np.var(data, ddof=1)
```

Доверительные интервалы

```
from scipy.stats import t
ci_mean = t.interval(0.95, len(data)-1, loc=mean, scale=sem(data))
ci_std = np.sqrt((len(data)-1) * std**2 / stats.norm.ppf([0.025, 0.975], len(data)-1))
```

```
from statsmodels.stats.power import TTestIndPower, TTestPower
```

Анализ мощности

```
power_analysis = TTestIndPower()
```

Расчет необходимого размера выборки

```
sample_size = power_analysis.solve_power( effect_size=0.5, power=0.8, alpha=0.05, ratio=1.0 )
```

Расчет мощности существующего теста

```
power = power_analysis.power( effect_size=0.5, nobs1=50, alpha=0.05, ratio=1.0 )
```

1. Автоматизация в Python

Инструменты для работы с ненормальными данными

Использовать непараметрические тесты:

from **scipy.stats** import mannwhitneyu, kruskal, Wilcoxon

- **Манна-Уитни:** `stat, p_value = mannwhitneyu(group_a, group_b)`
- **Вилкоксона:** `stat, p_value = wilcoxon(before, after)`
- **Нескольких групп:** `stat, p_value = kruskal(group_a, group_b, group_c)`
- **Бутстрап для построения доверительных интервалов вокруг медианы или любого другого показателя:**

```
def bootstrap_ci(data, n_bootstraps=10000, ci=95):  
    boot_means = []  
    for _ in range(n_bootstraps):  
        sample = np.random.choice(data, size=len(data), replace=True)  
        boot_means.append(np.mean(sample))  
        lower = np.percentile(boot_means, (100-ci)/2)  
        upper = np.percentile(boot_means, 100 - (100-ci)/2)  
    return lower, upper  
# Доверительный интервал для медианы  
ci_lower, ci_upper = bootstrap_ci(data)
```

Попробовать преобразования данных:

- **Логарифмирование** `np.log`, `np.log1p(data)`, **корень квадратный** `np.sqrt(data)`— для правосторонне скошенных данных (например, Revenue).

Использовать Пуассоновские или Negative Binomial тесты для счетных данных (например, количество покупок) `poisson`, `nbinom`

2. Визуализация результатов

Основные принципы визуализации в A/B-тестах

Цель: Донести результат теста ясно, точно и недвусмысленно.

Три принципа:

- Показывать не только "вердикт", но и неопределенность.
- Сравнивать группы напрямую.
- Давать контекст (например, исторические данные).

2. Визуализация результатов



Идея визуализации №1: Доверительные интервалы

Что показать: График с точками (среднее значение для группы А и В) и "усами" (доверительные интервалы вокруг них).

Идея для графика:

- **Горизонтальный bar chart** с CI для каждой группы.
- **График "Forest Plot"**: Идеально для одновременного сравнения нескольких метрик или сегментов.

Почему это работает: Сразу видно, есть ли перекрытие интервалов. Минимум chartjunk (визуального мусора), максимум информации.



2. Визуализация результатов

Идея визуализации №2: Распределения и до-после


Идея 2.1: Для ненормальных/скошенных данных.

- **Что показать:** Boxplot (sns.boxplot) или Violin plot (sns.violinplot) для групп A и B.
- **Почему это работает:** Позволяет наглядно оценить медиану, квантили, выбросы и форму распределения. Прямо показывает проблему скошенности.


Идея 2.2: Для контроля за временными эффектами.

- **Что показать:** Линейный график (sns.lineplot) с метрикой по дням до и после начала теста для обеих групп.
- **Почему это работает:** Позволяет убедиться, что группы были параллельны до теста (A/A-тест) и увидеть динамику эффекта во времени.

Распределение метрик по группам
(Violinplot + Boxplot)



Динамика метрик во времени
(Контроль временных эффектов)



2. Визуализация результатов

Идея визуализации №3: Последовательный анализ

Проблема: "Подглядывание" за результатами искажает p-value.


Решение: Графики последовательного анализа (Sequential Analysis).

Что показать: График, где по оси X — количество наблюдений или дней, а по Y — накопленная статистика (Z-скор, вероятность превосходства).

- На график наносятся "границы значимости". Как только линия пересекает границу — тест можно останавливать

Почему это работает: Позволяет безопасно мониторить тест и часто останавливать его раньше, экономя трафик и время.

Библиотеки: statsmodels



3. Пайплайны анализа

Зачем нужны пайплайны?

Пайплайн — это эволюция от анализа как "искусства" к анализу как "надежного инженерного процесса".

Проблемы ручного анализа:

- Ошибки при копипасте.
- Долго и неповторимо.
- Невозможно масштабировать на десятки тестов.

Цели пайплайна:

- **Автоматизация:** От данных до отчета одним запуском.
- **Стандартизация:** Все тесты анализируются одинаково.
- **Воспроизводимость:** Любой коллега может получить тот же результат.

3. Пайплайны анализа

Ключевые компоненты пайплайна

Блок-схема:

- **Data Ingestion Layer:** Автоматическое подключение к БД / платформе экспериментов (SQL, API).
- **Processing & Validation Layer:**
 - Проверка качества данных (A/A-тест, равенство размеров групп).
 - **Автоматические проверки на "проблемные" данные, EDA:** Тест на нормальность (Шapiro-Уилк), расчет скоса. В зависимости от результата — запускается соответствующий путь анализа (Т-тест или Манна-Уитни).
- **Analysis & Calculation Layer:** Расчет ключевых метрик, p-value, доверительных интервалов, мощности.
- **Reporting & Visualization Layer:** Генерация стандартизированного отчета (PDF, HTML) или дашборда (Tableau, Plotly Dash).

3. Пайплайны анализа

Инструменты и реализация*

Для оркестрации:

- **Apache Airflow:** Золотой стандарт для планирования и мониторинга пайплайнов.
- **Prefect / Dagster:** Современные альтернативы.

Для шаблонов анализа (Templates):

- **Jupyter Notebooks** можно параметризовать с помощью papermill.
- **Создать библиотеку функций** на Python, которые вызываются из главного скрипта.

Для отчетности:

- **Google Data Studio / Tableau:** Подключение к агрегированным данным.
- **Plotly Dash / Streamlit:** Создание интерактивных дашбордов прямо на Python.

*Примеры инструментов и реализаций даны исключительно для ознакомления, не является рекомендацией применения

Мы научились

1. Автоматизировать анализ тестов
2. Визуализировать ключевые метрики
3. Строить воспроизводимые пайплайны

Ответы на вопросы



Мы научились

1. Планировать тесты
2. Работать с данными
3. Применять инструменты анализа

**Спасибо
за внимание!**

