



А/В-тестирование

## Модуль 4: Практические кейсы

2025



# План модуля

## Дизайн эксперимента

1. E-commerce
2. Мобильные приложения
3. Продвинутые стратегии

# План занятия

## E-commerce

1. Тестирование UI/UX изменений
  2. Метрики: конверсия, средний чек
  3. Бизнес-интерпретация
- Ответы на вопросы

# 1. Тестирование UI/UX изменений

## Что мы тестируем в E-commerce? (Фокус на UI/UX)

**Цель UI/UX тестов:** убрать "трение" на пути пользователя к покупке.

### Примеры гипотез:

- "Увеличение кнопки 'В корзину' на 20% повысит конверсию в добавление товара."
- "Упрощение шагов оформления заказа (с 5 до 3) снизит процент брошенных корзин."
- "Добавление отзывов и рейтингов на карточку товара увеличит средний чек."

### Версия А (Контрольная)

Изображение товара

Маленькая кнопка "В корзину"

Смартфон Premium X200

34 990 Р

В корзину

Оформление заказа

1. Контактные данные

2. Адрес доставки

3. Способ доставки

Длинная форма из 5 шагов

5. Подтверждение заказа

### Версия В (Тестовая)

Изображение товара

Увеличенная кнопка "В КОРЗИНУ"

Смартфон Premium X200

34 990 Р

Упрощенная форма из 3 шагов

В КОРЗИНУ

Оформление заказа

1. Данные для доставки

2. Способ оплаты

3. Подтверждение

Отзывы покупателей

★★★★★ Отличный телефон! Батарея держит 2 дня

★★★★☆ Хорошая камера, но тяжёлый

Новый блок с отзывами

# 1. Тестирование UI/UX изменений


## Ошибки при планировании UI/UX тестов

### Недостаточно данных:

- *Проблема:* Запуск теста на малом трафике. Результаты нестабильны, высокий шанс ложноположительных или ложноотрицательных результатов.
- *Действие:* Рассчитать необходимый размер выборки до старта теста. Использовать калькуляторы мощности теста (Power Analysis).

### Ненормальное распределение (Аномалии):

- *Проблема:* В данных появился резкий всплеск или провал из-за внешних факторов (сбой в рекламе, праздник, технические неполадки).
- *Действие:* Визуализировать метрики по дням. Идентифицировать аномальный день. Принять решение: исключить этот день из анализа или остановить тест и перезапустить его позже.



## 2. Метрики: конверсия, средний чек

### Метрики: конверсия, средний чек

**Конверсия (CR):** % пользователей, выполнивших целевое действие (например, покупку) от общего числа.

- Формула:  $(\text{Число покупок} / \text{Число визитов}) * 100\%$

**Средний чек (AOV):** Средняя сумма одного заказа.

- Формула:  $(\text{Общая выручка} / \text{Число заказов})$



### Конверсия

Воронка превращения  
посетителей в покупателей



### Средний чек

Средняя сумма одного заказа

## 2. Метрики: конверсия, средний чек

### Конверсия и ее составляющие

Конверсию нужно разбивать на этапы воронки:

- Конверсия в просмотр карточки товара
- Конверсия в добавление в корзину
- Конверсия в начало оформления заказа
- Конверсия в успешный заказ

Это помогает точнее определить "узкое горлышко"



## 2. Метрики: конверсия, средний чек


### Средний чек и его "скосы"

**Проблема:** На данные сильно влияют немногочисленные очень крупные или очень мелкие заказы (выбросы). Среднее арифметическое (AOV) может быть необъективным.

**Диагностика:** Построить гистограмму распределения сумм заказов. Если она не похожа на "колокол" — распределение скошено.

**Действия:**

- Использовать **медианный чек** (серединное значение) как более устойчивую метрику.
- Применять **статистические тесты, устойчивые к выбросам** (например, тест Манна-Уитни вместо t-теста).
- Сегментировать аудиторию (например, "новички" vs "постоянные клиенты") и анализировать их отдельно.






### 3. Бизнес-интерпретация

#### Бизнес-интерпретация

- **p-value < 0.05** — это только начало.
- Главный вопрос: "**Насколько изменение выгодно бизнесу?**"
- Вводим понятие **OPE (Overall Evaluation Criterion)** — общий оценочный критерий, например, **общая выручка**.

*Выручка = Трафик \* Конверсия \* Средний Чек*

ВЫРУЧКА = ТРАФИК × КОНВЕРСИЯ × СРЕДНИЙ ЧЕК



# 3. Бизнес-интерпретация

## Сценарный анализ: Принимаем решение

**Сценарий 1: Победа по всем фронтам** (Конверсия  $\nearrow$ , Средний чек  $\nearrow$ ) - **> Роллаут!**

**Сценарий 2: Компромисс** (Конверсия  $\nearrow$ , Средний чек  $\searrow$ ) -> Считаем влияние на выручку. Если выручка растет — внедряем.

**Сценарий 3: Статистически незначимо** (Нет четкого winner'a) -> Решение: отклонить гипотезу или провести тест заново с большей выборкой/длительностью.



# 3. Бизнес-интерпретация


## Пример бизнес-интерпретации на кейсе

### Данные:

- **Гипотеза:** Удаление одного обязательного поля из формы заказа увеличит конверсию.
- **Результат:** Конверсия в заказ выросла с 4.1% до 4.5% (p-value = 0.01). Средний чек не изменился.

### Бизнес-расчет:

- *Ежемесячный трафик:* 1 000 000 визитов.
- *Текущая выручка (A):*  $1,000,000 \times 0.041 \times 2500$  руб. = 102,500,000 руб.
- *Ожидаемая выручка (B):*  $1,000,000 \times 0.045 \times 2500$  руб. = 112,500,000 руб.
- **Прирост выручки:** +10,000,000 руб. в месяц.



# 3. Бизнес-интерпретация

## Когда данные врут? (Ошибки интерпретации)



**Эффект подглядывания (Peeking):** Если постоянно проверять результаты до конца теста, многократно повышается шанс ложноположительного результата.

**Решение:** Заранее определить длительность теста и размер выборки. Не подглядывать!



**Ковариата (Сегментация):** Общий результат может скрывать разнонаправленные эффекты. Пример: Новая кнопка не понравилась постоянным клиентам (их конверсия упала), но понравилась новым (их конверсия выросла). В сумме — ноль.

**Решение:** Всегда проводить анализ по сегментам.



## 3. Бизнес-интерпретация

### Итоговый чек-лист успешного АВ-теста

1. **Гипотеза:** Четкая, измеримая.
2. **План:** Рассчитана длительность и размер выборки.
3. **Корректность:** Нет аномалий в данных, трафик чист.
4. **Метрики:** Основные (CR, AOV) и второстепенные отслеживаются.
5. **Статистика:** Учтены скошенные распределения, выбран верный тест.
6. **Интерпретация:** Проведен сценарный анализ и расчет выгоды для бизнеса (OPE).
7. **Решение:** Внедрить, отклонить или провести итерацию.

## Мы научились

1. Анализировать e-commerce метрики
2. Формулировать бизнес-рекомендации
3. Обнаруживать скрытые эффекты

# Ответы на вопросы



# План занятия

## Мобильные приложения

1. Тестирование новых фич
  2. Метрики вовлеченности
  3. Когортный анализ
- Ответы на вопросы



# 1. Тестирование новых фич

## Стратегия тестирования новых фич

**Цель:** Проверить ценность гипотезы для пользователя, а не факт "работает/не работает".

**Основные метрики:** Первичные (например, конверсия в целевое действие), Вторичные (вовлеченность, отток), Охранные (стабильность, производительность).

**Гипотеза:** "Мы предполагаем, что добавление функции 'X' увеличит метрику 'Y' на Z%, потому что..."

**Что делать, если...данных недостаточно:**

- Рассчитать мощность теста до его запуска. Если по истечении расчетного времени выборка не набрана – продлить тест. Если фича нишевая – использовать модель лифта (uplift modeling) для таргета на подходящую аудиторию.



# 1. Тестирование новых фич

## Работа с аномалиями и скошенными данными

**Проблема:** Многие метрики в мобильных приложениях (доход, длительность сессии) имеют тяжелые хвосты и положительно скошены (большинство пользователей – низкие значения, малое число – очень высокие).

**Ошибка:** Применение t-теста к таким данным может дать ложные результаты.

### Решение:

- **Бутстрап (Bootstrap):** Непараметрический метод, не требующий предположения о нормальности.
- **Логарифмирование данных:** Преобразует распределение к более нормальному виду. (Важно: интерпретация результата будет в "разы", а не в "%").
- **Тримминг (обрезка выбросов):** Аккуратное отсечение верхних 1-5% значений для снижения влияния аномалий.
- **Метрики, устойчивые к выбросам:** Медиана вместо среднего.

## 2. Метрики вовлеченности

### Ключевые метрики вовлеченности

**DAU/WAU/MAU (Daily/Weekly/Monthly Active Users):** "Температура" приложения.

**Глубина вовлеченности:** Среднее число сессий на пользователя, длительность сессии, экраны за сессию.

**Retention Rate:** % пользователей, вернувшихся на N-ый день после установки.



## 2. Метрики вовлеченности


### Проблемы с метриками вовлеченности

**Распределение:** Длительность сессии и экраны за визит почти всегда скошены. Медианный пользователь проводит 2 минуты, а среднее "раздувают" power users.

**Ошибка:** Говорить "средняя длительность сессии выросла на 10%" – часто бессмысленно.

#### Что делать, если...метрика сильно скошена:

- **Использовать медиану и персентили (25-й, 75-й)** для описания "типичного" пользователя.
- **Сравнивать персентили** между группами А и В (например, медиана в группе В выше).
- **Применять критерий Манна-Уитни** вместо t-теста для сравнения двух распределений.




## 2. Метрики вовлеченности

### Визуализация результатов теста на вовлеченности

- Показываем не "среднее", а "распределение"
- Отказываемся от простых столбчатых диаграмм со средним значением.
- Предпочтение графикам, показывающим всю картину.

Гистограмма с  
наложением

Распределение  
длительности сессии для  
групп А и В на одном  
графике




ECDF

Кумулятивная функция  
распределения для  
сравнения процентилей  
между группами



Диаграмма с  
персентилями

Медиана и квантили  
распределения для  
наглядного сравнения  
групп



# 3. Когортный анализ

## Что такое когортный анализ?

**Когорта** – группа пользователей, объединенных общим признаком в определенный период (например, неделя установки).

**Зачем?** Убрать шум от постоянно меняющегося состава пользователей. Увидеть долгосрочный эффект фичи.

**Связь с А/В-тестом:** Разбить пользователей теста на когорты по дате входа и посмотреть, как меняется их поведение с течением времени.




# 3. Когортный анализ

## Когортный анализ в A/B-тестировании

**Подход:** Создаем две большие когорты: "Группа А" и "Группа В" (по дате попадания в эксперимент).

**Метрика:** Чаще всего **Retention (удержание)**. Увеличивает ли новая фича долю пользователей, которые возвращаются к нам через 3, 7, 30 дней?

**Пример гипотезы:** "Фича не просто поднимает конверсию в первый день, но и увеличивает LTV (Lifetime Value) за счет лучшего удержания".



Удержание на 7-й день

42%

58%

+38%

Значительное улучшение среднесрочного удержания

Удержание на 30-й день

18%

28%

+56%

Существенный рост долгосрочной лояльности

Прогноз LTV

\$24.50

\$32.80

+34%

Увеличение пожизненной ценности пользователя

# 3. Когортный анализ


## Проблемы данных в когортном анализе

**Недостаток данных:** Для поздних "дней жизни" (например, День 30) в свежих когортах данные будут постоянно неполными. Решение: не интерпретировать "серые" (незаполненные) ячейки тепловой карты.

**Скошенность внутри когорт:** Если в когорте есть 1-2 "кита", которые генерируют 80% доходов, это исказит средний доход на пользователя (ARPU).

**Что делать, если...внутри когорт данные ненормальные:**

- Анализировать **медианный доход на пользователя** внутри когорты.
- Строить когорты **по среднему чеку (ARPPU)** для платящих пользователей.
- Использовать **персентильный подход** для анализа распределения внутри каждой ячейки когортной таблицы.



■ Низкие значения ■ Ниже среднего ■ Средние значения ■ Выше среднего ■ Высокие значения ■ Недостаточно данных





# 3. Когортный анализ


## Комплексный пример

1. **Гипотеза:** "Система достижений увеличит удержание на 7-й день на 5%".
2. **Запуск A/B-теста.**
3. **Первичная метрика:** Конверсия в получение первого достижения. -> **Статзначимый рост.**
4. **Анализ вовлеченности:** Медианная длительность сессии не изменилась, но 75-й перцентиль вырос. -> **Фича понравилась более вовлеченным пользователям.**
5. **Когортный анализ:** Когорты группы В стабильно показывают +4% к удержанию на 7-й день. -> **Гипотеза подтвердилась, фича оказывает долгосрочный эффект.**


Конверсия в получение первого достижения



Длительность сессии (медиана и персентили)



Когортный анализ: удержание на 7-й день



## Мы научились

1. Работать с мобильными метриками
2. Тестирование метрики вовлеченности
3. Интерпретировать поведенческие паттерны

# Ответы на вопросы



# План занятия

## Продвинутые стратегии

1. MVT тестирование
  2. Bandit-алгоритмы
  3. Последовательное тестирование
- Ответы на вопросы

# 1. MVT-тестирование (Multi-Variable Testing)


## Что такое MVT-тестирование?

Тестирование нескольких факторов (А, В, С) с несколькими вариациями (А1, А2, В1, В2...) одновременно.

**Цель:** определить не только лучшие комбинации, но и **взаимодействие факторов**.

**Пример:** Заголовок (А), Изображение (В), Цвет кнопки (С).

**Продолжительность теста:** Минимальная длительность (дни) =  $\text{ceil}(\text{Минимальный размер группы} \times \text{Количество комбинаций}) / \text{Ежедневный трафик})$ .



# 1. MVT-тестирование (Multi-Variable Testing)

## MVT: Проблемы с данными и их решения


### Проблема1: Недостаточно данных

- *Действие:* Резко возрастает количество вариантов. Для 3 факторов по 2 варианта = 8 комбинаций. Нужен огромный трафик.
- *Решение:* Использовать **дробный факторный дизайн (Fractional Factorial)** – тестируем только часть комбинаций, жертвуя малозначимыми взаимодействиями.

### Проблема2: Данные ненормальные/сильно скошены (например, доход на пользователя)

- *Действие:* Стандартный ANOVA может быть неэффективен.
- *Решение:* Применить **непараметрические методы** (тест Манна-Уитни для медиан) или **бутстреп** для оценки доверительных интервалов. Или использовать **обобщенные линейные модели (GLM)**, предназначенные для конкретных типов данных (например, Гамма-распределение для сильно скошенных непрерывных данных).

Экспоненциальный рост комбинаций



Проблема: Недостаточно данных

Решение: Дробный факторный дизайн - тестируем только часть комбинаций


Когда классические методы подводят



Скошенное распределение (доход)

Проблема: Данные ненормальные/скошены  
Действие: Стандартный ANOVA неэффективен

Методы для работы с ненормальными данными



Решение: Непараметрические методы, бутстреп или GLM для специфичных распределений (Гамма, Пуассон)

## 2. Bandit-алгоритмы

### Beyond A/B: Multi-Armed Bandit (MAB)

**MAB:** подход в машинном обучении, который помогает выбрать наиболее подходящее действие из нескольких альтернатив

*Метафора:* Игровой автомат (bandit) с несколькими рычагами.

*Цель:* **Баланс между исследованием (Exploration) и использованием (Exploitation).**

*Преимущество перед A/B-тестом:* Меньше "потерь" во время теста, трафик постепенно перераспределяется в пользу победителя.

#### Как работает Bandit-алгоритм:

Bandit-алгоритмы решают проблему компромисса между:

- **Исследованием (Exploration):** тестирование новых или менее используемых вариантов
- **Использованием (Exploitation):** применение варианта с наилучшей известной эффективностью

#### Основные типы Bandit-алгоритмов:

- **$\epsilon$ -greedy:** С вероятностью  $\epsilon$  выбирается случайный вариант, иначе - лучший известный
- **Upper Confidence Bound (UCB):** Выбирает вариант с наивысшей верхней границей доверительного интервала
- **Thompson Sampling:** Байесовский подход, выбирает вариант на основе вероятности его оптимальности

#### Преимущества перед классическим A/B-тестированием:

- Меньше "потерь" во время теста
- Автоматическая адаптация к изменениям
- Более эффективное использование трафика







## 2. Bandit-алгоритмы

### Скошенные метрики

**Проблема:** Сильно скошены метрики (например, средний чек)

**Действие:** Алгоритмы, основанные на средних значениях (например,  $\epsilon$ -greedy), могут быть нестабильны.

**Решение:** Использовать **Thompson Sampling**, который работает с апостериорными распределениями. Он более робастен к шуму и скошенности, так как учитывает всю форму распределения, а не только среднее.









## 2. Bandit-алгоритмы

### Нестационарные данные

**Проблема: Нестационарность данных (изменение предпочтений пользователей со временем)**

*Действие:* Статичный A/B-тест или простой Bandit "застрянет" на устаревшем варианте.

*Решение:* Использовать **адаптивные Bandit-алгоритмы** с "забыванием" (например, добавляя скользящее окно или фактор затухания), которые быстрее реагируют на изменения.






# 3. Последовательное тестирование

## Последовательный анализ: проверка по ходу дела




Проверка гипотез не после набора всей выборки, а **после поступления каждой новой порции данных**.

Позволяет остановить тест досрочно при явной победе одного из вариантов  $H_1$  или при отсутствии эффекта  $H_0$ .

Ключевой инструмент: **Sequential Probability Ratio Test (SPRT)** и его модификации.



- LLR > 0 Данные более вероятны при  $H_1$
- LLR < 0 Данные более вероятны при  $H_0$
- LLR = 0 Данные одинаково вероятны при обеих гипотезах





# 3. Последовательное тестирование

## Сила и риски последовательного подхода

**Преимущество:** Экономия трафика и времени (в среднем, до 50%).

**Риск:** Частые проверки ведут к **инфляции ошибки первого рода** (вероятности ложного обнаружения эффекта).

**Решение:** Использовать специально разработанные поправки (O'Brien-Fleming – p-value зависит от номера подглядывания, Pocock – p-value постоянный), которые "жестче" на старте и "снисходительнее" ближе к концу, контролируя общую ошибку.



# 3. Последовательное тестирование




## Последовательное тестирование и ненормальные данные

**Проблема:** Классический SPRT предполагает нормальность или биномиальность данных.

**Решение 1 (Непараметрическое):** Использовать **последовательные тесты на основе бутстрепа**. После каждого нового наблюдения мы пересчитываем статистику и повторяем процедуру бутстрепа, чтобы проверить, достигли ли мы порога значимости.

**Решение 2 (Мощное):** Использовать **обобщенные последовательные вероятностные соотношения**, основанные на правильной модели данных (например, для Пуассоновских или Гамма-распределений).

**Если данных недостаточно:** Сам подход последовательного анализа решает эту проблему – мы видим, когда данных "достаточно" для принятия решения, и останавливаемся



### 3. Последовательное тестирование

#### Сравнительная таблица стратегий

| Критерий                           | MVT-тестирование                          | Bandit-алгоритмы                                     | Последовательный анализ                                     |
|------------------------------------|-------------------------------------------|------------------------------------------------------|-------------------------------------------------------------|
| Основная цель                      | Найти взаимодействия факторов             | Минимизировать потери                                | Сэкономить трафик и время                                   |
| Распределение трафика              | Фиксированное                             | Динамическое                                         | Фиксированное, но тест может закончиться досрочно           |
| Что делать с ненормальными данными | Generalized Linear Models (GLM), Бутстреп | Thompson Sampling                                    | Бутстреп, Специфичные модели                                |
| Главный вызов                      | Огромная требуемая выборка                | Риск "застрять" в субоптимальном варианте            | Инфляция ошибки I рода                                      |
| Идеальный сценарий                 | Оптимизация страниц/воронок               | Сезонные акции, рекомендации, где цена ошибки высока | Поиск больших эффектов на бинарных или непрерывных метриках |

## Мы научились

1. Проектировать сложные эксперименты
2. Применять адаптивные методы
3. Оптимизировать процесс принятия решений

# Ответы на вопросы



## Мы научились

1. Планировать тесты
2. Работать с данными
3. Применять инструменты анализа



**Спасибо  
за внимание!**

