



A/B-тестирование

Модуль 4: Практические кейсы

2025



План модуля

Дизайн эксперимента

1. E-commerce
2. Мобильные приложения
3. Продвинутые стратегии

План занятия

E-commerce

1. Тестирование UI/UX изменений
 2. Метрики: конверсия, средний чек
 3. Бизнес-интерпретация
- Ответы на вопросы

1. Тестирование UI/UX изменений

Что мы тестируем в E-commerce? (Фокус на UI/UX)

Цель UI/UX тестов: убрать "трение" на пути пользователя к покупке.

Примеры гипотез:

- "Увеличение кнопки 'В корзину' на 20% повысит конверсию в добавление товара."
- "Упрощение шагов оформления заказа (с 5 до 3) снизит процент брошенных корзин."
- "Добавление отзывов и рейтингов на карточку товара увеличит средний чек."

Версия А (Контрольная)

Изображение товара

Маленькая кнопка "В корзину"

Смартфон Premium X200

34 990 Р

В корзину

Оформление заказа

1. Контактные данные

2. Адрес доставки

3. Способ доставки

Длинная форма из 5 шагов

5. Подтверждение заказа

Версия В (Тестовая)

Изображение товара

Увеличенная кнопка "В КОРЗИНУ"

Смартфон Premium X200

34 990 Р

Упрощенная форма из 3 шагов

В КОРЗИНУ

Оформление заказа

1. Данные для доставки

2. Способ оплаты

3. Подтверждение

Отзывы покупателей

★★★★★ Отличный телефон! Батарея держит 2 дня

★★★★☆ Хорошая камера, но тяжёлый

Новый блок с отзывами

1. Тестирование UI/UX изменений


Ошибки при планировании UI/UX тестов

Недостаточно данных:

- *Проблема:* Запуск теста на малом трафике. Результаты нестабильны, высокий шанс ложноположительных или ложноотрицательных результатов.
- *Действие:* Рассчитать необходимый размер выборки до старта теста. Использовать калькуляторы мощности теста (Power Analysis).

Ненормальное распределение (Аномалии):

- *Проблема:* В данных появился резкий всплеск или провал из-за внешних факторов (сбой в рекламе, праздник, технические неполадки).
- *Действие:* Визуализировать метрики по дням. Идентифицировать аномальный день. Принять решение: исключить этот день из анализа или остановить тест и перезапустить его позже.



2. Метрики: конверсия, средний чек

Метрики: конверсия, средний чек

Конверсия (CR): % пользователей, выполнивших целевое действие (например, покупку) от общего числа.

- Формула: $(\text{Число покупок} / \text{Число визитов}) * 100\%$

Средний чек (AOV): Средняя сумма одного заказа.

- Формула: $(\text{Общая выручка} / \text{Число заказов})$



Конверсия

Воронка превращения
посетителей в покупателей



Средний чек

Средняя сумма одного заказа

2. Метрики: конверсия, средний чек

Конверсия и ее составляющие

Конверсию нужно разбивать на этапы воронки:

- Конверсия в просмотр карточки товара
- Конверсия в добавление в корзину
- Конверсия в начало оформления заказа
- Конверсия в успешный заказ

Это помогает точнее определить "узкое горлышко"



2. Метрики: конверсия, средний чек


Средний чек и его "скосы"

Проблема: На данные сильно влияют немногочисленные очень крупные или очень мелкие заказы (выбросы). Среднее арифметическое (AOV) может быть необъективным.

Диагностика: Построить гистограмму распределения сумм заказов. Если она не похожа на "колокол" — распределение скошено.

Действия:

- Использовать **медианный чек** (серединное значение) как более устойчивую метрику.
- Применять **статистические тесты, устойчивые к выбросам** (например, тест Манна-Уитни вместо t-теста).
- Сегментировать аудиторию (например, "новички" vs "постоянные клиенты") и анализировать их отдельно.




3. Бизнес-интерпретация

Бизнес-интерпретация

- **p-value < 0.05** — это только начало.
- Главный вопрос: "**Насколько изменение выгодно бизнесу?**"
- Вводим понятие **OPE (Overall Evaluation Criterion)** — общий оценочный критерий, например, **общая выручка**.

*Выручка = Трафик * Конверсия * Средний Чек*

ВЫРУЧКА = ТРАФИК × КОНВЕРСИЯ × СРЕДНИЙ ЧЕК



3. Бизнес-интерпретация

Сценарный анализ: Принимаем решение

Сценарий 1: Победа по всем фронтам (Конверсия $\uparrow$, Средний чек $\uparrow$) - **> Роллаут!**

Сценарий 2: Компромисс (Конверсия $\uparrow$, Средний чек $\downarrow$) -> Считаем влияние на выручку. Если выручка растет — внедряем.

Сценарий 3: Статистически незначимо (Нет четкого winner'a) -> Решение: отклонить гипотезу или провести тест заново с большей выборкой/длительностью.



3. Бизнес-интерпретация


Пример бизнес-интерпретации на кейсе

Данные:

- **Гипотеза:** Удаление одного обязательного поля из формы заказа увеличит конверсию.
- **Результат:** Конверсия в заказ выросла с 4.1% до 4.5% (p-value = 0.01). Средний чек не изменился.

Бизнес-расчет:

- *Ежемесячный трафик:* 1 000 000 визитов.
- *Текущая выручка (A):* $1,000,000 \times 0.041 \times 2500$ руб. = 102,500,000 руб.
- *Ожидаемая выручка (B):* $1,000,000 \times 0.045 \times 2500$ руб. = 112,500,000 руб.
- **Прирост выручки:** +10,000,000 руб. в месяц.



3. Бизнес-интерпретация

Когда данные врут? (Ошибки интерпретации)



Эффект подглядывания (Peeking): Если постоянно проверять результаты до конца теста, многократно повышается шанс ложноположительного результата.

Решение: Заранее определить длительность теста и размер выборки. Не подглядывать!



Ковариата (Сегментация): Общий результат может скрывать разнонаправленные эффекты. Пример: Новая кнопка не понравилась постоянным клиентам (их конверсия упала), но понравилась новым (их конверсия выросла). В сумме — ноль.

Решение: Всегда проводить анализ по сегментам.



3. Бизнес-интерпретация

Итоговый чек-лист успешного АВ-теста

1. **Гипотеза:** Четкая, измеримая.
2. **План:** Рассчитана длительность и размер выборки.
3. **Корректность:** Нет аномалий в данных, трафик чист.
4. **Метрики:** Основные (CR, AOV) и второстепенные отслеживаются.
5. **Статистика:** Учтены скошенные распределения, выбран верный тест.
6. **Интерпретация:** Проведен сценарный анализ и расчет выгоды для бизнеса (OPE).
7. **Решение:** Внедрить, отклонить или провести итерацию.

Мы научились

1. Анализировать e-commerce метрики
2. Формулировать бизнес-рекомендации
3. Обнаруживать скрытые эффекты

Отвѣты на вопросы



План занятия

Мобильные приложения

1. Тестирование новых фич
 2. Метрики вовлеченности
 3. Когортный анализ
- Ответы на вопросы

1. Тестирование новых фич

Стратегия тестирования новых фич

Цель: Проверить ценность гипотезы для пользователя, а не факт "работает/не работает".

Основные метрики: Первичные (например, конверсия в целевое действие), Вторичные (вовлеченность, отток), Охранные (стабильность, производительность).

Гипотеза: "Мы предполагаем, что добавление функции 'X' увеличит метрику 'Y' на Z%, потому что..."

Что делать, если...данных недостаточно:

- Рассчитать мощность теста до его запуска. Если по истечении расчетного времени выборка не набрана – продлить тест. Если фича нишевая – использовать модель лифта (uplift modeling) для таргета на подходящую аудиторию.



1. Тестирование новых фич

Работа с аномалиями и скошенными данными

Проблема: Многие метрики в мобильных приложениях (доход, длительность сессии) имеют тяжелые хвосты и положительно скошены (большинство пользователей – низкие значения, малое число – очень высокие).

Ошибка: Применение t-теста к таким данным может дать ложные результаты.

Решение:

- **Бутстрап (Bootstrap):** Непараметрический метод, не требующий предположения о нормальности.
- **Логарифмирование данных:** Преобразует распределение к более нормальному виду. (Важно: интерпретация результата будет в "разы", а не в "%").
- **Тримминг (обрезка выбросов):** Аккуратное отсечение верхних 1-5% значений для снижения влияния аномалий.
- **Метрики, устойчивые к выбросам:** Медиана вместо среднего.

2. Метрики вовлеченности

Ключевые метрики вовлеченности

DAU/WAU/MAU (Daily/Weekly/Monthly Active Users): "Температура" приложения.

Глубина вовлеченности: Среднее число сессий на пользователя, длительность сессии, экраны за сессию.

Retention Rate: % пользователей, вернувшихся на N-ый день после установки.



2. Метрики вовлеченности

Проблемы с метриками вовлеченности

Распределение: Длительность сессии и экраны за визит почти всегда скошены. Медианный пользователь проводит 2 минуты, а среднее "раздувают" power users.

Ошибка: Говорить "средняя длительность сессии выросла на 10%" – часто бессмысленно.

Что делать, если...метрика сильно скошена:

- **Использовать медиану и персентили (25-й, 75-й)** для описания "типичного" пользователя.
- **Сравнивать персентили** между группами А и В (например, медиана в группе В выше).
- **Применять критерий Манна-Уитни** вместо t-теста для сравнения двух распределений.



Среднее
значение

5.2 мин
5.8 мин

+11.5%
(ненадежный
показатель)

Медиана

2.1 мин
2.8 мин

+33.3%
(значимое
улучшение)

Критерий
Манна-Уитни

p-value = 0.023

**Статистически
значимо**


2. Метрики вовлеченности

Визуализация результатов теста на вовлеченности

- Показываем не "среднее", а "распределение"
- Отказываемся от простых столбчатых диаграмм со средним значением.
- Предпочтение графикам, показывающим всю картину.

Гистограмма с
наложением

Распределение
длительности сессии для
групп А и В на одном
графике




ECDF

Кумулятивная функция
распределения для
сравнения процентилей
между группами



Диаграмма с
персентилями

Медиана и квантили
распределения для
наглядного сравнения
групп



3. Когортный анализ

Что такое когортный анализ?

Когорта – группа пользователей, объединенных общим признаком в определенный период (например, неделя установки).

Зачем? Убрать шум от постоянно меняющегося состава пользователей. Увидеть долгосрочный эффект фичи.

Связь с А/В-тестом: Разбить пользователей теста на когорты по дате входа и посмотреть, как меняется их поведение с течением времени.




3. Когортный анализ

Когортный анализ в A/B-тестировании

Подход: Создаем две большие когорты: "Группа А" и "Группа В" (по дате попадания в эксперимент).

Метрика: Чаще всего **Retention (удержание)**. Увеличивает ли новая фича долю пользователей, которые возвращаются к нам через 3, 7, 30 дней?

Пример гипотезы: "Фича не просто поднимает конверсию в первый день, но и увеличивает LTV (Lifetime Value) за счет лучшего удержания".



Удержание на 7-й день

42%

58%

+38%

Значительное улучшение среднесрочного удержания

Удержание на 30-й день

18%

28%

+56%

Существенный рост долгосрочной лояльности

Прогноз LTV

\$24.50

\$32.80

+34%

Увеличение пожизненной ценности пользователя

3. Когортный анализ


Проблемы данных в когортном анализе

Недостаток данных: Для поздних "дней жизни" (например, День 30) в свежих когортах данные будут постоянно неполными. Решение: не интерпретировать "серые" (незаполненные) ячейки тепловой карты.

Скошенность внутри когорт: Если в когорте есть 1-2 "кита", которые генерируют 80% доходов, это исказит средний доход на пользователя (ARPU).

Что делать, если...внутри когорт данные ненормальные:

- Анализировать **медианный доход на пользователя** внутри когорты.
- Строить когорты **по среднему чеку (ARPPU)** для платящих пользователей.
- Использовать **персентильный подход** для анализа распределения внутри каждой ячейки когортной таблицы.



■ Низкие значения ■ Ниже среднего ■ Средние значения ■ Выше среднего ■ Высокие значения ■ Недостаточно данных



3. Когортный анализ


Комплексный пример

1. **Гипотеза:** "Система достижений увеличит удержание на 7-й день на 5%".
2. **Запуск A/B-теста.**
3. **Первичная метрика:** Конверсия в получение первого достижения. -> **Статзначимый рост.**
4. **Анализ вовлеченности:** Медианная длительность сессии не изменилась, но 75-й перцентиль вырос. -> **Фича понравилась более вовлеченным пользователям.**
5. **Когортный анализ:** Когорты группы В стабильно показывают +4% к удержанию на 7-й день. -> **Гипотеза подтвердилась, фича оказывает долгосрочный эффект.**


Конверсия в получение первого достижения



Длительность сессии (медиана и персентили)



Когортный анализ: удержание на 7-й день



Мы научились

1. Работать с мобильными метриками
2. Тестирование метрики вовлеченности
3. Интерпретировать поведенческие паттерны

Ответы на вопросы



План занятия

Продвинутые стратегии

1. MVT тестирование
 2. Bandit-алгоритмы
 3. Последовательное тестирование
- Ответы на вопросы

1. MVT-тестирование (Multi-Variable Testing)


Что такое MVT-тестирование?

Тестирование нескольких факторов (А, В, С) с несколькими вариациями (А1, А2, В1, В2...) одновременно.

Цель: определить не только лучшие комбинации, но и **взаимодействие факторов**.

Пример: Заголовок (А), Изображение (В), Цвет кнопки (С).

Продолжительность теста: Минимальная длительность (дни) = $\text{ceil}(\text{Минимальный размер группы} \times \text{Количество комбинаций}) / \text{Ежедневный трафик})$.



1. MVT-тестирование (Multi-Variable Testing)

MVT: Проблемы с данными и их решения


Проблема1: Недостаточно данных

- *Действие:* Резко возрастает количество вариантов. Для 3 факторов по 2 варианта = 8 комбинаций. Нужен огромный трафик.
- *Решение:* Использовать **дробный факторный дизайн (Fractional Factorial)** – тестируем только часть комбинаций, жертвуя малозначимыми взаимодействиями.

Проблема2: Данные ненормальные/сильно скошены (например, доход на пользователя)

- *Действие:* Стандартный ANOVA может быть неэффективен.
- *Решение:* Применить **непараметрические методы** (тест Манна-Уитни для медиан) или **бутстреп** для оценки доверительных интервалов. Или использовать **обобщенные линейные модели (GLM)**, предназначенные для конкретных типов данных (например, Гамма-распределение для сильно скошенных непрерывных данных).

Экспоненциальный рост комбинаций



Проблема: Недостаточно данных

Решение: Дробный факторный дизайн - тестируем только часть комбинаций


Когда классические методы подводят



Скошенное распределение (доход)

Проблема: Данные ненормальные/скошены
Действие: Стандартный ANOVA неэффективен

Методы для работы с ненормальными данными



Решение: Непараметрические методы, бутстреп или GLM для специфичных распределений (Гамма, Пуассон)

2. Bandit-алгоритмы

Beyond A/B: Multi-Armed Bandit (MAB)

MAB: подход в машинном обучении, который помогает выбрать наиболее подходящее действие из нескольких альтернатив

Метафора: Игровой автомат (bandit) с несколькими рычагами.

Цель: **Баланс между исследованием (Exploration) и использованием (Exploitation).**

Преимущество перед A/B-тестом: Меньше "потерь" во время теста, такова трафик постепенно перераспределяется в пользу победителя.

Как работает Bandit-алгоритм:

Bandit-алгоритмы решают проблему компромисса между:

- **Исследованием (Exploration):** тестирование новых или менее используемых вариантов
- **Использованием (Exploitation):** применение варианта с наилучшей известной эффективностью

Основные типы Bandit-алгоритмов:

- **ϵ -greedy:** С вероятностью ϵ выбирается случайный вариант, иначе - лучший известный
- **Upper Confidence Bound (UCB):** Выбирает вариант с наивысшей верхней границей доверительного интервала
- **Thompson Sampling:** Байесовский подход, выбирает вариант на основе вероятности его оптимальности

Преимущества перед классическим A/B-тестированием:

- Меньше "потерь" во время теста
- Автоматическая адаптация к изменениям
- Более эффективное использование трафика







2. Bandit-алгоритмы

Скошенные метрики

Проблема: Сильно скошены метрики (например, средний чек)

Действие: Алгоритмы, основанные на средних значениях (например, ϵ -greedy), могут быть нестабильны.

Решение: Использовать **Thompson Sampling**, который работает с апостериорными распределениями. Он более робастен к шуму и скошенности, так как учитывает всю форму распределения, а не только среднее.







2. Bandit-алгоритмы

Нестационарные данные

Проблема: Нестационарность данных (изменение предпочтений пользователей со временем)

Действие: Статичный A/B-тест или простой Bandit "застрянет" на устаревшем варианте.

Решение: Использовать **адаптивные Bandit-алгоритмы** с "забыванием" (например, добавляя скользящее окно или фактор затухания), которые быстрее реагируют на изменения.




3. Последовательное тестирование

Последовательный анализ: проверка по ходу дела

Проверка гипотез не после набора всей выборки, а **после поступления каждой новой порции данных**.

Позволяет остановить тест досрочно при явной победе одного из вариантов H_1 или при отсутствии эффекта H_0 .

Ключевой инструмент: **Sequential Probability Ratio Test (SPRT)** и его модификации.





3. Последовательное тестирование

Сила и риски последовательного подхода

Преимущество: Экономия трафика и времени (в среднем, до 50%).

Риск: Частые проверки ведут к **инфляции ошибки первого рода** (вероятности ложного обнаружения эффекта).

Решение: Использовать специально разработанные поправки (O'Brien-Fleming – p-value зависит от номера подглядывания, Pocock – p-value постоянный), которые "жестче" на старте и "снисходительнее" ближе к концу, контролируя общую ошибку.



3. Последовательное тестирование




Последовательное тестирование и ненормальные данные

Проблема: Классический SPRT предполагает нормальность или биномиальность данных.

Решение 1 (Непараметрическое): Использовать **последовательные тесты на основе бутстрепа**. После каждого нового наблюдения мы пересчитываем статистику и повторяем процедуру бутстрепа, чтобы проверить, достигли ли мы порога значимости.

Решение 2 (Мощное): Использовать **обобщенные последовательные вероятностные соотношения**, основанные на правильной модели данных (например, для Пуассоновских или Гамма-распределений).

Если данных недостаточно: Сам подход последовательного анализа решает эту проблему – мы видим, когда данных "достаточно" для принятия решения, и останавливаемся



3. Последовательное тестирование

Сравнительная таблица стратегий

Критерий	MVT-тестирование	Bandit-алгоритмы	Последовательный анализ
Основная цель	Найти взаимодействия факторов	Минимизировать потери	Сэкономить трафик и время
Распределение трафика	Фиксированное	Динамическое	Фиксированное, но тест может закончиться досрочно
Что делать с ненормальными данными	GLM, Бутстреп	Thompson Sampling	Бутстреп, Специфичные модели
Главный вызов	Огромная требуемая выборка	Риск "застрять" в субоптимальном варианте	Инфляция ошибки (без корректного дизайна)
Идеальный сценарий	Оптимизация целых страниц/воронок	Сезонные акции, рекомендации, где цена ошибки высока	Поиск больших эффектов на бинарных или непрерывных метриках

Мы научились

1. Проектировать сложные эксперименты
2. Применять адаптивные методы
3. Оптимизировать процесс принятия решений

Ответы на вопросы



Мы научились

1. Планировать тесты
2. Работать с данными
3. Применять инструменты анализа

**Спасибо
за внимание!**

