


1. Решающие деревья: введение

План занятия, теория + практика

- Деревья решений: взгляд сверху
- Критерии информативности
- Процесс построения дерева

Деревья решений: взгляд сверху


Типы задач в ML



Регрессия: подобрать линию, наилучшим образом описывающую данные (аппроксимировать зависимость)


Классификация: подобрать линию, как можно более точно разделяющую классы

Как понять какая “линия” лучше?



(это регрессия)

Как понять какая “линия” лучше?



(это классификация)

Алгоритм решающего дерева #1

Решающее дерево – это ML-модель в форме дерева, где:


- каждый узел проверяет значение одного из признаков,
- ветви указывают, куда двигаться дальше в зависимости от результата проверки.

Логические правила (предикаты, индикаторы) задают условия на узлах дерева и определяют, какую ветвь выбрать для конкретного объекта.

Можно записать условие как:

$$[x_i \leq t],$$

где t – порог по определенному признаку.



Алгоритм решающего дерева #2

В целом, ничего не мешает использовать в предикатах сложные модели и условия.
Но обычно берут **сравнение значения по одному определенному признаку с порогом**.

Открытые вопросы:

- в каком порядке “задавать” вопросы (размещать предикаты)?
- какие выбрать значения порогов?

PS: ещё термины...



- самая верхняя вершина – **корневая**, другие вершины с предикатами – **внутренние**.
- тупиковая (конечная) ветка, которая не ведет к новым условиям – **листовая**.

Геометрически

Каждый уровень дерева ==
разделение (гипер)плоскости на 2
части.



*В листовой вершине
присваивается:*

- метка самого популярного класса или вероятность в случае **классификации**;
- константный прогноз, усредненный по объектам из обучающей выборки, попавшим в данную вершину, в случае **регрессии**.





Пошаговый пример #1

Предикат 1 « $X_1 \leq 5.0$ », деление по предикату 1





Пошаговый пример #2

Предикат 2 « $X_1 \leq 9$ », деление по предикату 2





Пошаговый пример #3

Предикат 3 « $X_1 \leq 7.842$ », деление по предикату 3



Пошаговый пример #4



Предикат 4 « $X_2 \leq 9.0$ », деление по предикату 4



По сути, решающее дерево разбило все пространство признаков на прямоугольные области. И в каждой определенной области объекту присваивается определенный класс.


Итог: для классификации

Итоговые прямые == разделение плоскости.



Итог: для регрессии

Итоговые линии – приближение зависимости.



Критерии информативности

Какой предикат следующий?

Важно в какой последовательности выбираются предикаты. Для этого используются **критерии информативности**.


Это метрики, которые помогают оценить, *насколько хорошо разбиение данных на узле дерева решений*:

- разделяет объекты по классам (для классификации)
- приближает значения целевой переменной (для регрессии)

Виды критериев информативности:

- классификация — энтропия и критерий Джини
- регрессия — дисперсия


Построение дерева #1



Построение дерева #2

1. Entropy criteria: $H(R) = -p_0 \log p_0 - p_1 \log p_1$

2. Gini impurity: $H(R) = 1 - p_0^2 - p_1^2 = 1 - 2p_0p_1$



$$\frac{|L|}{|Q|} H(L) + \frac{|R|}{|Q|} H(R) \longrightarrow \min_{j,t}$$

What is H?

p_k - доля объектов
класса k в выборке:

$$p_k = \frac{1}{|X|} \sum_{i \in X} [y_i = k]$$

Энтропия

Это мера неопределенности в системе:

$$H(X) = - \sum_{i=1}^C p_i \log_2(p_i),$$

где X — это признак,

C — множество классов,

p_i — вероятность появления класса i .

Чем больше энтропия, тем больше неопределенности в системе.

Если все значения переменной X равновероятны, то энтропия будет максимальной.

А если все значения имеют одну и ту же величину, то энтропия будет минимальной.

Критерий Джини

Он также измеряет неопределенность выборки, альтернатива энтропии:

$$Gini(X) = 1 - \sum_{i=1}^C p_i^2,$$

где X — это признак,

C — множество классов,

p_i — вероятность появления класса i .

Чем меньше значение критерия Джини, тем более однородные объекты в выборке.

Чем больше значение критерия Джини, тем менее однородные объекты в выборке.

В деревьях решений для разбиения выбирают признак, который сильнее всего уменьшает индекс Джини :)

Дисперсия

Оценивает, насколько хорошо признак разделяет таргет (приближает):

$$Var(X) = \frac{1}{n} \sum_{i=1}^n \left(x_i - \bar{x} \right)^2,$$

где n — количество объектов в выборке,

x_i — значение целевой переменной для i -го объекта,

$\bar{x}$ — среднее значение целевой переменной в выборке.

Для разбиения выбирают признак, который сильнее всего уменьшает дисперсию.

Процесс повторяется до критерия остановки.

Процесс построения дерева

Алгоритм

Используется **жадный алгоритм** — выбираются оптимальные для уровня **признак + порог** на этом признаке и только на этом узле, без попыток просчитать несколько шагов вперед.

Прирост информации (Information Gain) — это мера, показывающая, насколько хорошо признак разделяет данные на классы.

ТО ЕСТЬ измеряет, насколько разбиение данных по признаку уменьшает неопределённость (энтропию или критерий Джини).

Чем выше прирост информации, тем полезнее признак для разделения данных на однородные группы по классам.

Виды алгоритмов

То что мы только что описали – это алгоритм **ID3 (Iterative Dichotomiser 3)**, строит дерево, выбирая разбиения по максимальному приросту информации (Information Gain).

C4.5 использует Gain Ratio (скорректированный прирост информации) + может обрабатывать пропуски, в конце делает прунинг.

CART (Classification and Regression Trees) – ключевое отличие в том, что строит бинарные деревья.

ID3/C4.5: пошагово для КИ=энтропия #1

1. Начинаем с полного набора данных. Это будет корневой узел дерева.
2. Для каждого признака рассчитаем энтропию (кол-во неопределенности) набора данных по формуле:

$$H(X) = - \sum_{i=1}^c p_i \log_2(p_i)$$

3. Для каждого признака и t рассчитаем прирост информации по формуле:

$$IG(S, A) = H(S) - \sum \frac{|S_v|}{|S|} * H(S_v).$$

IG(S,A) – прирост информации для признака A, S_v – количество элементов в поднаборе данных, где значение признака A равно v, S – общее количество элементов в наборе данных, $H(S_v)$ – энтропия признака.

ID3/C4.5: пошагово для $KI=$ энтропия #2

4. Выберите признак и t с наибольшим приростом информации. Этот признак станет узлом дерева, и **каждое его значение может рассмотрено как отдельное поддерево**.
5. Для каждого значения выбранного признака повторите шаги 2–4, пока не будет достигнут критерий остановки (напр., мин. кол-во элементов в листе или глубина дерева).

CART: пошагово для КИ=Джини #1

1. Начинаем с полного набора данных. Это будет корневой узел дерева.
2. Для каждого признака и для каждого возможного порога разбиения (для числовых признаков) или значения (для категориальных признаков) разделите данные **на два поднабора** $S_{\text{лев}}$ и $S_{\text{прав}}$.
3. Вычислите индекс Джини (меру неопределённости) для подмножеств:

$$G(S) = 1 - \sum_{i=1}^c p_i^2$$

где p_i — доля элементов класса i в наборе S .

CART: пошагово для КИ=Джини #2

4. Вычислите качество разбиения по формуле (чем больше значение ΔG , тем лучше признак и порог разбиения):

$$\Delta G(S, A) = G(S) - \frac{|S_{\text{лев}}|}{|S|} G(S_{\text{лев}}) - \frac{|S_{\text{прав}}|}{|S|} G(S_{\text{прав}}).$$

5. Выберите признак и порог с максимальным приростом ΔG . Этот признак становится узлом дерева, а его разбиение — ветвлением.

6. Повторите шаги 2–5 для каждой из двух полученных ветвей, пока не выполнен критерий остановки (например, минимальное количество элементов в листе, максимальная глубина дерева или нулевая неопределённость).

Регуляризация деревьев решений

Способы регуляризации для деревьев более разнообразные:

- `max_depth` – ограничение глубины дерева.
- `min_samples_leaf` – минимум объектов в листе.
- `max_leaf_nodes` – максимум листьев в дереве.
- Регуляризация (L1/L2) – штраф за большие веса.
- Pruning – удаление ветвей без значимого вклада в качество.

Спасибо за внимание!