1/6 **Введение**

текущий урок

Тот, кто не знает прошлого, не знает ни настоящего, ни будущего, ни самого себя.

Вольтер
Французский философ

Добро пожаловать в первый модуль, посвященный этике искусственного интеллекта (ИИ). Изучение этой дисциплины важно начать с рассказа о том, как развивалась наука ИИ.

Разработка ИИ и его применение имеет долгую историю: от примитивных систем, работающих на основе логики и математики, до сложных алгоритмов и нейронных сетей, способных анализировать и обрабатывать большие объемы данных. Знание этой истории поможет вам понять текущее положение и прогнозы развития ИИ.

История развития науки ИИ также поможет осознать его этические аспекты. Множество этических вопросов, связанных с ИИ, таких как приватность данных, автономное принятие решений и влияние на трудовые рынки, возникали и рассматривались на протяжении многих лет.

Изучение развития ИИ позволяет учиться на ошибках и проблемах прошлого, чтобы избежать их в будущем и учесть этические аспекты при разработке и применении ИИ.

Сегодня искусственный интеллект так или иначе повлиял на различные сферы человеческой деятельности: от здравоохранения до транспорта, от финансов до кибербезопасности, от образования до дизайна и проектирования.

Сегодня многие задачи решаются с помощью ИИ-сервисов и цифровых помощников: ChatGPT, Grammarly, ClickUp и других интеллектуальных инструментов. Ещё сравнительно недавно многие из нас не слышали о таких компаниях, как OpenAI, NVIDIA или DeepMind, а сегодня их разработки активно обсуждаются во всём мире. Может показаться, что человечество только недавно достигло уровня развития, позволяющего создавать сложные нейронные сети и применять их в промышленном масштабе.

Однако это не совсем так. История развития искусственного интеллекта уходит в 1950-е годы. Многие фундаментальные идеи, лежащие в основе современных алгоритмов машинного обучения, были предложены десятилетия назад. Например, архитектура трансформеров, которая сегодня лежит в основе многих языковых моделей, была описана в научной статье Attention Is All You Need в 2017 году. Позже на её основе появились модели семейства GPT, а в 2022 году был представлен сервис ChatGPT, сделавший технологии генеративного ИИ массово доступными.

Почему же только сейчас происходит бум нейросетей и искусственного интеллекта? Причин несколько:

1. Мощность

Компьютеры XX века не имели такой мощности и скорости обработки данных, как те, которые у нас есть сейчас. Данные, которые компьютер раньше обрабатывал за несколько часов, сейчас обрабатываются за несколько секунд.

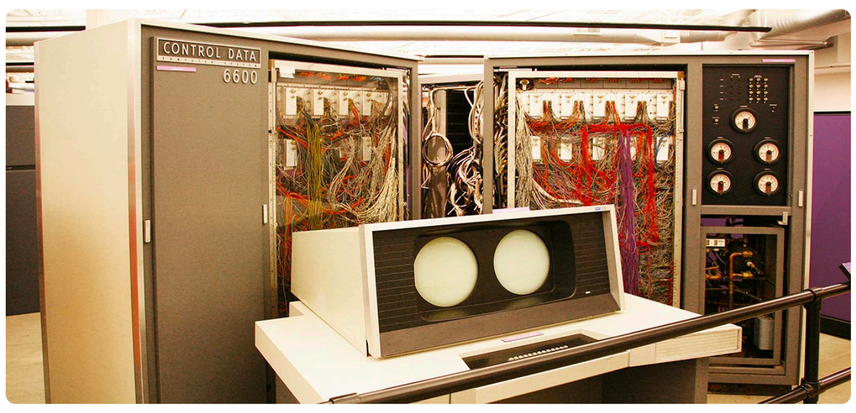

2. Данные

Как правило, при разработке ИИ-продукта самым долгим и трудоемким является не процесс построения модели, а сбор и разметка данных для последующей работы с ними. Например, для чата GPT потребовалось разметить более миллиарда параметров.

3. Базы данных

Сегодня многие из вас сталкивались или даже работали с базами данных: от CRM до простого Excel. Сама инфраструктура записи и хранения большого количества информации на компьютерах сейчас развита намного лучше, чем в XX веке. Поэтому, накопив критическую массу информации с ценами на недвижимость, причинами развития рака, персональными данными клиентов самых крупных маркетплейсов, специалисты по машинному обучению наконец-то смогли привести в действие свои алгоритмы и протестировать их.

Таким образом, большинство ИИ-продуктов, сегодня набирающих популярность в промышленном масштабе, являются потомками тех самых алгоритмов, написанных 10, 30 или даже 50 лет назад. Отсюда следует правило буравчика (rule of thumb) в мире ИИ: наука сильно опережает промышленную разработку.

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026

Дизайн MAX Разработка TUNE-IT

2/6 Промышленное и исследовательское машинное обучение

текущий урок

Возможно, каждый из вас сталкивался с аббревиатурой R&D (Research & Development) в научных статьях, или в колонках на сайте TechCrunch.com, или даже в финансовой отчетности: у таких tech-гигантов как Apple или Alphabet, как правило, всегда есть статья расходов на R&D.

В России эта деятельность называется НИОКР (научно-исследовательские и опытно-конструкторские работы), и ею, как правило, занимаются лаборатории при институтах или крупных корпорациях.

Если говорить исключительно о развитии индустрии машинного обучения (machine learning или ML), то сегодня практически все компании выделяют финансы на развитие ИИ-продуктов и других ИИ-решений. Даже несмотря на то, что Research & Development идут рука об руку, даже внутри одной лаборатории деятельность сотрудников может быть четко разделена на исследовательскую (Research) и промышленную (Industrial). И хотя обе предполагают использование алгоритмов машинного обучения, они различаются по своим целям, методологиям и приложениям.

Промышленное машинное обучение сфокусировано на использовании методов ML для оптимизации процессов, повышения эффективности и автоматизации задач в различных отраслях. Его основная цель — повысить производительность рабочей силы или оборудования, снизить затраты предприятия и стимулировать инновации. Промышленное машинное обучение часто предполагает работу с большими наборами данных, развертывание моделей в реальных сценариях и интеграцию алгоритмов машинного обучения в существующие системы или продукты. В этой области особое внимание уделяется практическому применению, масштабируемости, надежности, а самое главное — прибыльности.

С другой стороны, исследовательское машинное обучение в первую очередь связано с развитием теоретических основ, алгоритмов и методологий машинного обучения. Исследователи в этой области стремятся разрабатывать новые модели, алгоритмы и методы для решения сложных проблем и раздвигать границы возможного. Исследовательское машинное обучение часто включает в себя эксперименты, анализ данных и теоретический анализ, чтобы получить представление о поведении и ограничениях моделей машинного обучения. Основное внимание уделяется разработке новых подходов, которые можно применять в промышленных условиях и за ее пределами.

В то время как промышленное машинное обучение чаще отдает приоритет практичности и прямой применимости, исследовательское машинное обучение делает упор на инновациях, исследованиях и теоретическом понимании. Однако две эти области не исключают, а часто взаимно дополняют друг друга. Информация, полученная в результате исследований в области машинного обучения, может вдохновить на новые подходы и методы для промышленного применения, а практические задачи и данные из промышленных условий могут стать основой для исследований и стимулировать совершенствование алгоритмов и моделей.

Промышленное машинное обучение находит применение в различных секторах, таких как производство, финансы, здравоохранение, транспорт и многие другие. Оно обеспечивает профилактическое обслуживание, обнаружение аномалий, прогнозирование спроса, персонализированные рекомендации, обнаружение мошенничества и многое другое. Используя возможности машинного обучения, отрасли могут извлечь ценную информацию из своих данных и принимать решения на основе данных.

Исследования машинного обучения способствуют разработке новых алгоритмов и моделей, улучшающих возможности систем машинного обучения. Это позволяет обрабатывать более сложные и разнообразные наборы данных, обнаруживать сложные закономерности и генерировать более точные прогнозы. Кроме того, исследовательское машинное обучение привело к прорывам в таких областях, как компьютерное зрение, обработка естественного языка, обучение с подкреплением и генеративное моделирование, открывая новые возможности для промышленного применения.

Поэтому набор навыков, который нужен для каждой сферы, довольно разный.

- Для промышленной разработки требуются хорошие знания программирования, классического машинного обучения, глубокого машинного обучения, иногда даже робототехники.
- Для исследовательской сферы ML нужно иметь глубокие знания математики, линейной алгебры, статистики, эконометрики: хорошо понимать, как работать с матрицами, как работают внутри трансформеры, как лучше всего визуализировать данные.

В любом случае, каждая из этих сфер очень интересна и может привести к большим открытиям, как в научной, так и в промышленной деятельности. Поэтому, если у вас есть желание внедрить что-то инновационное в свои разработки или бизнес, есть смысл прочитать исследования, написанные в 50-х, 80-х или 2000-х годах. Возможно именно исследования тех времен наведут вас на какие-то идеи.

Предлагаем попутешествовать во времени, чтобы ознакомиться с разработками и научными трудами каждой из индустрий ML, вдруг какое-нибудь исследование середины XX века натолкнет вас на светлые мысли.

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026

Дизайн MAX Разработка TUNE-IT

3/6 История искусственного интеллекта

текущий урок

Возможно, каждый из вас сталкивался с аббревиатурой R&D (Research & Development) в научных статьях, или в колонках на сайте TechCrunch.com, или даже в финансовой отчетности: у таких tech-гигантов как Apple или Alphabet, как правило, всегда есть статья расходов на R&D.

В России эта деятельность называется НИОКР (научно-исследовательские и опытно-конструкторские работы), и ею, как правило, занимаются лаборатории при институтах или крупных корпорациях.

Если говорить исключительно о развитии индустрии машинного обучения (machine learning или ML), то сегодня практически все компании выделяют финансы на развитие ИИ-продуктов и других ИИ-решений. Даже несмотря на то, что Research & Development идут рука об руку, даже внутри одной лаборатории деятельность сотрудников может быть четко разделена на исследовательскую (Research) и промышленную (Industrial). И хотя обе предполагают использование алгоритмов машинного обучения, они различаются по своим целям, методологиям и приложениям.

Промышленное машинное обучение сфокусировано на использовании методов ML для оптимизации процессов, повышения эффективности и автоматизации задач в различных отраслях. Его основная цель — повысить производительность рабочей силы или оборудования, снизить затраты предприятия и стимулировать инновации. Промышленное машинное обучение часто предполагает работу с большими наборами данных, развертывание моделей в реальных сценариях и интеграцию алгоритмов машинного обучения в существующие системы или продукты. В этой области особое внимание уделяется практическому применению, масштабируемости, надежности, а самое главное — прибыльности.

С другой стороны, исследовательское машинное обучение в первую очередь связано с развитием теоретических основ, алгоритмов и методологий машинного обучения. Исследователи в этой области стремятся разрабатывать новые модели, алгоритмы и методы для решения сложных проблем и раздвигать границы возможного. Исследовательское машинное обучение часто включает в себя эксперименты, анализ данных и теоретический анализ, чтобы получить представление о поведении и ограничениях моделей машинного обучения. Основное внимание уделяется разработке новых подходов, которые можно применять в промышленных условиях и за ее пределами.

В то время как промышленное машинное обучение чаще отдает приоритет практичности и прямой применимости, исследовательское машинное обучение делает упор на инновациях, исследованиях и теоретическом понимании. Однако две эти области не исключают, а часто взаимно дополняют друг друга. Информация, полученная в результате исследований в области машинного обучения, может вдохновить на новые подходы и методы для промышленного применения, а практические задачи и данные из промышленных условий могут стать основой для исследований и стимулировать совершенствование алгоритмов и моделей.

Промышленное машинное обучение находит применение в различных секторах, таких как производство, финансы, здравоохранение, транспорт и многие другие. Оно обеспечивает профилактическое обслуживание, обнаружение аномалий, прогнозирование спроса, персонализированные рекомендации, обнаружение мошенничества и многое другое. Используя возможности машинного обучения, отрасли могут извлечь ценную информацию из своих данных и принимать решения на основе данных.

Исследования машинного обучения способствуют разработке новых алгоритмов и моделей, улучшающих возможности систем машинного обучения. Это позволяет обрабатывать более сложные и разнообразные наборы данных, обнаруживать сложные закономерности и генерировать более точные прогнозы. Кроме того, исследовательское машинное обучение привело к прорывам в таких областях, как компьютерное зрение, обработка естественного языка, обучение с подкреплением и генеративное моделирование, открывая новые возможности для промышленного применения.

Поэтому набор навыков, который нужен для каждой сферы, довольно разный.

- Для промышленной разработки требуются хорошие знания программирования, классического машинного обучения, глубокого машинного обучения, иногда даже робототехники.
- Для исследовательской сферы ML нужно иметь глубокие знания математики, линейной алгебры, статистики, эконометрики: хорошо понимать, как работать с матрицами, как работают внутри трансформеры, как лучше всего визуализировать данные.

В любом случае, каждая из этих сфер очень интересна и может привести к большим открытиям, как в научной, так и в промышленной деятельности. Поэтому, если у вас есть желание внедрить что-то инновационное в свои разработки или бизнес, есть смысл прочитать исследования, написанные в 50-х, 80-х или 2000-х годах. Возможно именно исследования тех времен наведут вас на какие-то идеи.

Предлагаем попутешествовать во времени, чтобы ознакомиться с разработками и научными трудами каждой из индустрий ML, вдруг какое-нибудь исследование середины XX века натолкнет вас на светлые мысли.

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026

Дизайн MAX Разработка TUNE-IT

4.4 Сферы разработки искусственного интеллекта

Текущий урок

Сферу жизни, в которую уже прочно ИИ, великое множество: сегодня он помогает классифицировать тексты, сегментировать картинки и даже генерировать контент. Поэтому узнать больше узнать об этих сферах и понять, что послужило основными трендами для их развития и как они отразилось на нашей с вами обыденности.

Natural language processing (NLP)

Одной из первых сфер развития ИИ стала обработка естественного языка или Natural language processing (NLP), имеющая богатую историю развития, охватывающую несколько десятилетий. Путешествие началось в 1950-х годах, когда исследователи начали изучать как машины могут понимать и обрабатывать человеческий язык.

Первые усилия были сосредоточены на подходах, основанных на языковых правилах, которые кодировались вручную. Однако прогресс был ограничен из-за сложности языка и огромного количества лингвистических структур и вариаций.

В 1960-е годы появились статистические методы, использующие вероятностные модели для анализа и создания языка. Это привело к значительному прогрессу в области машинного перевода, где программы могли автоматически переводить текст с одного языка на другой.

1970-е годы ознаменовали зарождение области компьютерной лингвистики, целью которой было преодоление разрыва между языком и компьютерами. Ученые начали разрабатывать методы синтаксического и семантического анализа для извлечения структуры и значения предложений.

В 1980–1990-е годы с развитием интернета стали доступны большие объемы текстовых данных, что вызвало интерес к корпусным методам. Исследователи начали использовать алгоритмы машинного обучения для автоматического изучения шаблонов и правил на основе данных, что позволяет выполнять более точные задачи обработки языка, такие как маркировка частей речи и распознавание именованных объектов.

И только в середине 2000-х глубокое обучение произвело революцию в NLP. Нейронные сети, особенно рекуррентные и сверточные архитектуры, продемонстрировали замечательные успехи в различных языковых задачах, включая анализ настроений (определение текста на позитив и негатив), классификацию текста по темам и машинный перевод. Этот прорыв стал возможен благодаря наличию более крупных наборов данных, более мощного оборудования и улучшенных алгоритмов обучения.

В последние годы наблюдается рост популярности моделей трансформеров, в частности — появление архитектуры Transformer в 2017 году. Трансформеры внесли значительные улучшения в понимание языка и задачи генерации, что привело к разработке современных моделей NLP, таких как BERT, GPT, и T5.

Сегодня NLP стала важным компонентом различных приложений, таких как виртуальные помощники, чат-боты, системы анализа настроений и поиска информации.

История развития NLP демонстрирует эволюцию подходов и техник, от методов, основанных на правилах, до статистических систем и систем, основанных на знаниях, и, в конечном итоге, к прорывам, достигнутым с помощью глубокого обучения и моделей-трансформеров. По мере развития технологий и появления новых лингвистических знаний NLP продолжает развиваться, расширяя границы того, чего могут достичь машины в понимании и обработке человеческого языка.

Computer vision (CV)

Другая сфера ИИ, которая повсеместно применяется в кибербезопасности, медицине, робототехнике и даже в сельском хозяйстве — это компьютерное зрение.

С 1960-х годов исследователи стремились разработать машины, способные воспринимать и понимать визуальную информацию. Начинались все с простых методов обнаружения границ, а сейчас перешло к сложным моделям глубокого обучения.

В 1960-х компьютерное зрение возникло как дисциплина, целью которой было научить компьютеры интерпретировать изображения. Ранние методы были сосредоточены на задачах низкоуровневой обработки изображений, таких как обнаружение краев, обнаружение углов и анализ текстур. Эти методы заложили основу для последующего развития в этой области.

В 1970-х и 1980-х годах исследования компьютерного зрения сместились в сторону распознавания образов, стремясь идентифицировать и классифицировать объекты на основе их характеристик и форм. Однако прогресс был ограничен из-за нехватки вычислительных мощностей и доступности данных.

Значительный прорыв, обусловленный появлением более мощных компьютеров и больших наборов данных, произошел 1990-е годы. Исследователи изучали новые методы, такие как теория масштабного пространства, извлечение признаков и геометрическое распознавание. Эти достижения позволили улучшить распознавание и отслеживание объектов, что привело к практическому применению в различных областях, таких как наблюдение, робототехника и медицинская визуализация.

Поворотный момент в компьютерном зрении ознаменовали 2000-е годы — появились алгоритмы машинного обучения, в частности, поддерживающие векторные машины и случайные леса. Эти методы позволили более точно и эффективно обнаруживать и классифицировать объекты. Кроме того, появление цифровых камер и интернета привело к накоплению огромных объемов размеченных визуальных данных, что способствовало разработке более сложных алгоритмов.

В последние годы глубокое обучение произвело революцию в компьютерном зрении. Сверточные нейронные сети (CNN) стали доминирующим подходом, использующим несколько уровней нейронной обработки для изучения сложных визуальных образов. Благодаря наличию огромных вычислительных ресурсов и крупномасштабных наборов данных CNN достигли беспрецедентной точности в таких задачах, как классификация изображений, обнаружение объектов и семантическая сегментация.

Сегодня компьютерное зрение применяется во многих областях. Технологии распознавания лиц получили широкое распространение, обеспечивая безопасную аутентификацию и улучшая системы наблюдения. Автономные транспортные средства в значительной степени полагаются на компьютерное зрение, чтобы воспринимать и понимать окружающую среду, что делает их более безопасными и эффективными. Медицинская визуализация извлекает выгоду из алгоритмов компьютерного зрения для диагностики и планирования лечения.

Speech recognizer

История распознавания речи восходит к середине XX века, когда исследователи начали изучать возможность разработки машин, способных понимать человеческую речь. За прошедшие годы в этой области произошли значительные изменения, что привело к появлению сложных систем распознавания речи, которые мы имеем сегодня.

Ранние усилия по распознаванию речи были сосредоточены на методах распознавания образов с использованием спектрограмм. В 1950-х годах Bell Labs представила систему «Audrey», которая могла распознавать цифры, произнесенные одним голосом. Однако эти ранние системы имели ограниченный словарный запас и были не очень точными.

В 1960-х и 1970-х годах исследователи начали изучать скрытые модели Маркова (CMM) для распознавания речи. CMM позволили моделировать статистические закономерности в речи, что значительно повысило точность систем распознавания. Несмотря на эти достижения, технология все еще была далека от практического использования в повседневном использовании из-за ограниченного словарного запаса и высокого уровня ошибок.

В 1980-е годы инженерным факультетом Кембриджского университета произошел прорыв. Был презентован «Набор инструментов для скрытых марковских моделей» (HTK). HTK предоставил набор основу для разработки систем распознавания речи и стал широко использоваться в исследовательском сообществе.

В 1990-х значительный прогресс в распознавании речи был достигнут, благодаря достижениям в области машинного обучения и доступности более мощных вычислительных ресурсов. Исследователи начали включать нейронные сети в системы распознавания речи, что привело к повышению точности и способности обрабатывать большие словарные запасы.

В конце 1990-х и начале 2000-х годов появились коммерческие системы распознавания речи, такие как ViaVoice от IBM и Dragon NaturallySpeaking от Dragon Systems. Эти системы смогли распознавать непрерывную речь и имели улучшенный словарный запас, что сделало их более практичными для повседневного использования.

С появлением смартфонов и виртуальных помощников в 2010-х годах распознавание речи стало повсеместной технологией. Такие компании, как Google и Apple, интегрировали распознавание речи в свои мобильные устройства, позволив пользователям выполнять задачи с помощью голосовых команд.

Сегодня системы распознавания речи достигли такого уровня, что могут точно расшифровывать большие объемы речи в режиме реального времени. Они используются в различных приложениях, включая службы транскрипции, устройства с голосовым управлением и голосовые помощники. Продолжающиеся исследования и разработки продолжают расширять границы распознавания речи с целью достижения еще большей точности и лучшего понимания естественного языка.

Machine Learning (ML)

Машинное обучение имеет долгую и увлекательную историю, насчитывающую несколько десятилетий. Его корни можно проследить в 1940-х годах, когда исследователи начали изучать идею создания машин, способных обучаться и адаптироваться на основе данных.

Один из первых прорывов в машинном обучении произошел в 1956 году, когда Артур Самюэл разработал компьютерную программу, позволяющую играть в шашки. Используя технику, называемую обучением с подкреплением, программа со временем улучшила свою производительность, делая выводы из собственного опыта.

В 1960-х и 1970-х годах машинное обучение получило дальнейшее развитие благодаря внедрению алгоритмов дерева решений и развитию концепции искусственных нейронных сетей. Эти сети были вдохновлены структурой и функционированием человеческого мозга и проложили путь к более сложным моделям машинного обучения.

Однако прогресс в машинном обучении замедлился в 1980-х и 1990-х годах из-за ограничений вычислительной мощности и доступности данных. Исследователи переключили свое внимание на экспертные системы, основанные на правилах, которые полагались на явные знания, а не на обучение на данных.

На рубеже веков произошло возрождение машинного обучения. Доступность больших наборов данных и достижения в области вычислительной мощности вдохнули интерес к этой области. В 2006 году Джеффри Хинтон и его команда представили глубокое обучение — область машинного обучения, в которой используются многослойные искусственные нейронные сети. Глубокое обучение изменило правила игры, превзойдя традиционные методы машинного обучения в различных областях, таких как распознавание изображений и речи.

Развитие интернета и цифровых технологий еще больше способствовало развитию машинного обучения. Такие компании, как Google, «ВКонтакте» и Amazon, начали использовать алгоритмы машинного обучения для работы систем рекомендаций, поисковых систем и таргетированной рекламы. Широкое внедрение машинного обучения сделало его массовым явлением и продемонстрировало его потенциал в преобразовании отраслей.

В последние годы, с появлением больших данных и облачных вычислений, машинное обучение продолжает быстро развиваться. Доступность масштабных наборов данных и мощной вычислительной инфраструктуры позволила исследователям и практикам разрабатывать более сложные модели машинного обучения, такие как глубокое обучение с подкреплением и генеративно-состязательные сети.

Робототехника и прочее

Ранний ИИ в робототехнике был сосредоточен на системах, основанных на правилах, где хорошо определенные инструкции направляли действия робота. Однако этих системам не хватало адаптивности, и они с трудом справлялись со сложными задачами. Внедрение машинного обучения в 1980-х годах стало революцию в области искусственного интеллекта в робототехнике, позволив роботам учиться на основе данных и повышать свою производительность.

Одна важная веха произошла в 1990-х годах с появлением робототехники, основанной на поведении. Эти системы подразделяли интеллектуальное поведение простых модулей поведения для достижения сложных действий. Такой подход позволил роботам проявлять больше автономии и гибкости при взаимодействии с окружающей средой.

В последние годы появление глубокого обучения и нейронных сетей подняло искусственный интеллект в робототехнике на новые высоты. Глубокое обучение позволяет роботам распознавать закономерности, воспринимать объекты и принимать решения на основе огромных объемов данных. Это достижение значительно улучшило способность роботов выполнять сложные задачи, такие как распознавание объектов, обработка естественного языка и даже автономное вождение.

Использование ИИ в робототехнике нашло применение в различных областях. Промышленная автоматизация выиграла от роботизированных систем, которые могут выполнять повторяющиеся задачи с точностью и эффективностью. В здравоохранении для операций, терапии и ухода внедряют роботов на базе искусственного интеллекта, что улучшает результаты лечения пациентов. Кроме того, роботы с поддержкой искусственного интеллекта используются в поисково-спасательных операциях, исследовании космоса и мониторинге окружающей среды, где они могут перемещаться по опасным средам или собирать данные в отдаленных районах.

Несмотря на эти достижения, проблемы остаются. Обеспечение безопасной и этичной работы роботов, устранение предвзятости в алгоритмах ИИ, а также обеспечение прозрачности и подотчетности — важнейшие задачи. Нахождение правильного баланса между контролем человека и автономностью роботов также требует тщательного рассмотрения.

Будущее искусственного интеллекта в робототехнике обещает огромные перспективы. Продолжение исследований в области расширенного восприятия, принятия решений и взаимодействия человека и робота еще больше расширит возможности роботов. Более того, интеграция ИИ с другими новыми технологиями, такими как дополненная реальность, виртуальная реальность и интернет вещей, откроет новые возможности для интеллектуальных робототехнических систем.

* Meta Platforms Inc. признана экстремистской, её продукты запрещены на территории РФ.

‹ Предыдущий урок Следующий урок ›

5/6 Итоги модуля

текущий урок

ИИ интегрирован в повседневную жизнь и применяется в здравоохранении, финансах, транспорте и т. д. Такие компании, как Google, «Фейсбук»* и Amazon, вкладывают значительные средства в исследования и разработки в области искусственного интеллекта, расширяя границы возможностей машин. Однако этические проблемы и потенциальное влияние ИИ на рынок труда и общество продолжают оставаться важными темами для обсуждения.

Развитие искусственного интеллекта было нелинейным: с оглушительными успехами и непредсказуемыми провалами. По пути философских, символических рассуждений на тему замены человека машинами до современного ML и DL ИИ превратился в неотъемлемую часть нашего мира. Благодаря постоянным исследованиям и инновациям, будущее искусственного интеллекта имеет огромный потенциал для дальнейшего развития и влияния.

Прозрачность, подотчетность, предвзятость, конфиденциальность и влияние на занятость — ключевые области, которые требуют этических ограничений для руководства разработкой и внедрением систем ИИ. Нахождение баланса между технологическим прогрессом и этической ответственностью имеет решающее значение для создания будущего, в котором ИИ будет приносить пользу человечеству, одновременно защищая наши коллективные ценности.

О том как это сделать и какие инструменты помогут сделать любой ИИ-продукт более этичным, поговорим в следующем модуле!

* Meta Platforms Inc. признана экстремистской, её продукты запрещены на территории РФ

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026

Дизайн MAX Разработка TUNE-IT

1/6 Введение

текущий урок

> Данные — это новая нефть. Но, в отличие от нефти, данные можно использовать снова и снова.
>
> Клайв Хамби, аналитик, создатель системы Tesco Clubcard

Отличная новость для всех дата-сайентистов и ML/DL инженеров: сегодня вы — новые «нефтяники»!

Имея на руках хорошо размеченные данные, вы можете:

- предсказать вероятность заболевания,
- порекомендовать пользователю новый интересный контент,
- классифицировать товары по типу: просроченный или годный,
- и еще много всего!

Но ключевой момент — это получение хорошо размеченных данных!

> **Разметка данных** — добавление в сырые данные тегов, которые позволяют модели машинного обучения видеть целевые атрибуты.

Имея на руках хорошо размеченные данные, вы можете:

- предсказать вероятность заболевания,
- порекомендовать пользователю новый интересный контент,
- классифицировать товары по типу: просроченный или свежий.

И это только малая часть того, что можно автоматизировать.

Качество разметки — ответственность дата-сайентиста. Если данные размечены некачественно, модель будет предсказывать неправильные результаты, что может привести к неприятным последствиям, например:

- человек с серьезным заболеванием получит неправильный диагноз и его лечение в лучшем случае не поможет, а в худшем — навредит;
- пользователь сайта столкнется с неточными рекомендациями и решит покинуть его;
- полиция задержит невиновного, если его внешность частично совпадает с фотороботом преступника.

Для того чтобы добиться качественной разметки данных, в процессе участвуют несколько специалистов:

- Разметчик — собирает и подготавливает данные.
- Разработчик — создает алгоритм.
- Тестировщик — проверяет модель на уязвимости и ошибки.

Рассмотрим пример: вы разрабатываете сервис по доставке цветов, который предлагает букеты на основе предпочтений, таких как любимый цвет, музыкальные предпочтения или стиль одежды. Разметчик должен найти закономерности между этими различными группами данных, чтобы создать систему рекомендаций, работающую точнее интуиции. Например, он может обнаружить, что фанатам ориентального техно нравятся бордовые розы и белые лилии.

Затем разработчик создаёт алгоритм, который преобразует эти данные в анкеты или формы для выбора предпочтений. Наконец, тестировщик проверяет модель, выявляя возможные ошибки, которые могли бы негативно повлиять на качество рекомендаций.

Этот пример иллюстрирует лишь один из этапов бизнес-процесса. В реальности существует множество других этапов, каждый из которых требует тщательного анализа и проработки. Далее мы подробно разберём каждое звено этой цепочки.

В этом модуле вы:

- познакомитесь с основными принципами работы с данными, включая их сбор, разметку и обработку;
- изучите роль специалистов, участвующих в обработке данных: разметчика, разработчика и тестировщика;
- поймёте важность качества разметки данных для работы моделей машинного обучения и последствия ошибок;
- научитесь различать первичные и вторичные данные, выбирать методы их сбора и обработки;
- ознакомитесь с этическими аспектами работы с данными, включая вопрос предвзятости искусственного интеллекта и её влияние на результаты;

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026

Дизайн MAX Разработка TUNE-IT

Когда речь заходит о разработке моделей машинного обучения, основным этапом является сбор качественных данных. От того, как данные собраны и предобработаны, зависит качество будущей модели. Поэтому специалисту по машинному обучению необходимо знать, какие существуют методы сбора данных и их особенности. Прежде чем подробно рассмотреть каждый из методов, давайте разберемся с понятием данных и доступных ресурсов.

Существуют два вида данных: первичные и вторичные, о таких несколько материалов из сбора. Выбор подходящего метода зависит от задачи, которую нужно решить.

Сбор первичных данных или primary research

Первичные данные (PD) — информация, собранная конкретным исследователем под конкретную цель.

Самым популярным методом сбора PD — опросы, наблюдение, эксперименты, интервью и фокус-группы. Рассмотрим каждый из этих методов более подробно.

Опросы

Опросы — один из самых распространенных методов сбора данных. Они могут проводиться через анкетирование или интервью по телефону, почте, онлайн или лично.

Преимущества этого способа включают гибкость по отношению к любой аудитории и к любой теме вопрос, низкие затраты и возможность с помощью вопросов сбора данных, которые невозможно получить другими способами. Также можно быстро собрать данные для успешного старта вашего проекта. Недостатки: низкая точность данных.

Пример

Телефонное анкетирование потенциальной целевой аудитории молока «Коровьи». Цель — выяснить, какой процент потребителей молока готов покупать молоко, которое производится на ферме, расположенной в экологически чистом районе. Для этого можно составить анкету, в которой будет несколько вопросов, помогающих определить, насколько важной для людей является экологическая обстановка вокруг ферм, которые снабжают молоком супермаркеты, в которых они ходят. Также можно составить вопросы, которые помогут выяснить, насколько важно для людей качество молока, которое они покупают.

А теперь предположим, что мы опросили 1 000 человек, которые ответили на вопросы. Результаты можно представить в виде таблицы. Однако такой способ не очень удобен для восприятия информации. Гораздо проще воспринимать информацию, представленную в виде диаграмм. Поэтому результаты опроса лучше представить в виде диаграмм.

Подробнее, какие из них построили лучше.

Опросник №1

Как часто вы смотрите контент на платформе ABC?

- Всегда
- Часто
- Редко
- Никогда

Считаете ли вы контент на платформе ABC оскорбительным?

- Да
- Нет

Смотрели ли вы когда-нибудь в круг смеха на платформе ABC?

- Да
- Нет

Есть ли развивающие платформы ABC творческие или детские, которые вам нравятся. Посоветовали ли бы вы свои друзьям/знакомым посмотреть его?

- Да
- Нет

Считаете ли вас ABC лучше продуктов на рынке?

- Да
- Нет

И в итоге, что подписка на платформу ABC стоит дорого?

- Да
- Нет

Пример опросника 1

Опросник №2

Как часто вы смотрите контент на платформе ABC?

- Каждый день
- 4-6 дней в неделю
- 1-3 дня в неделю
- Не смотрю

Какой контент на платформе ABC вы смотрите интересным?

- Детектив
- Мелодрама
- Комедия
- Другое _____

Смотрели ли вы когда-нибудь на платформе ABC?

- Да
- Нет

Посоветовали бы вы свои друзьям/знакомым стать подписчиками платформы ABC?

- Да
- Нет

Какой из платформ вам кажется больше всего?

- ABC
- XYZ
- Ютьютюзер

И в итоге, что подписка на платформу ABC очень дорогая

- Да
- Нет

Пример опросника 2

Хорошим отличием считается тот, который позволяет вам получить четкие и понятные ответы от респондентов. Поэтому вы, зная разницу между опросниками, можете выбрать наиболее подходящий. Рекомендуем по действительным основам наиболее лучше первого, поскольку соответствует реальным данным.

Правила составления опросника

1. **Используйте только в краткой язык.** Помните про понятный язык — респондентам должны быть понятны вопросы. Избегайте жаргона, профессиональных терминов и сложных синтаксических фраз, чтобы предотвратить неправильное толкование.

2. **Задавайте конкретные и целенаправленные вопросы.** Во избежание путаницы каждый вопрос должен касаться только одного аспекта. Будьте конкретны и избегайте общих формулировок, которые могут привести к неточным ответам.

3. **Соблюдайте логичный порядок вопросов.** Расположите вопросы в логическом порядке, который кажется респондентам естественным. Начните с простых и общих вопросов, а затем переходите к более сложным или специфическим. Последовательность поможет сохранить интерес респондентов и снизит вероятность ошибок.

4. **Избегайте наводящих или предвзятых вопросов.** Чтобы получить точные данные, ваши вопросы должны быть нейтральными. Избегайте использования слов, направляющих ответов, которые могут повлиять на мнение респондента или побуждают к конкретному ответу. Сохраняйте беспристрастность, чтобы обеспечить целостность данных.

5. **Используйте соответствующие форматы ответов.** Выбирайте форматы ответов, которые лучше всего соответствуют вопросам. Например, используйте закрытые вопросы, когда вам нужны ответы «да/нет» или «выберите один», а открытые вопросы, когда вы хотите собрать подробную информацию. Убедитесь, что варианты ответа охватывают все возможные ответы и не перекрываются.

6. **Избегайте двойных вопросов.** Каждый вопрос должен быть посвящен одному вопросу или теме. Избегайте объединения нескольких вопросов в один вопрос, поскольку это может запутать респондентов и получить неточные данные.

7. **Рассмотрите шкалы ответов и ранжирование.** Если ваши анкеты включают шкалы ответов или ранжирование, используйте четкие инструкции. Убедитесь, что респонденты понимают, когда следует перейти к следующему вопросу, или как перейти к другому разделу в онлайн-опросе.

8. **Проведите предварительное тестирование анкеты.** Прежде чем распространять анкету, проведите тестирование на небольшой выборке, чтобы выявить потенциальные недостатки или неясности. Предварительное тестирование может помочь вам усовершенствовать вопросы, чтобы повысить качество собранных данных.

9. **Предоставьте четкие инструкции.** Включите в анкету четкие четкие инструкции, которые помогут респондентам ответить на вопросы. Укажите любые необходимые термины или концепции, которые могут быть вам неизвестны.

10. **Будьте краткими.** Длинные анкеты могут привести к усталости и снижению количества ответов. Сохраняйте анкету как можно более краткой, сосредоточившись на самых необходимых данных. Избегайте ненужных вопросов, которые могут привести к сложным вопросам и удлинить вам лишнее или несущественное.

Задание 1

Предположим, что вы Coca-Cola.Вам нужно построить воронку для того, чтобы понять, какой процент людей, которые видят рекламу, купят ваш продукт.

Какие данные вам нужно собрать, чтобы построить такую воронку?

1. Количество вы были довольны тем недостатком достаточно низкого кулинар?
2. Вам понравился ваш вкусный новый бокал?
3. На каких сцену вы бы оценили наши приложение?
4. Что вы испытываете покар вся или общение?

Перепишите эти вопросы, чтобы они были математическими, ближе и давали более точные данные.

Был ли дегустаторительным ваш опыт доставки?
Ответ: Да/нет. Вопрос слишком общий. Без конечных суждений, как в количественном вопросе отзывов.

Оцените, насколько вы довольны доставкой по шкале от 1до 5, где 1 — совсем недовольны, а 5 — полностью довольны.
Плюсы: Нужные, конкретное формулировано с четкой шкалой, что позволит респондентам точно выразить свое мнение.

Как вам наш новый бокал?
Плюсы: Нужные, математическая формулировка, что позволит респондентам выразить свой мнение.

Оцените по шкале от 1до 5 вы дали нашему приложению, где 1 — совсем не нравится, а 5 — очень нравится?
Плюсы: Четкий задать как вариантов, так и конкретное примеру шкалы, что делает оценку понятной и позволяет в дальнейшем анализе данных.

Какие товары вы хотели(-ла) бы видеть?
Плюсы: Нужные открытый, что даёт респонденту свободу выбора и позволяет собирать больше информации. Вопрос с выбором ответа и ссылки на дает объективные данные о предпочтениях клиента.

Ответы

Наблюдения

Наблюдение — это метод, при котором исследователь фиксирует поведение объектов, события или явления. Это можно делать как в естественных условиях, так и в контролируемых среде, с участием респондентов.

Преимущества этого способа включают возможность получить информацию о том, как люди ведут себя в реальных ситуациях, без искажений, которые могут возникнуть при опросах. Это полезно для изучения сложных процессов, которые трудно описать словами, или для сценарий, в которых люди могут не осознавать свое поведение. Недостатки: это может быть трудоемким и дорогостоящим, а также может потребовать специальных навыков и обучения для наблюдателей.

Продолжим рассматривать пример с «Коровьими». Наблюдение за тем, как люди покупают молоко в естественных условиях, может помочь исследователям понять, какие факторы влияют на решение покупателя. Например, участники могут выбирать молоко, основываясь на ценность в зависимости от вашего времени следующим образом.

Если факт того, что участники будут в купальниками, может повлиять на результаты полученных в помещении, это всё же позволит собрать данные о том, как покупатели ведут себя в торговом зале. Это позволит исследователям понять, какие факторы влияют на решение покупателя, и использовать эту информацию для разработки более эффективных маркетинговых стратегий.

Проверяем может служить известный психологический сценарий: если бы покупатели в помещении увидели, что одна покупательница купила молоко, а другая — нет, посторонние бы женщины молоко, а другие — нет. Исследователи бы увидеть, насколько такие действия и эффективнее и сравнение с анализ покупателя как во данные, что основной вопрос? А это — эффективно?

Теперь напишем в примеры с «Коровьими»?

Ответы

Эксперименты

Предполагаем, вы предоставили респондентам все возможные виды молока, но не сказали, что молоко производится на ферме, расположенной в экологически чистом районе. Затем вы можете провести опрос, чтобы выяснить, насколько важно для людей качество этой воды. Результаты такого опроса могут помочь вам понять, насколько важна экологическая обстановка вокруг ферм, которые снабжают молоком супермаркеты, в которых они ходят. Также можно составить вопросы, которые помогут выяснить, насколько важно для людей качество молока, которое они покупают.

Таким образом, эксперимент позволяет не только выявить слабые стороны продукта, но и предложить возможные решения, которые выходят за рамки изучаемых вопросов.

Интервью

В социологии этот метод называется глубинное интервью, а в IT это часто называется юзабилити-тестирование (usability testing) — это процесс, в котором исследователь задает вопросы респондентам и фиксирует ответы. Интервью могут проводиться по телефону, лично или через видеосвязь. Важно учитывать, что интервью могут быть более трудоемкими и дорогостоящими, чем другие методы сбора данных, и могут потребовать специальных навыков и обучения для интервьюеров. Недостатки: с данными, которые вы собираете в ходе разработки мобильного приложения.

Теперь попробуйте придумать пример интервью для исследования продукта. Например, вы можете спросить у респондентов, чтобы узнать, что именно они ищут в молоке и можно улучшить в продукте?

Фокус-группы

Фокус-группы — это модерированная дискуссия малой численности группа, которая собирается для обсуждения определенной темы или продукта. Метод может быть полезен для получения качественных данных о мнениях и отношениях людей и для изучения сложных тем.

Например, исследователь могут использовать фокус-группы для изучения потребительских предпочтений в отношении молока. Они могут собрать группу людей с условиями, разными и отдельных с судить чтобы собрать мнения о методах обучения, структуре программ, внедрении технологий и общем качестве образования. Это позволит получить ценную информацию о том, что работает, а что нет, и помочь в улучшении и конечные конкретные данные. Недостатки: фокус-группы могут быть дорогими и трудоемкими в организации, а также могут потребовать специальных навыков и опыта работы с группой и могут иметь ограниченную репрезентативность.

Итоговое сложно фокус-группа используется в тех случаях, когда необходимо узнать не только, что думают люди, но и почему они так думают. Например, если компания хочет понять, почему ее последняя кампания в социальных сетях не принесла ожидаемых результатов, она может провести фокус-группу, чтобы выяснить, что не понравилось участникам в рекламе. Это позволит компании понять, какие аспекты кампании были неэффективными, и внести необходимые изменения в будущие кампании.

Сбор вторичных данных или secondary research

Основная отличия вторичных данных от первичных заключается в том, что во втором случае данные собираются не вами, а другим исследователем или организацией. Вторичные данные могут быть получены из различных источников, включая статьи или базы данных. Они могут быть полезны для экономии времени и ресурсов, а также могут предоставить ценную информацию, которая может не быть доступна другими способами.

Однако важно помнить, что надежность и качество таких данных исследователь не может не всегда контролировать напрямую. Здесь они могут быть менее релевантными и не актуальными. Например, статьи не журналов, статистика из журналов. Поэтому важно тщательно оценивать качество и надежность любых вторичных данных, которые вы планируете использовать. Это может включать рецензирование через источников и проверку их репутации.

Обзор литературы

Обзор литературы — один из наиболее распространенных методов исследования, который включает анализ опубликованных книг, научных статей, материалов конференций и других письменных источников по интересующей теме. Этот метод позволяет исследователям получить представление о существующих знаниях и идеях по теме, выявить пробелы в исследовании и сделать обоснованные выводы. Обзор литературы может быть полезным инструментом для определения направления будущих исследований и может помочь ученым в формулировании новых гипотез и разработке планов для дальнейшего изучения.

Анализ общедоступных наборов данных

Анализ общедоступных данных относится к предварительно отчетливых, результатов опросов, переписи, наблюдений и других источников, доступных широкому кругу исследователей. Такие данные можно найти на официальных сайтах, например, на Центр Research, Research.gov, статистических по поиску сайте и статьями можно найти в научных журналах, книгах и других публикациях. Использование общедоступных данных может сэкономить время и ресурсы, которые могут потребоваться для сбора данных, а также может служить хорошим способом для начала исследования. Использование данных может помочь исследователям получить представление о существующих знаниях и идеях по теме, выявить пробелы в исследовании и сделать обоснованные выводы. Однако важно тщательно оценивать качество и надежность любых данных, которые вы планируете использовать, чтобы гарантировать, что они соответствуют вашим исследовательским вопросам и являются достоверными.

Контент-анализ

Контент-анализ — это метод качественного исследования текста. Он позволяет исследователям систематически изучать текстовые данные, такие как новостные статьи, опубликованные отчеты, сообщения в социальных сетях и стенограммы интервью. Контент-анализ может быть полезным инструментом для выявления тенденций, тем и закономерностей в текстовых данных. Он может помочь исследователям понять, как часто определенные слова или фразы используются в тексте, а также выявить взаимосвязи между различными темами или концепциями. Подробнее о контент-анализе и о том, как его проводить, прочитать в этой статье.

Повторный анализ данных, собранных другими исследователями

Помимо других методов, исследователи могут использовать чужие данные, собранные ранее другими исследователями. Это может быть полезным способом для экономии времени и ресурсов, а также может предоставить ценную информацию, которая может не быть доступна другими способами. Использование чужих данных предоставляет уникальные возможность для исследователей изучать большие наборы данных, которые могут быть слишком дорогими или трудоемкими для сбора самостоятельно. Также данные позволяют исследователям использовать данные из различных источников, чтобы получить более полное представление о предмете исследования. Однако важно тщательно оценивать качество и надежность любых данных, которые вы планируете использовать, чтобы гарантировать, что они соответствуют вашим исследовательским вопросам и являются достоверными и добросовестным участием.

Задание 2

Предположим, что вы ML-инженер, работающий в Авто-банке. Вас попросили построить модель, которая будет предсказывать, какие клиенты с наибольшей вероятностью откликнутся на предложение о кредитовании. Вам нужно собрать данные для этого. Какие данные вы будете использовать? Составьте список данных, которые можно найти в открытых источниках.

Попробуйте самостоятельно найти такие данные и дополнить пропуски в таблице ниже.

Дата	Ответ
11/11/2022	15,05
01/01/2023	15,05
01/04/2023	15
01/07/2023	15,01
01/10/2023	15,02
01/01/2024	15,03
01/04/2024	15,04
01/07/2024	15,05
01/10/2024	15,06
01/01/2025	15,07
01/04/2025	15,08
01/07/2025	15,09
01/10/2025	15,10

1. 11/11/22 — 12
2. 01/01/2023 — 13
3. 01/01/2025 — 13

Ответы

Итог

Подведем краткий итог. Чтобы найти наиболее подходящий метод сбора данных, можно ответить на несколько ключевых вопросов:

- Какова цель исследования?
Определите цели исследования, которые нужно достичь, которые лучше всего соответствуют вашим данным результатам.
- Какие у вас есть ресурсы?
Оцените доступные ресурсы, время, бюджет, человеческие ресурсы. Это поможет определить, какие методы сбора данных можно использовать при этом этой метод.
- Какие характеристики есть у вашей целевой группы?
Учитывайте такие факторы, как демографические данные, социально-экономический статус, уровень образования и другие релевантные факторы.
- Какой метод будет наиболее точным по отношению к респондентам?
Выберите метод, который наиболее вероятно будет точным для респондентов и собирающий точные сведения, а также поможет избежать предвзятости и субъективности участия.

Ответьте на эти вопросы, вы сможете выбрать наиболее эффективный и точный метод сбора данных для вашего исследования.

3/6 Предвзятость искусственного интеллекта

текущий урок

В предыдущем уроке мы обсудили методы сбора данных и как они влияют на успех создания моделей машинного обучения. Однако сбор данных — это лишь первый шаг. Теперь важно понимать, что сами данные могут содержать предвзятость, а это может привести к несправедливым или неточным результатам работы модели. Именно поэтому в работе с искусственным интеллектом возникает необходимость учитывать не только технические аспекты, но и этические.

В этом уроке мы изучим, что такое предвзятость искусственного интеллекта, как она может влиять на результаты работы алгоритмов и какие этические проблемы она порождает. Мы рассмотрим примеры реальных ситуаций, где предвзятость стала проблемой, и обсудим различные подходы к её выявлению и смягчению.

Этические проблемы

Опросник составлен, респонденты выбраны, данные собраны. Можно ли теперь передавать их разработчику для создания алгоритма?

С точки зрения процесса — да. Но если рассматривать этот вопрос с этической стороны, важно учесть еще один нюанс. Искусственный интеллект — это всего лишь инструмент для обработки данных, но подходы к его работе должны опираться на принципы справедливости и непредвзятости. В англоязычной литературе вы встретите такие термины, как fairness (справедливость) и bias (предвзятость).

Теперь давайте свяжем этику и технологии с помощью мыслительного эксперимента. Представьте, что вы — дата-сайентист, которому поручено разработать поисковую систему для отображения изображений, соответствующих ключевым словам, как в Google Images.

Технически это реализовать несложно. Но представьте, что 90% генеральных директоров в мире — мужчины. Когда пользователь запрашивает изображение «генеральный директор», ИИ будет показывать только мужчин, отражая реальную статистику. Однако есть и 10% женщин, которые занимают руководящие должности. Должны ли мы поддерживать такую гендерную стереотипизацию, усиливая неравенство? Или стоит создать более сбалансированную выборку, в которой будут представлены и мужчины, и женщины, даже если это не соответствует реальности?

Дата-сайентисты часто рассматривают предвзятость как статистическое отклонение. Алгоритм считается плохим, если в большинстве случаев он даёт неверные результаты. Например, если погодное приложение регулярно переоценивает вероятность дождя, его прогнозы будут считаться недостоверными.

Однако проблема предвзятости гораздо шире. Этот термин часто воспринимается негативно, ассоциируется с необъективностью. Мы предлагаем рассматривать его иначе — как характеристики, заранее заложенные в данных самой реальностью.

Поэтому алгоритм, который по запросу «генеральный директор» показывает только мужчин, предвзят, но при этом статистически объективен. С другой стороны, если мы разработаем модель, которая игнорирует пол, мы закладываем в неё статистическую предвзятость другого рода.

Как вы бы решили эту этическую проблему? Пока можете подумать над этим — мы вернёмся к вопросу позже.

Теперь давайте представим другую ситуацию. Вы работаете в кредитном отделе банка, и у вас есть алгоритм, который быстро оценивает, можно ли выдать кредит конкретному человеку. Основой служит кредитный рейтинг (FICO), который предсказывает вероятность возврата денег. Большинство людей с рейтингом выше 600 получают кредит, а остальные — нет.

Этот алгоритм кажется непредвзятым и справедливым, если он оценивает всех на основе их кредитной истории, не обращая внимания на такие характеристики как раса. Но что, если представители одной расы имеют статистически более высокий рейтинг, чем представители другой? Этот дисбаланс связан с историческим неравенством.

И вот снова возникает этическая дилемма: справедливо ли увековечивать исторические неравенства через алгоритм, который просто воспроизводит существующую реальность?

Есть ещё одна концепция справедливости — распределительная. Согласно этому подходу, алгоритм будет считаться справедливым, если приводит к справедливым результатам. С этой точки зрения, наш алгоритм несправедлив, потому что он фактически принимает дискриминационные решения, даже если они кажутся статистически обоснованными.

Один из способов решения этой проблемы — запрограммировать разные пороги для разных групп клиентов: для одной FICO будет 600, для другой — 500. Это добавляет человеческий фактор в процесс принятия решений, где алгоритмическая справедливость лишь помогает, но не является единственным инструментом.

Мы привели несколько примеров реальных этических дилемм. Теперь давайте систематизируем подходы к их решению.

Как решаются этические проблемы

Определение источников предвзятости

Первый шаг в решении этических проблем — выявление потенциальных источников предвзятости. Необходимо тщательно изучить данные, чтобы понять, как различные формы систематической ошибки могут на них повлиять. Например, могут ли ошибки при сборе данных или наблюдениях вносить искажения? Используются ли исторические данные, которые уже содержат предвзятость? Ответив на эти вопросы, можно предотвратить или смягчить возможные негативные последствия предвзятости.

Установление руководящих принципов

Для эффективного управления предвзятостью организациям важно установить руководящие принципы и процедуры, которые будут направлены на её выявление и устранение. Прогрессивные компании документируют каждый случай предвзятости, описывают шаги, предпринятые для её устранения, и предпринимают меры по её смягчению. Прозрачность в этих процессах помогает минимизировать ошибки и улучшить работу моделей машинного обучения.

Определение репрезентативных данных

Перед тем как собирать данные для обучения модели, важно понять, как должен выглядеть репрезентативный набор данных. Аналитики должны учитывать, какую популяцию необходимо смоделировать, и какие характеристики должны быть учтены. Только точные и сбалансированные данные позволяют создать модель с минимальной предвзятостью.

Мониторинг и анализ моделей в реальной работе

Последний шаг — это мониторинг работы модели в реальной жизни. Модель может работать по-разному в учебных условиях и на практике. Поэтому необходимо внедрять методы постоянного анализа и мониторинга эксплуатационных характеристик модели. Если будут обнаружены признаки предвзятости, важно вовремя внести коррективы, чтобы предотвратить потенциальный вред.

Эти вопросы интересуют не только специалистов по искусственному интеллекту, но и учёных из разных гуманитарных наук. Мы предлагаем вам ознакомиться со статьями, которые помогут глубже погрузиться в тему. Они на английском, поэтому самое время воспользоваться преимуществами, которые дает искусственный интеллект, и перевести их в один клик по кнопке прямо в браузере:

- Почему так сложно сделать искусственный интеллект справедливым и беспристрастным?
- 10 вещей, которые мы должны требовать от Big Tech-пятерки сегодня

Итог

В этом уроке вы разобрали одну из самых сложных и важных проблем в области искусственного интеллекта — предвзятость. Вы увидели, как она может возникать на этапе сбора данных, а также рассмотрели, как алгоритмы могут непреднамеренно усиливать существующие социальные и исторические неравенства. Этические проблемы, связанные с предвзятостью, требуют систематического подхода, начиная с тщательного анализа данных, установления принципов работы и заканчивая постоянным мониторингом модели в реальной эксплуатации.

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026
Дизайн MAX Разработка TUNE-IT

Теперь вы хорошо знакомы с подготовительными шагами создания модели ИИ. Но на этом работа не заканчивается. Как может показаться, сами алгоритмы и модели ИИ — это просто набор математических формул, а математика, как известно, беспристрастна. Однако выбор модели и процесс её обучения также таят в себе ряд сложностей и этических нюансов.

В этом уроке мы рассмотрим, как правильно выбирать модель, как этап обучения может повлиять на результат, и как заложенные данные влияют на точность и справедливость предсказаний.

Представьте, что вы разрабатываете алгоритм, который должен определить сложность лечения пациента по анализу крови, полу и возрасту.

Данные поступают к вам в виде таблицы.

ID	Пол	Возраст	СОЭ	Lc	Симптомы	Трудноизлечимость пациентов
123	М	45	4	5	Сухость во рту	1
256	Ж	31	5	8	Болят колени	0
184	М	80	1	2	Ломота в коленных чашечках	1

Пример таблицы

Допустим, у вас есть некоторые экзогенные переменные, которые вы можете использовать как X_train, а именно:

- пол: мужчина/женщина;
- возраст;
- скорость оседания эритроцитов, мм/час;
- количество лейкоцитов на литр;
- симптомы, которые зафиксировал доктор в мед-карте.

> **Экзогенные переменные** — это переменные, значения которых задаются извне модели и не определяются другими переменными внутри неё.

Помните, как на уроках алгебры вы составляли уравнения вроде 2x = y? Работа с экзогенными переменными немного сложнее, но принцип тот же. Давайте разберёмся на конкретном примере.

Алгоритм, использующий такие параметры, как анализ крови, пол и возраст пациента, должен определить, является ли пациент трудноизлечимым. Переменная «y» будет иметь два возможных значения: 1 — пациент трудноизлечим, 0 — пациент не является трудноизлечимым. От этого зависит, какое лекарство доктор назначит своему пациенту.

Подходов к решению этой задачи множество. Расскажем о некоторых из них.

Мультиномиальная логистическая регрессия

Мультиномиальная логистическая регрессия — это один из самых простых и распространённых методов для работы с несколькими взаимосвязанными переменными, которые не являются бинарными. Этот метод позволяет вычислить вероятность принадлежности объекта к одной из нескольких категорий.

> ***Мультиномиальная логистическая регрессия*** — это статистический метод, который используется для предсказания вероятности того, что наблюдение принадлежит к одной из нескольких категорий исхода. Этот метод расширяет логистическую регрессию для работы с более чем двумя исходами.

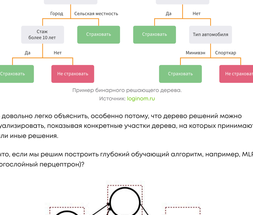

Линейная регрессия (слева) и логистическая регрессия (справа).
Источник: 3dnews.ru

Так как в датасете несколько экзогенных переменных, нам нужно будет построить функцию y,

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots\ldots + \beta_n X_n$$

А потом через формулу P(y) посчитать вероятность того, что пациент является трудноизлечимым.

$$p = \frac{1}{1+e^{-y}}$$

Объяснить заказчику механику распределения пациентов по группам несложно. Сначала мы определяем силу влияния экзогенных переменных (иксов) на переменную «y». Потом преобразуем «y» в вероятность, по которой и решаем, является пациент трудноизлечимым или нет.

Деревья решений

Деревья решений — это один из популярных методов машинного обучения. Конечно, перекладывать решения на деревья мы не будем. Деревья решений — это семейство моделей, которые позволяют восстанавливать нелинейные зависимости произвольной сложности. Нас будет интересовать один конкретный вид — бинарное решающее дерево.

> На данном этапе необходимым и достаточным будет понимание бинарного решающего дерева — как схемы, в которой из любой ее внутренней вершины выходит ровно два ребра.

Чтобы лучше разобраться, приведем в пример такую иллюстрацию.

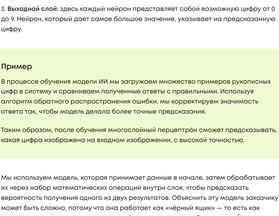

Пример бинарного решающего дерева.
Источник: loginom.ru

Это довольно легко объяснить, особенно потому, что дерево решений можно визуализировать, показывая конкретные участки дерева, на которых принимаются те или иные решения.

Но что, если мы решим построить глубокий обучающий алгоритм, например, MLP (многослойный перцептрон)?

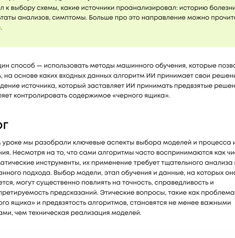

Многослойный перцептрон.
Источник: radioprog.ru

> **Многослойный перцептрон** — это тип искусственной нейронной сети, которая состоит как минимум из трех слоев: входного, скрытого и выходного. На выходах скрытого и выходного слоев используются нелинейные функции. При обучении этой сети применяется информация учителя, для коррекции ошибок используется алгоритм обратного распространения ошибки.

Давайте представим, что у нас есть многослойный перцептрон, который нужно научить распознавать рукописные цифры.

1. **Входной слой:** мы загружаем изображение рукописной цифры размером 28x28 пикселей в систему. Каждый пиксель является входным нейроном.

2. **Скрытый слой:** на этом уровне нейроны обрабатывают информацию из входного слоя. Они выявляют особенности и формы в цифре, такие как изгибы и углы.

3. **Выходной слой:** здесь каждый нейрон представляет собой возможную цифру от 0 до 9. Нейрон, который дает самое большое значение, указывает на предсказанную цифру.

Пример

В процессе обучения модели ИИ мы загружаем множество примеров рукописных цифр в систему и сравниваем полученные ответы с правильными. Используя алгоритм обратного распространения ошибки, мы корректируем значимость ответа так, чтобы модель делала более точные предсказания.

Таким образом, после обучения многослойный перцептрон сможет предсказывать, какая цифра изображена на входном изображении, с высокой точностью.

Мы используем модель, которая принимает данные в начале, затем обрабатывает их через набор математических операций внутри слоя, чтобы предсказать вероятность получения одного из двух результатов. Объяснить эту модель заказчику может быть сложно, потому что она работает как «чёрный ящик» — то есть как некоторая система, внутренние устройство и механизм работы которой слишком сложен, чтобы объяснить простыми словами.

Проблема чёрного ящика с ИИ вызывает этические вопросы. Если мы не можем понять, как алгоритм ИИ принимает решения, как мы можем убедиться, что его решения справедливы? Например, если ИИ используется для найма, как мы можем быть уверены, что он не *дискриминирует* людей? Чтобы решить эту проблему, исследователи стараются сделать алгоритмы ИИ более понятными. Один из подходов — это создание «объяснимого ИИ» (XAI)

Хотя правильнее было бы выразиться «объясняющего».

Например, ИИ рекомендует схему лечения, а ниже пишет объяснение, как он пришел к выбору схемы, какие источники проанализировал: историю болезни, результаты анализов, симптомы. Больше про это направление можно прочитать в статье.

Еще один способ — использовать методы машинного обучения, которые позволяют понять, на основе каких входных данных алгоритм ИИ принимает свои решения. Нахождение источника, который заставляет ИИ принимать предвзятые решения, позволяет контролировать содержимое «черного ящика».

Итог

В этом уроке мы разобрали ключевые аспекты выбора моделей и процесса их обучения. Несмотря на то, что сами алгоритмы часто воспринимаются как чисто математические инструменты, их применение требует тщательного анализа и осознанного подхода. Выбор модели, этап обучения и данные, на которых она обучается, могут существенно повлиять на точность, справедливость и интерпретируемость предсказаний. Этические вопросы, такие как проблема «черного ящика» и предвзятость алгоритмов, становятся не менее важными задачами, чем техническая реализация моделей.

5/6 Итоги

текущий урок

Модуль подошёл к концу – самое время вспомнить и закрепить всё самое важное из него.

Чтобы материал лучше усвоился, предлагаем вам прочитать кейс, в котором последовательно изложены все основные этапы создания модели ИИ.

Первый этап – сбор данных

Команда дата-сайентистов собирает данные пациентов больницы, чтобы создать модель ИИ, которая будет предсказывать вероятность тяжелой формы ковида для каждого пациента, поступившего с первыми симптомами и положительным тестом. Это нужно для того, чтобы вовремя госпитализировать пациента и предотвратить осложнения.

Однако исследование противоречит закону и конфиденциальности личной информации. Возникает этическая дилемма: соблюдать закон или отказаться от исследования, которое могло бы спасти жизни людей. Было принято следующее решение: команда находит способ хранить данные безопасно, а также просит информированное согласие от пациентов на использование их данных.

Второй этап – выбор модели машинного обучения

Команда получила данные и провела исследование. Однако она обнаруживает, что выбранная модель, несмотря на статистическую объективность, приводит к дискриминации — по статистике чаще осложнения получают пациенты 50+, поэтому молодые люди могут не получить место в больнице, хотя находятся в зоне риска.

И снова этическая проблема — нужно понять, как добиться не только объективного, но и справедливого моделирования. Команда проводит дополнительные исследования для сокращения предвзятости и обеспечения справедливого прогнозирования риска для всех пациентов.

Третий этап – тестирование ML-продукта

Команда проводит тестирование ML-продукта на большом датасете из медицинских карточек пациентов. В процессе тестирования исследователи обнаруживают, что данные, на которых тестировалась модель, были предоставлены только из общего отделения — то есть по пациентам, которые лечились на дому.

Команда запрашивает данные из отделения реанимации, снова проводит тестирование, чтобы добиться максимально возможной точности предсказания ML-продукта для всех групп пациентов.

Четвертый этап – масштабирование продукта

Команда готовит ML-продукт к масштабированию и внедрению в реальную практику. И несмотря на то, что большая часть этических проблем была решена на первых трех этапах, на четвертом также обнаруживаются препятствия.

Бесконтрольное масштабирование может привести к тому, что доступ к продукту получат клиники, у которых нет официальной медицинской лицензии. Это подвергнет пациентов неконтролируемому риску и может нанести ущерб здоровью из-за потенциально низкого качества медицинской помощи. Широкое распространение продукта может привести к его использованию в неподходящих условиях, что противоречит целям обеспечения здоровья и безопасности пациентов.

Команда решает внедрять продукт только в тех клиниках, которые обладают необходимой лицензией и сертификацией для предоставления качественной медицинской помощи, таким образом обеспечивая этичное использование продукта и его надежность для конечных пользователей.

Список литературы:

- 1.17. Neural network models (supervised) // scikit-learn.org [Электронный ресурс]. URL: https://scikit-learn.org/stable/modules/neural_networks_supervised.html.
- 8 Machine Learning Models Explained in 20 Minutes // www.datacamp.com [Электронный ресурс]. URL: https://www.datacamp.com/blog/machine-learning-models-explained.
- Case Study PDFs // aiethics.princeton.edu [Электронный ресурс]. URL: https://aiethics.princeton.edu/case-studies/case-study-pdfs/.
- Classification in Machine Learning: An Introduction // www.datacamp.com [Электронный ресурс]. URL: https://www.datacamp.com/blog/classification-machine-learning.
- Decision Tree Classification in Python Tutorial // www.datacamp.com [Электронный ресурс]. URL: https://www.datacamp.com/tutorial/decision-tree-classification-python.
- Multilayer Perceptron Explained with a Real-Life Example and Python Code: Sentiment Analysis // towardsdatascience.com [Электронный ресурс]. URL: https://towardsdatascience.com/multilayer-perceptron-explained-with-a-real-life-example-and-python-code-sentiment-analysis-cb408ee93141.

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026

Дизайн MAX Разработка TUNE-IT

1/6 Введение

текущий урок

«Технология сама по себе не является ни хорошей, ни плохой — но и нейтральной она тоже не является»

Мелвин Кранцберг, историк технологий

В прошлом модуле мы рассказали о принципах этичной разработки ИИ. И вот, когда модель готова и её можно использовать, встаёт вопрос о границах её применения и ответственности за использование этой новой силы, которая способна сдвинуть с мёртвой точки горы информации, накопленной человечеством за тысячелетия.

В этом модуле вы глубже изучите этические аспекты использования ИИ, узнаете о видах ошибок, которые могут возникать при разработке и применении технологий, а также рассмотрите реальные кейсы для анализа.

По итогам изучения модуля вы сможете:

- Оценивать риски внедрения ИИ в чувствительных сферах с этической точки зрения.
- Классифицировать ошибки в принятии решений и предлагать способы их минимизации.
- Разрабатывать этические принципы и сценарии использования ИИ, способные снизить риски и усилить ответственность.

Попробуем превратить высказывание Черчилля в начале этого модуля в конкретный пример. мысленно переместиться в компанию Alphabet (материнскую компанию Google), проникнуться энтузиазмом разработчиков и идейных вдохновителей беспилотных автомобилей, а затем почитать новости и осознать последствия разработки.

Этот пример хорошо иллюстрирует, как быстро могут разбиться о реальность самые высокие цели и мечты, если не думать о последствиях заранее.

Светлые надежды на ИИ неслучайны — ведь «доброе, светлое, вечное» в него можно запрограммировать так, что ИИ неукоснительно будет следовать алгоритму. И действительно, ИИ не сядет пьяным за руль, как это может сделать человек. Но разве можно говорить о том, что доброе, светлое вечное раз и навсегда закреплено в правилах и кодексах? И можно ли сказать, что одно и то же правило в разных контекстах будет работать одинаково?

Предлагаем вам разобрать следующий пример.

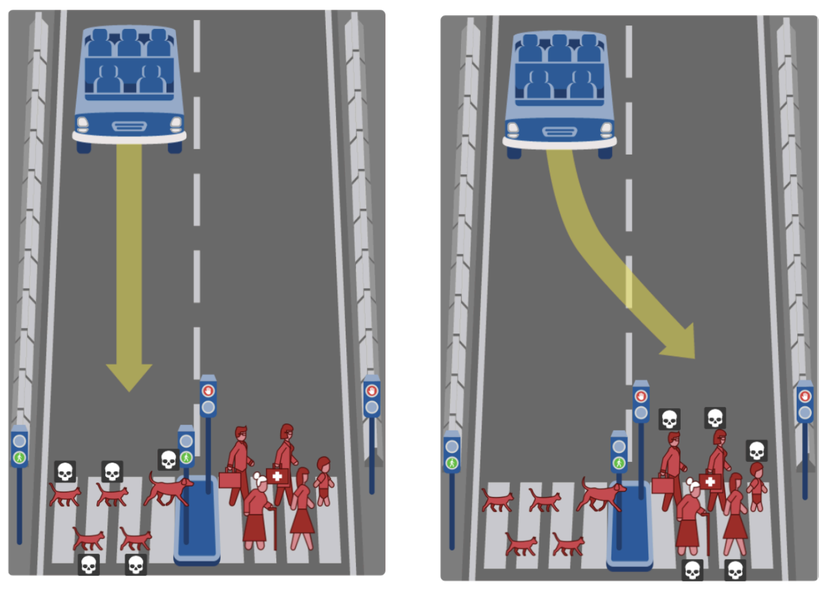

Источник: moralmachine.net

Что происходит на картинке: машина выходит из строя и не останавливается, когда для неё загорается красный свет. В это же время для пешеходов загорается зелёный, и они по ПДД имеют право перейти дорогу. Для таких случаев необходим аварийный сценарий. Но какой выбор нужно запрограммировать в ИИ при условии, что на обеих частях дороги есть пешеходы — справа животные, а слева — люди? Как решить, должен ли автомобиль проехать прямо и тогда сбить животных, или свернуть влево — на ту часть дороги, по которой идут люди? Выбор не из простых, не так ли?

Тогда приведём еще один пример:

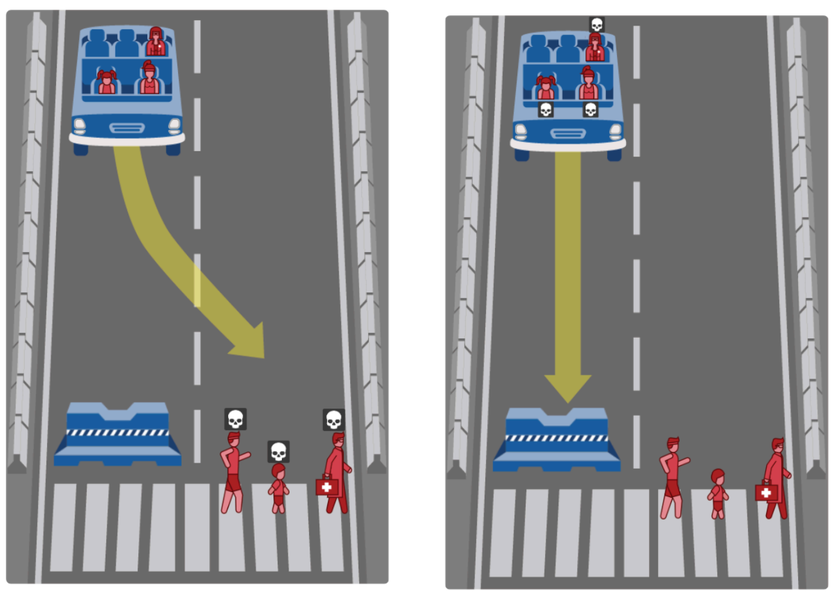

Источник: moralmachine.net

Допустим, рабочие поставили дорожный разделительный блок. Но ИИ, зашитый в машину, не обучен распознавать подобные объекты. Поэтому у него нет и протокола, как действовать в таких случаях. На кону жизнь людей — если машина свернет влево, пострадают пешеходы; если на всех скоростях влетит в разделитель — пассажиры.

Ответы на эти вопросы нужно найти до ввода ИИ-продукта в эксплуатацию.
Для этого исследователи проводят множество тестов в лабораторных условиях.

Ещё один пример. Представьте, что вы уже закончили курс и вас наняли в Лабораторию Сколково разрабатывать лекарство, способный полностью вылечивать людей от астмы. Но, как и положено любому лекарству, у него есть побочные эффекты: если его выписать пациенту, у которого нет астмы, лекарство негативно повлияет на работу печени.

Риск подобных ошибок пугает. Но больше тревожит неопределённость — неужели нужно будет изобретать и искать бесчисленное множество ситуаций, в которых что-то может пойти не так? Но нужно с чего-то начать.

Начнём с классификации ошибок.

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026

Дизайн MAX Разработка TUNE-IT

Первый класс — ошибки I и II рода. Это категории статистики, которые помогают оценить точность проверки гипотез. Они могут возникнуть, когда мы, например, делаем неверные выводы о популяции на основе выборочных данных. А теперь подробнее поговорим о каждом.

Ошибки типа I

Ошибки типа I возникают, когда мы отвергаем нулевую гипотезу , которая на самом деле верна.

> **Нулевая гипотеза** — стартовая точка любого исследования, когда учёные договариваются, что не признают связь между двумя наблюдаемыми событиями, феноменами до тех пор, пока не будет доказано обратное.

Например, вам необходимо установить связь между процентной ставкой по ипотеке и количеством заёмщиков, подписавших кредитный договор. Нулевой гипотезой в этом случае станет утверждение, что эти переменные не зависят друг от друга, пока на большом массиве данных не будет доказано обратное.

Другими словами, мы ошибочно полагаем, что существует значительный эффект или взаимосвязь, хотя их на самом деле нет. Эту ошибку часто обозначают как α (альфа) и представляют собой уровень значимости или вероятность совершения ошибки типа I.

Если вернуться к нашему примеру, где мы проверяем эффективность лекарства для лечения астмы, то нулевая гипотеза утверждает: препарат не лечит астму. Если исследователи ошибочно отвергают нулевую гипотезу, то есть допускают, что препарат эффективен, хотя на самом деле это не так, они совершают ошибку I рода. Это может привести к тому, что препарат попадёт в продажу без доказанной эффективности, что потенциально может нанести вред.

Ошибки типа II

Ошибки типа II возникают, когда мы не можем отвергнуть нулевую гипотезу, которая в действительности является ложной. В этом случае мы можем не заметить важной корреляции между параметрами в массиве данных. Вероятность совершения ошибки второго рода часто обозначается как β (бета).

Разовьём историю про медицинские препараты. Нулевой гипотезой при разработке лекарства станет предположение, что это лекарство не лечит астму. Но исследователи, например, могут неправильно сконструировать условия для эксперимента, в результате чего нулевую гипотезу не удастся отвергнуть — это будет означать, что лекарство неэффективно. В результате пациент не получит никакого лечения. Тогда мы имеем дело с ошибкой II рода.

Вероятность отклонения нулевой гипотезы, при условии, что альтернативная гипотеза верна, называют статистической мощностью проверки гипотезы. Чем она выше, тем ниже вероятность совершить ошибку второго типа. И наоборот — чем ниже статистическая мощность, тем выше вероятность не отвергнуть нулевую гипотезу, когда она на самом деле ложна, то есть совершить ошибку второго рода.

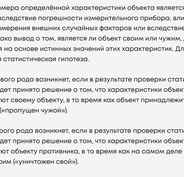

Основные параметры для определения мощности

Оба типа ошибок приводят к серьёзным последствиям.

А теперь предлагаем поразмышлять, какая ситуация опаснее: если мы назначим лечение здоровому человеку (ошибка I типа), или — не назначим лечение больному (ошибка II типа)?

Решение этой дилеммы лежит не только в плоскости этики. Если мы имеем дело с бизнесом, приходится считаться с бюджетом — то есть компания, заказавшая разработку, должна получить с продукта доход. Бизнес смотрит на статистику иначе: даже если процент ошибок алгоритма высок, но все-таки меньше половины, компании всё равно вводят продукт в эксплуатацию, чтобы получить первый доход с минимально жизнеспособного продукта и средства на продолжение разработки.

Задание 1

А теперь предлагаем вам потренироваться на простой задаче, чтобы убедиться, что теория усвоилась.

Условия задачи: военные наблюдают некоторый объект. Он может быть или своим, или объектом противника. Система обнаружения по результатам нескольких замеров определённых характеристик относит объект к одному из классов:

- Нулевая гипотеза (H0): объект свой.
- Альтернативная гипотеза(H1): объект противника.

Как бы вы описали ошибки первого и второго типа, которые могли быть допущены?

Проверить себя

Результат замера определённой характеристики объекта является случайной величиной, вследствие погрешности измерительного прибора, влияния на результат измерения внешних случайных факторов или вследствие иных причин. Однако вывод о том, является ли объект своим или чужим, должен проводиться на основе истинных значений этих характеристик. Для этой цели выдвигается статистическая гипотеза.

Ошибка первого рода возникнет, если в результате проверки статистического критерия будет принято решение о том, что характеристики объекта соответствуют своему объекту, в то время как объект принадлежит объектом противнику («пропущен чужой»).

Ошибка второго рода возникнет, если в результате проверки статистического критерия будет принято решение о том, что характеристики объекта соответствуют объекту противника, в то время как на самом деле объект является своим («уничтожен свой»).

Существует также перечень чувствительных сфер, использование ИИ в которых потенциально неэтично (до тех пор, пока не будет доказано обратное). Среди них:

Конфиденциальность и наблюдение

Наверное, вы сами с неохотой делитесь, например, своими биометрическими данными с банками. Вопреки тому, что данные собираются не для контроля, а для защиты конфиденциальности, многие беспокоятся за чрезмерное вторжение больших корпораций в частную жизнь. Опасность представляет не столько организация, собирающая данные, сколько высокий риск несанкционированного доступа к личной информации в результате успешной хакерской атаки. Это может привести к использованию данных в недобрых целях — для манипуляции, слежки и т.д. И также противоречит закону — ведь право на частную жизнь и автономию закреплено в Конституции.

Предвзятость в принятии решений

Алгоритмы ИИ обучаются на существующих данных, которые в точности отражают многогранную действительность, в том числе с её дискриминирующими установками. Если никак не перерабатывать сырые данные, алгоритмы ИИ могут увековечить и даже укрепить социальные предрассудки. В результате — несправедливые решения в области найма на работу, кредитования, уголовного правосудия и т.п. Прошлое человечества полно тёмных страниц, но это не значит, что их обязательно брать с собой в будущее.

Производство оружия

Со времён появления атомной бомбы, человечество впервые задумалось об ответственности всех причастных за создание и применение того, что было изобретено. Тот, кто владеет оружием массового поражения, получает возможность решать судьбы не только отдельных людей, но и целых народов. Опасно передавать управление этим механизмом алгоритмам. В любом случае контролирующей инстанцией всегда должен оставаться человек.

Сокращение рабочих мест и социо-экономическое расслоение

Одним из громких инфоповодов 2023 года стали нейросети, которые пошатнули уверенность людей в том, что их профессии всегда будут востребованы. Действительно, что бы ни говорили, дальнейшее бесконтрольное развитие ИИ может привести к сокращению рабочих мест. В первую очередь это касается низкоквалифицированного труда, потому что его легче всего автоматизировать.

Манипулирование и дезинформация

Технологии на основе искусственного интеллекта могут использоваться для дезинформирования людей и манипулирования общественным мнением. Например, технологии дипфейков может создавать убедительные фейковые видеоролики с участием первых лиц, подрывая доверие к визуальным документам, подтверждающим факт события. Как итог — распространение фейковых новостей, пропаганды и дезинформации, за которой всё сложнее обнаружить правду.

Этическое принятие решений и ответственность

Концепт ответственности полностью держится на понимании свободы выбора. Но если выбор для ИИ программируется изначально, то непонятно, кого привлекать в ответственности за его действия — разработчиков, дата-сайентистов, кого-то ещё? Использование ИИ в процессе принятия важных решений в чувствительных сферах: медицине, социальной политике — ставит общество перед необходимостью пересмотреть концепции ответственности и выбора и, как следствие, менять сложившийся судебный процесс, или ограничить применение ИИ.

Манипулирование эмоциями

Манипулирование эмоциями — поощрение нездоровых привычек. Алгоритмы ИИ могут использоваться для обнаружения уязвимостей в психике человека. Например, социальные сети внедряют ИИ с целью создания точных рекомендаций под запрос пользователя. Но что, если человек борется с зависимостью от курения? Будет ли алгоритм предлагать пользователю книги о борьбе с пагубной привычкой или же предложит рекламу электронных сигарет?

Пока искусственный интеллект не развился в неконтролируемую силу, крайне важно осознать угрозы, которые он представляет. Система сдержек, жёстких правил использования, постоянные дискуссии на эти темы необходимы, чтобы минимизировать вред от использования ИИ. Во главу угла необходимо поставить такие ценности, как справедливость, прозрачность, подотчётность ИИ и право человека на частную жизнь.

Общество начало осмыслять эти проблемы сравнительно недавно. Самый чувствительный вопрос на повестке сегодня — использование конфиденциальных данных для обучения модели ИИ с целью повышения производительности. Конфиденциальными данными принято считать личные записи, финансовые операции, данные о состоянии здоровья и многое другое. Разумеется, обучая модель ИИ на этих данных, можно добиться очень высокой точности прогнозов и прогресса во всех областях применения модели.

Чтобы собирать данные, необходимо:

- обеспечить, чтобы личные данные собирались только с осознанного согласия;
- стремиться к сбору анонимных данных, минимизируя возможность их идентификации;
- ограничить использование данных конкретной целью: например, данные для алгоритмов двигательных приложений не должны использоваться банковскими аналитиками;
- заранее разработать меры на случай утечки данных в руки хакеров;
- ввести в законодательство строгие санкции за утечку персональных данных.

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026
Дизайн MAX Разработка TUNE-IT

3/6 Меры предосторожности по защите персональных данных от утечек

текущий урок

А теперь расскажем, какие на данный момент существуют меры предосторожности по защите персональных данных от утечек. Их можно разделить на четыре группы: безопасность сбора, хранения, передачи и использования.

Методы безопасного сбора данных

Анонимизация. Можно собирать данные анонимно — удалить прямые идентификаторы, такие как имена, адреса и номера документов, а лучше изначально не собирать их. Даже если данные попадут в плохие руки, ни один человек не попадёт под прямую угрозу. Все как в известном фильме — нет имени, нет и человека.

Принцип объединения данных. Суть его проста, как и посыл в книге Ортеги-и-Гассета «Восстание масс»: если данные обобщать и объединять в группы, на основе которых формулировать гипотезы о глобальных тенденциях, каждая конкретная личность затеряется в массе и станет лишь тысячной долей процента в статистике.

Методы безопасного хранения данных

Псевдонимизация. В истории есть множество примеров использования этого приема. Наверняка, вы слышали, что учёные до сих пор сомневаются в авторстве пьес, которые закреплены в анналах истории за именем Шекспира. Многие шекспироведы считают, что Эдуард де Вер, граф Оксфордский писал их под псевдонимом, потому что такого мастерства работы со словом не мог добиться выходец из семьи ремесленников. В цифровом пространстве псевдонимизация предполагает умышленную замену имен или другими именами, или же уникальными кодами. При этом доступ к исходной информации могут получить только авторизованные лица с возможностью повторной идентификации данных посредством отдельного ключа.

Маскирование данных. Проще говоря, это замена исходных данных фиктивными данными или произвольными символами. На самом деле это очень древний способ обеспечения конфиденциальности. Думаем, первое, что вы сможете вспомнить на эту тему — противостояние «Энигмы» и «Машины Тьюринга» (если нет, рекомендуем вам прочитать увлекательную статью). В работе с большими цифровыми данными используют похожие по принципу методы, такие как рандомизация, шифрование, токенизация. При этом важно, что целостность и полезность данных сохраняется.

Дифференциальная конфиденциальность. Метод, суть которого проще объяснить высказыванием «ложь легче всего спрятать между правдами». Избыточность данных, часть из которых фальшивая, тоже хороший способ увести из под угрозы конкретного человека. Ведь только 100% совпадение важных данных указывает на искомую личность.

Минимизация данных. Обратный метод — «меньше знаешь, крепче спишь». Если информация имеет малое статистическое значение, можно её не собирать. Вряд ли где-то кроме развлекательных журналов будут публиковать статьи вроде «Мужчины с этими именами — лучшие мужья». Такую статистику, к счастью, никто не ведёт.

Метод безопасной передачи данных

Безопасные протоколы обмена данными. То есть внедрение безопасных протоколов, таких как шифрование данных, безопасные соединения и контроль доступа при передаче данных. Эти меры гарантируют, что только авторизованные лица смогут получить доступ к общим данным и использовать их. Самый известный протокол — HTTPS (HyperText Transfer Protocol Secure).

Метод безопасного использования информации

Регулярные проверки и мониторинг. Это профилактический контроль за практиками использования данных. Есть специальные агентства форензик-специалистов, которые по заказу проводят анализ защищенности инфраструктур заказчика. Они действуют как белые хакеры — ищут уязвимости и выдают рекомендации по их устранению. Проведение регулярных проверок и мониторинг практики использования данных может помочь выявить любые потенциальные риски или утечки обезличенных данных. Это позволяет оперативно устранять любые проблемы и обеспечивает постоянное соблюдение правил конфиденциальности.

А теперь вернёмся к примеру про эффективность лекарства от астмы. Представим, что датасет нам передали врачи местной больницы. Посмотрите на два этих датасета и скажите, какой из них можно передать в разработку?

ID	Год рождения	Пол	Дата первого приема у врача	Степень реакции на пыль	Астма
123	26.02.93	0	01.05.23	0	1
456	15.05.90	1	01.07.23	3	0
789	11.12.85	0	05.08.23	2	1
234	08.03.79	1	11.12.22	1	0

ФИО	Год рождения	Пол	Дата первого приема у врача	Почта	Астма
Иванов Иван Иванович	26.02.93	Ж	01.05.23	iii@mail.ru	1
Питт Брад Иванович	15.05.90	М	01.07.23	bpi@mail.ru	0
Трамп Дональд Васильевич	11.12.85	Ж	05.08.23	donald_mago@mail.ru	1
Коваленко Екатерина Сергеевна	08.03.79	М	11.12.22	kov_ek@mail.ru	0

Как вы уже догадались, верный ответ — первый. Во второй же таблице:

- ФИО вместо ID.
- Личные почты пациентов. Кроме того, что это конфиденциальная информация, никакого отношения к астме эти данные не имеют.
- Пол тоже рекомендуется кодировать, например М—1, Ж—0.
- Год рождения можно выслать отдельной табличкой.

Это задание для самостоятельной работы, за него не предусмотрены баллы. Однако оно поможет вам закрепить новый материал.

Задание 1

0 points possible (ungraded)

Какие из данных представленных ниже считаются конфиденциальными:

- [x] ФИО
- [ ] Город проживания
- [ ] Музыкальные предпочтения
- [ ] Возраст
- [ ] Доход
- [ ] Пол
- [ ] Имя домашнего животного

Show answer

Отправить

Верных

Теперь, когда данные собраны этично, пора разобраться с правовой стороной вопроса — разберём, что такое соглашение о неразглашении, и как ваши личные данные охраняются законом.

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026.

Дизайн MAX Разработка TUNE-IT

4/6 Соглашение о неразглашении (NDA)

текущий урок

Ни одна операция по сбору данных не обходится без составления NDA.

> **Соглашение о неразглашении** (NDA) — документ, в котором прописываются условия сохранения конфиденциальности представленной информации. NDA может подписываться как частными лицами, так и организацией в целом.

Важно знать, как составлять этот документ, а не надеяться на юристов. Их зона ответственности — право и закон, а ваша — предусмотреть все возможные нюансы вашей работы. Ниже — несколько общих рекомендаций о том, какая информация должна быть в договоре:

Информация	Что именно нужно указать	Пример
Кто подписывает соглашение?	Имена и физические адреса всех сторон соглашения. Все люди имеют место прописки, а организации — юридический адрес.	Иванов Иван Иванович, серия и номер паспорта, адрес регистрации — вы наверняка уже заполняли подобные соглашения
Что будет считаться конфиденциальной информацией, а что нет?	Определение не должно быть размытым. Важно указать конкретные типы информации, которые подлежат защите.	Медицинский стартап собирает данные для разработки лекарства от ковида. Часть информации, такой как количество пациентов ковидного госпиталя, находится в свободном доступе — поэтому она не будет считаться конфиденциальной.
Какова цель соглашения?	Цель — конкретное исследование, проблема, задача, под которые собирается информация.	Тот же медицинский стартап собирает анализы крови пациентов с астмой, чтобы выявить закономерность между показателями — содержанием глюкозы в крови, и др.
Какие у стороны обязательства и ограничения?	Подробно объяснить, как информация должна обрабатываться, храниться и защищаться, включая способы предотвращения утечек.	Определить, например, провайдера облачного хранилища, которое будет использоваться.
На какой срок заключается соглашение?	Это не обязательно будет дата. Часто в качестве срока указывают срок выполнения конкретных условий.	Это может быть дата — 23.09.2025, а может условие — данными можно пользоваться до тех пор, пока не будет завершена перепись населения и оглашены ее результаты.
Какие будут санкции за нарушение условий соглашения?	Финансовые штрафы, судебные запреты или др.	Утечка данных большой компании всегда ярко освещается в СМИ. Наверняка все помнят, как это произошло, например, с данными клиентов Яндекс. Еды. Обычно, и конкретно в этом случае, компании штрафуют. Подробнее об этом кейсе можно прочитать по ссылке.
В рамках какого права будут решаться юридические вопросы?	Область права, которая будет регулировать отношения между сторонами.	КоАП, УК РФ, Трудовой кодекс и т.п. Например, по вине сотрудника в компании произошла утечка конфиденциальной информации. Отношения между сторонами будет регулироваться Трудовым кодексом.

Включите пункт о том, что NDA — полное соглашение между сторонами, аннулирующее прежние устные или письменные договоренности. А ещё установите, будет ли возможность вносить правки в соглашение и порядок их внесения. Чтобы любые изменения всегда фиксировались в письменной форме.

И, разумеется, не забудьте проконсультироваться с юристами. Мы рассказали только о вопросах, над которыми стоит подумать до составления договора.

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026

Дизайн MAX Разработка TUNE-IT

5/6 Итоги

текущий урок

Итак, в этом модуле мы рассказали, почему важно думать об этической чистоте продукта до ввода его в эксплуатацию.

ИИ — не что-то принципиально новое, ведь человечество давно работает с методами автоматизации процессов. Но с массивами данных в таком масштабе работать ещё не приходилось. С этим связано большое количество проблем, часть из которых мы осветили в данной теме.

Для того, чтобы этично использовать искусственный интеллект в работе с информацией, нужно запомнить несколько моментов:

1. Есть всего два рода ошибок, смысл которых, состоит в том, что некоторые выводы ложно отвергают правду, а другие ложно не отвергают ложь.
2. На данный момент существует не так много способов безопасного обращения с данными. Их можно разделить на четыре группы: безопасность сбора, хранения, передачи и использования данных. Важно не собирать лишние данные, шифровать всю конфиденциальную информацию, передавать данные только с помощью безопасных протоколов. Главная задача — в результате утечки данных не допустить, чтобы злоумышленники могли причинить вред конкретному человеку.
3. Все аспекты, которые касаются сбора информации, постепенно осмысляются правовой системой. Слепых зон, которые государство не контролирует, становится все меньше. Составление NDA — один из способов урегулирования отношений сторон. Соглашение о неразглашении имеет юридическую силу, а значит легитимизирует и судебные разбирательства.

Список литературы:

- Хакер, спасший тридцать миллионов человеческих жизней. [Электронный ресурс]. – Режим доступа: https://culture.pl/ru/article/haker-spasshiy-tridcat-millionov-chelovecheskih-zhizney.
- Яндекс.Еда, утечки и правосудие. Предварительные итоги. [Электронный ресурс] // Хабр. – 2024. – Режим доступа: https://habr.com/ru/companies/digitalrightscenter/articles/763096/.

Предыдущий урок Следующий урок

Skillfactory — онлайн-школа IT-профессий. Онлайн-курсы по Data Science, аналитике, программированию и менеджменту © 2026

Дизайн MAX Разработка TUNE-IT