

Итоговый проект по дисциплине «Этика искусственного интеллекта»

Тема проекта: аудит и этическое сопровождение внедрения ИИ-системы для найма персонала (моделирование конфликта интересов).

Кейс

Вы — команда специалистов (или отдельный специалист) компании «ТехноРекрут». Ваша компания разработала и планирует внедрить у клиента (крупный ритейлер «МаркетПлюс») новую AI-систему для отбора резюме «Кадробот 3000».

Система уже обучена на исторических данных компании-клиента за последние пять лет и показывает высокую точность предсказания успешности кандидатов (метрика ROC-AUC = 0.85 на тестовых данных).

За два дня до финальной презентации и подписания контракта с компанией «МаркетПлюс» на сумму 15 млн руб. ваш аналитик обнаруживает проблему. Модель систематически занижает рейтинг кандидатов старше 45 лет и отдаёт предпочтение кандидатам, чьи резюме содержат маркеры, косвенно указывающие на принадлежность к большинству: определённые хобби, названия вузов, формулировки. Формально возраст не является признаком, но модель нашла корреляты (proxy variables), например «год окончания вуза» или «использование устаревшей лексики».

Клиент требует предоставить не только модель, но и «Этический паспорт решения» и «Политику ответственного использования», без которых контракт не будет подписан. Время на переобучение модели и сбор новых, более сбалансированных данных критически мало — две недели.

Цель проекта

Разработать комплект документов и стратегию действий, которые позволят:

- выявить и проанализировать этические риски системы «Кадробот 3000»;
- предложить реалистичные меры по их смягчению в условиях жёстких временных и коммерческих ограничений;
- аргументированно представить свою позицию трём группам заинтересованных сторон с противоположными интересами.

Роли и заинтересованные стороны

Вы (или команда) выступаете в роли руководителя группы этики и анализа рисков ИИ в компании «ТехноРекрут».

Подготовьте позицию и аргументы для встречи со следующими сторонами:

Алексей (генеральный директор «ТехноРекрута»): «Мы вложили 10 млн в разработку. Если не подпишем контракт или задержим сдачу, то потеряем прибыль и репутацию. Сделайте так, чтобы они подписали. Найдите компромисс!»

Ирина (HR-директор «МаркетПлюса»): «Нам нужны лучшие сотрудники. Но нам не нужен скандал, как в Amazon в 2018-м. Если модель дискриминирует людей 45+, я не подпишу акт. Нам важны разнообразие команды и комфортная среда для сотрудников любого возраста. Или вы убираете дискриминацию, или мы не работаем».

Пётр (юрист «МаркетПлюса»): «Предоставьте полную документацию по обработке данных и обоснование модели. Любой иск от соискателя, не прошедшего отбор, ляжет на нас. Две гарантии, что мы не нарушаем законодательство о персональных данных и не дискриминируем по возрасту (ст. 3 ТК РФ)?»

Структура проекта

Проект состоит из трёх частей, соответствующих разным типам деятельности: аналитической, проектной и коммуникативной.

Этап 1. Аналитический аудит и выявление рисков

Вам предоставили **синтетические данные** со следующими колонками:

- age — возраст кандидата;
- gender — пол;
- education — образование (1 — среднее, 2 — среднее специальное, 3 — высшее, 4 — учёная степень);
- experience — опыт работы (лет);
- graduation_year — год окончания вуза;
- outdated_vocab — наличие устаревшей лексики в резюме (1 — есть, 0 — нет);
- youth_hobby — наличие «молодёжных» хобби (1 — есть, 0 — нет);
- model_score — оценка модели (вероятность от 0 до 1);
- model_decision — решение модели (1 — пригласить, 0 — отказать);
- true_success — объективная успешность кандидата (1 — успешен, 0 — не успешен). Это «идеальная реальность», не зависящая от возраста;
- historical_success — историческое решение компании (1 — кандидат был нанят в прошлом, 0 — не нанят).

Именно на этих данных обучалась модель, и именно в них заложена возрастная предвзятость.

На основе данных выполните:

- Технический анализ.** Определите, как именно модель дискриминирует. Какие признаки стали прокси-переменными для возраста? Почему модель решила, что они важны? При выполнении анализа вы можете использовать код, но это обязательно. Главное — показать понимание того, какие расчёты нужны и какие выводы из них следуют.
- Этический анализ.** Оцените последствия. Кто именно пострадает от использования такой модели? В чём выражается несправедливость (распределительная, процедурная)? При оценке последствий подумайте не только о самих кандидатах, но и о компании: какие репутационные и бизнес-риски создаёт дискриминационная модель?
- Правовой анализ.** Соотнесите ситуацию с нормами российского и международного права (GDPR, 152-ФЗ). Какие статьи и законы потенциально нарушаются? Достаточно указать конкретные статьи (например, ст. 3 ТК РФ, 152-ФЗ) и кратко объяснить, как они соотносятся с ситуацией. Детальная юридическая экспертиза не требуется.

Этап 2. Разработка этического паспорта и политики использования

Подготовьте два ключевых документа от лица разработчика:

- Этический паспорт ИИ-решения (заполняйте на основе анализа из этапа 1, все выводы подтверждайте данными):
 - Назначение и предполагаемые границы использования модели.
 - Выявленные ограничения и известные биасы (со ссылкой на этап 1).
 - Метрики справедливости, рассчитанные для модели (например, демографический паритет, равные возможности). Объясните, почему выбраны именно эти метрики и что они показывают в данном контексте.
 - Рекомендации по регулярному пересмотру и аудиту модели.

Уточнение по метрикам. При выборе метрик опирайтесь на четыре подхода к справедливости, изученные в курсе: демографический паритет, равные возможности, равная точность, справедливость через неосведомлённость. Объясните, почему выбранный подход наиболее уместен именно для задачи найма.

- Политика ответственного использования для клиента («МаркетПлюс»):
 - Инструкция: как именно HR-специалист должен использовать рекомендации «Кадробота» (как вспомогательный инструмент, а не как окончательный вердикт).
 - Процедура эскалации и апелляции для кандидатов («Право на объяснение»).
 - Требования к составу команды, работающей с системой (обязательное включение людей, способных оспорить решение модели).

Уточнение по оформлению. Политика должна содержать не менее пяти конкретных пунктов-инструкций для сотрудников клиента.

Этап 3. Подготовка к переговорам и аргументация

Подготовьте презентацию (5–7 слайдов), в которой одновременно:

- Успокойте Алексея (своего директора). Покажите, что контракт будет подписан, а риски — под контролем. Предложите план действий, который не требует полной переделки модели, но снимает основные этические претензии.
- Убедите Ирину (HR-директора клиента). Докажите, что вы ответственно подходите к вопросу. Предъявите «Этический паспорт» и «Политику» как доказательство вашей зрелости. Объясните, почему полное отсутствие bias технически недостижимо сейчас, но предложите компромиссные меры защиты (например, «человек в контуре», специальные квоты на интервью для кандидатов 45+).
- Предоставьте гарантии Петру (юристу). Объясните, какие юридические механизмы (лицензионный договор, ограничение ответственности, процедуры обработки персональных данных) защитят его компанию от исков.

Требования к оформлению и содержанию

- Объём аналитической записки (этапы 1 и 2): не более десяти страниц (без приложений).
- Презентация (этап 3): 5–7 слайдов.
- Обязательное использование понятий: прокси-переменные, справедливость (разные виды), риск-ориентированный подход, человек в контуре, право на объяснение, дискриминация.
- Реалистичность: все предложения выполнимы в описанных условиях (две недели, бюджет, существующая модель).

Критерии оценивания (максимум 50 баллов)

- Глубина анализа проблемы (10 баллов):
 - Верно идентифицированы источники предвзятости (данные, модель, постановка задачи).
 - Проведён анализ последствий для разных групп заинтересованных сторон.
- Качество проработки этических рисков (15 баллов):
 - «Этический паспорт» полный и корректный.
 - Предложены и обоснованы метрики справедливости.
 - Учтены различные философские подходы к справедливости: утилитаризм, либертарианство, теория справедливости Ролза.
- Реалистичность и системность предложенных решений (10 баллов):
 - Предложенные меры сочетают технические, процессуальные и организационные изменения.
 - Учтены ограничения: время, деньги, интересы бизнеса.
 - «Политика использования» решает проблему на уровне взаимодействия человека и модели.
- Правовая и социальная грамотность (5 баллов):
 - Корректно применяются юридические термины и нормы.
 - Учитывается социальный контекст.
- Качество аргументации и презентации (10 баллов):
 - Учитываются интересы всех трёх сторон.
 - Защита убедительна, продемонстрирована готовность к компромиссам и умение их обосновать.

Задание, оцениваемое ментором

Этика искусственного интеллекта. Итоговый проект (PJ)

Домашнее задание проверит ментор и поставит оценку. Если возникнут сложности, обращайтесь в канал модуля. Желаем успехов! :)

Сдать домашнее задание

Сдать дз

< Предыдущий урок

Следующий урок >