

От IC50 к pIC50: Оптимальные стратегии моделирования и интерпретации биологической активности соединений

Биологический смысл и математические основы IC50, CC50 и SI

В фармацевтических исследованиях и хемоинформатике ключевыми метриками для количественной оценки эффективности и безопасности потенциальных лекарственных соединений являются показатели IC50, CC50 и SI. Понимание их фундаментального биологического смысла и математических свойств является первым и необходимым шагом для корректной постановки задачи машинного обучения и интерпретации полученных результатов. Эти метрики служат количественными индикаторами взаимодействия молекулы препарата с биологической системой, позволяя ранжировать соединения по их терапевтическому потенциалу.

Показатель IC50, или полумаксимальная ингибирующая концентрация, является одним из самых распространенных и информативных показателей эффективности препарата [51 126](#). Он определяется как концентрация ингибитора, необходимая для подавления половины (50%) максимальной биологической активности в заданной системе [20 33](#). Эта активность может быть выражена по-разному: от ингибирования конкретного фермента до подавления репликации вируса или клеточной пролиферации [20 135](#). Физически, значение IC50 соответствует точке перегиба на дозозависимой кривой, которая описывает реакцию системы на увеличение концентрации вещества [33](#). Такие кривые обычно хорошо описываются математическими моделями, такими как уравнение Хилла [33](#) или четырехпараметрическая логистическая модель [34](#). Последняя часто используется в программном обеспечении для расчета IC50, например, GraphPad Prism 8.0, и имеет вид

$$Y = Y_{min} + (Y_{max} - Y_{min}) / (1 + (X / IC_{50})^H)$$
, где Y — ответ, X — концентрация, Y_{min}

и Y_{max} — минимальный и максимальный ответы, а H — параметр наклона кривой ³⁴. Биологический смысл IC_{50} заключается в оценке потенции соединения. Чем ниже значение IC_{50} , тем более сильным ингибитором является соединение, поскольку для достижения нужного эффекта требуется меньшая его концентрация ^{6 33}. Это часто свидетельствует о более высокой специфичности связывания с мишенью и потенциально меньшей системной токсичности при терапевтических дозах ³³. Например, в исследовании ингибиторов SARS-CoV-2 были найдены соединения с IC_{50} ниже 100 нМ, что указывает на их высокую активность ⁹¹.

Показатель CC_{50} , или полумаксимальная цитотоксическая концентрация, является зеркальным аналогом IC_{50} , но применяется в контексте токсикологии ¹³. CC_{50} определяется как концентрация соединения, которая вызывает цитотоксическое действие на 50% клеточной популяции в условиях *in vitro* эксперимента ¹³. Этот показатель позволяет оценить, насколько безопасным является соединение, то есть сколько его необходимо для повреждения и гибели здоровых клеток. Высокое значение CC_{50} свидетельствует о низкой цитотоксичности и, следовательно, о большей безопасности соединения ¹³. Если IC_{50} характеризует терапевтический эффект, то CC_{50} характеризует побочный, токсический эффект. Например, для антикоронавирусного препарата Remdesivir было показано, что его CC_{50} составляет более 10 мкМ, что является хорошим показателем низкой токсичности в тестовых клеточных линиях ¹³. В другом исследовании было показано, что некоторые полимерные производные демонстрируют IC_{50} около 230 нМ и CC_{50} около 1 мкМ против HCoV-NL63, что также говорит об относительно низкой токсичности ¹³.

Третьим и наиболее важным с точки зрения итоговой оценки является селективный индекс (Selectivity Index, SI). SI представляет собой безразмерную величину, которая количественно характеризует "терапевтическое окно" — разницу между концентрацией, необходимой для получения желаемого терапевтического эффекта, и концентрацией, вызывающей токсические побочные эффекты ¹³. SI рассчитывается как простое отношение CC_{50} к IC_{50} :

$$SI = \frac{CC_{50}}{IC_{50}}$$

^{13 97}. Биологический смысл этого показателя очевиден: он отвечает на вопрос, во сколько раз нужно увеличить терапевтическую концентрацию, чтобы достичь уровня токсичности. Чем выше значение SI, тем более селективным,

безопасным и перспективным является соединение [13](#). Соединение с высоким SI оказывает нужное воздействие на патологическую мишень при минимальном повреждении здоровых клеток. Например, ингибитор HCV NS5B polymerase Compound 254 имел EC50 7.3 мкМ и CC50 > 98.4 мкМ, что привело к очень высокому SI > 13 [13](#). Напротив, Valerenic acid имел EC50 4.43 мкМ и CC50 6.15 мкМ, что дало низкий SI около 1.39, что указывает на ограниченное терапевтическое окно [13](#). Таким образом, SI является производной метрикой, объединяющей информацию об активности (IC50) и безопасности (CC50).

Математическая связь между этими тремя показателями, выраженная формулой $SI = CC_{50}/IC_{50}$, является ключевым элементом при построении моделей машинного обучения. Эта связь неявная, но фундаментальная. Она означает, что SI полностью определяется двумя другими переменными. Любая попытка предсказать SI напрямую игнорирует эту внутреннюю структуру данных и создает для модели сложную, нелинейную задачу. Когда модель обучается предсказывать SI, она фактически пытается аппроксимировать функцию деления двух других переменных, которые могут иметь очень разные масштабы и распределения. Это делает задачу обучения значительно более трудной и потенциально менее стабильной по сравнению с обучением на исходных переменных IC50 и CC50. Кроме того, существует явная корреляция между IC50 и CC50. Химические структурные особенности, усиливающие связывание с целевой мишенью (понижая IC50), могут одновременно влиять и на токсичность (изменяя CC50). Например, увеличение липофильности может улучшить проникновение через клеточные мембраны и повысить активность, но также может увеличить неон-целевую связываемость и токсичность [23](#). Исследование, сравнивающее хлорированные и фторированные соединения, показало, что хлорированные аналоги имели несколько более высокую активность (pIC50) и одновременно более высокую токсичность (pCC50), что указывает на наличие таких взаимосвязей [23](#). Таким образом, при построении моделей важно учитывать не только отдельные значения, но и возможные корреляции между ними, что является одной из главных идей многоцелевого обучения.

Показатель	Полное название	Определение	Биологический смысл	Примеры значений
IC50	Полумаксимальная ингибирующая концентрация	Концентрация, снижающая биологическую активность на 50% 20 33 .	Потенция соединения. Чем ниже IC50, тем выше активность 6 33 .	<100 нМ (высокая активность), >100 мкМ (низкая активность) 91 .
CC50	Полумаксимальная цитотоксическая концентрация	Концентрация, вызывающая цитотоксическое действие на 50% клеточной популяции 13 .	Безопасность/токсичность соединения. Чем выше CC50, тем ниже токсичность 13 .	>10 мкМ (низкая токсичность), ~6 мкМ (умеренная токсичность) 13 .
SI	Селективный индекс	Отношение CC50 к IC50 ($SI = CC50 / IC50$) 13 97 .	Терапевтическое окно. Чем выше SI, тем более селективный и безопасный препарат 13 .	>66 (широкое терапевтическое окно), ~1.39 (узкое окно) 13 .

Эти три метрики образуют единую систему оценки. При построении моделей машинного обучения необходимо четко осознавать их взаимосвязи. Прямое использование SI в качестве целевой переменной является методологически проблематичным, поскольку модель будет вынуждена работать с уже выведенной, сильно сжатой и нелинейной характеристикой, которая может нести меньше информации для обучения общих закономерностей, чем исходные, более "сырые" данные (IC50 и CC50). Правильный подход заключается либо в совместном моделировании IC50 и CC50 с последующим вычислением SI как постобработки, либо в обучении трех независимых моделей, но последний вариант менее предпочтителен из-за потери информации о корреляциях. Переход к логарифмическим шкалам (pIC50, pCC50) является стандартной практикой, которая не только улучшает математические свойства данных, но и делает их более интуитивно понятными для исследователя, поскольку высокое значение pX всегда соответствует высокой активности или низкой токсичности.

Сравнительный анализ архитектур моделей: Независимые vs. Совместное Моделирование

При постановке задачи предсказания фармакологических свойств, таких как IC50, CC50 и SI, возникает фундаментальный вопрос о выборе архитектуры модели: следует ли обучать три отдельные, независимые регрессионные модели (подход «в лоб») или использовать подход совместного (или многоцелевого) моделирования, когда одна модель предсказывает все три показателя одновременно. Выбор между этими двумя стратегиями имеет

глубокие последствия для производительности, стабильности и интерпретируемости итоговой модели. Анализ предоставленных источников показывает, что подходы к многоцелевому обучению предлагают значительные преимущества, особенно в контексте взаимосвязанных фармакологических показателей.

Подход «в лоб», заключающийся в обучении трех независимых моделей (одна для IC50, вторая для CC50, третья для SI), кажется самым простым и интуитивно понятным. Каждая модель обучается исключительно на своей целевой переменной, что упрощает реализацию и управление процессом обучения. Однако этот подход содержит критическую методологическую ошибку: он полностью игнорирует существующую математическую и статистическую связь между целевыми переменными. Главная проблема здесь — прямое предсказание SI. Поскольку SI определяется формулой $SI = CC_{50}/IC_{50}$, его распределение является результатом нелинейной операции над двумя другими переменными. Когда модель обучается предсказывать SI напрямую, она сталкивается с уже выведенным, сильно сжатым и потенциально нестабильным показателем. Это заставляет модель работать с гораздо более сложной функцией, чем просто предсказание IC50 или CC50. Например, малые изменения в IC50 или CC50, особенно вблизи нуля, могут приводить к огромным колебаниям в значении SI, делая целевую переменную SI очень шумной и трудной для аппроксимации. Таким образом, предсказание SI напрямую является "плохой идеей", так как оно ухудшает точность и стабильность модели, заставляя ее учиться на уже обработанных, но информационно бедных данных.

Более продвинутый и предпочтительный подход — это совместное (multi-task learning, MTL) или многоцелевое (multi-output) моделирование. В этой парадигме одна и та же модель обучается одновременно предсказывать несколько целевых переменных (в данном случае, IC50 и CC50). Этот подход основан на мощном предположении о том, что различные задачи (предсказание IC50 и CC50) имеют общие структуры и могут извлекать выгоду из совместного обучения. Преимущества MTL-подходов многогранны: 1. Учет корреляций: Модель может научиться выявлять и использовать скрытые корреляции между IC50 и CC50. Как было показано в одном из исследований, определенные химические особенности могут одновременно влиять на активность и токсичность соединений ²³. Совместное обучение позволяет модели "научиться" этим общим закономерностям, что приводит к более точным и обобщенным предсказаниям. Исследования показывают, что MTL-модели, учитывающие схожесть биологических целей, значительно превосходят модели,

обученные на каждой задаче по отдельности [42](#) [53](#) [57](#). 2. Снижение переобучения: Когда объем обучающих данных ограничен, MTL может помочь снизить риск переобучения. Обучаясь на нескольких связанных задачах, модель вынуждена формировать более общие и абстрактные представления о данных, что делает ее менее чувствительной к случайным шумам в данных по одной конкретной задаче. 3. Повышение точности: За счет использования общей информации из нескольких задач, MTL-модели часто достигают более высокой точности по сравнению с ансамблем из отдельных моделей. Экспериментальные результаты показывают, что все три рассматриваемые многозадачные алгоритмы обучения приводят к улучшению производительности по сравнению с однозадачными [53](#). В крупномасштабном проекте MELLODDY, в котором приняли участие десять фармацевтических компаний, применение федеративного обучения позволило всем участникам получить улучшенные модели, что является ярким примером успеха совместного подхода [38](#).

В контексте данной задачи, наиболее логичным является обучение двух моделей: одной для предсказания IC50, другой для CC50. После получения этих двух предсказаний, SI может быть легко и точно вычислен как их отношение ($SI_{pred} = CC50_{pred} / IC50_{pred}$). Этот подход сочетает в себе преимущества обоих миров: он избегает проблемы обучения на сложной и нелинейной переменной SI, сохраняя при этом возможность улавливать общие закономерности через совместное моделирование IC50 и CC50. Важно отметить, что даже если мы обучаем две разные модели, а не одну MTL-модель, если они используют одни и те же признаки и одинаковые гиперпараметры, мы все равно можем говорить о "совместном" подходе в широком смысле. Однако истинное многоцелевое обучение, при котором модель имеет общие слои или компоненты перед несколькими выходными слоями, является еще более мощным инструментом.

Другой вариант, который следует избегать, — это обучение трех независимых моделей для IC50, CC50 и SI. Хотя это технически возможно, оно порождает проблему согласованности: предсказанное значение SI, полученное путем деления предсказанных CC50 и IC50 ($SI'_{pred} = CC50_{pred} / IC50_{pred}$). Это создает внутреннее противоречие в системе прогнозов. Более того, как уже упоминалось, обучение модели на SI является неэффективным.} / IC50_{pred}) , скорее всего, будет отличаться от значения, предсказанного третьей моделью (SI'''_{pred}

Таким образом, сравнительный анализ однозначно указывает на предпочтительность подходов, основанных на совместном моделировании. Вместо того чтобы бороться с нелинейностью связи, следует либо обучать одну MTL-модель для предсказания IC50 и CC50, либо обучать две отдельные модели, но на этих двух переменных. В обоих случаях SI должен рассматриваться как производная величина, вычисляемая на этапе постобработки. Это позволяет моделям сосредоточиться на более простых и информативных задачах, что в конечном итоге приводит к более точным, стабильным и интерпретируемым результатам.

Подход	Описание	Преимущества	Недостатки	Рекомендация
Независимые модели («в лоб»)	Обучение трех отдельных моделей для IC50, CC50 и SI.	Простота реализации, четкое разделение задач.	Полная потеря информации о корреляциях; обучение на нелинейной и шумной переменной SI; внутреннее несоответствие предсказаний.	Не рекомендуется.
Две независимые модели	Обучение двух моделей для IC50 и CC50 с последующим вычислением SI как постобработки.	Сохраняет информацию о корреляциях между IC50 и CC50; избегает сложной задачи обучения на SI.	Не использует явно общие закономерности, как это делает MTL.	Предпочтительный подход.
Совместное (MTL) моделирование	Обучение одной модели, имеющей два выхода для IC50 и CC50.	Максимальное использование общих закономерностей; потенциально более высокая точность и стабильность; снижение переобучения.	Более сложная архитектура и настройка гиперпараметров.	Наиболее предпочтительный подход.

В заключение, выбор архитектуры модели должен быть продиктован пониманием внутренних связей между целевыми переменными. Подход, игнорирующий математическую связь $SI = CC_{50}/IC_{50}$ и предлагающий обучать модель на SI напрямую, является методологически неверным и приведет к снижению качества предсказаний. Совместное моделирование IC50 и CC50, будь то через одну MTL-модель или два связанных алгоритма, является правильным путем, так как оно позволяет моделям извлекать максимальную пользу из структуры данных, что является ключевой целью в QSAR-моделировании.

Обоснование и влияние логарифмической трансформации целевых переменных

Одной из наиболее важных и широко распространенных практик в QSAR-моделировании является логарифмическая трансформация фармакологических показателей, в частности, переход от IC50 к pIC50 и от CC50 к pCC50. Эта процедура, определяемая формулой $pIC_{50} = -\log_{10}(IC_{50})$, является не просто удобством, а фундаментальным шагом, который улучшает качество моделей и делает их результаты более интуитивно понятными. Анализ предоставленных источников позволяет выделить три ключевые причины для проведения такой трансформации: нормализация распределения данных, улучшение численной стабильности и усиление интерпретируемости.

Первая и самая веская причина — это устранение смещения и нормализация распределения целевой переменной. Исходные значения IC50 и CC50 представляют собой концентрации вещества, которые могут варьироваться на несколько порядков, от наномолярных (нМ) до микромолярных (мкМ) или даже миллимолярных (мМ) уровней [24](#). Это означает, что диапазон значений может быть огромным, например, от 1×10^{-9} М до 1×10^{-4} М. Распределение таких данных почти всегда крайне асимметрично, с длинным правым хвостом, содержащим большое количество низкоактивных (высоких IC50) соединений [24](#). Такое смещенное распределение является серьезной проблемой для многих классов моделей машинного обучения, особенно для линейных моделей, которые часто предполагают нормальность распределения ошибок. Логарифмическая трансформация эффективно "сжимает" этот огромный диапазон. Значения IC50 в диапазоне от 1 нМ до 100 мкМ преобразуются в значения pIC50 в более управляемом диапазоне, например, от 6 до 10 (при условии перевода всех концентраций в одни и те же единицы, например, молярность) [19](#) [151](#). Эта трансформация делает распределение целевой переменной более симметричным, близким к нормальному, что является одним из ключевых предположений для многих статистических методов и улучшает их стабильность и надежность [19](#) [24](#). Исследование, посвященное предсказанию активности антиоксидантов, прямо указывает на то, что трансформация IC50 в pIC50 была выполнена для улучшения качества моделирования и визуализации данных [24](#).

Вторая причина — это улучшение численной стабильности и производительности вычислений. Работа с числами, имеющими очень большой диапазон, может приводить к проблемам с точностью вычислений с плавающей

запятой, особенно в итеративных алгоритмах, таких как градиентный спуск, используемый в нейронных сетях и моделях градиентного бустинга. Логарифмирование переводит проблему из области экспоненциально больших и малых чисел в область относительно небольших чисел, что повышает стабильность и скорость сходимости обучения ¹⁴⁸. Кроме того, многие химические и биологические процессы по своей природе являются логарифмическими. Например, связывание лиганда с рецептором описывается уравнением Больцмана, которое связано с логарифмической шкалой энергии. Поэтому использование логарифмической шкалы является более естественным способом представления силы взаимодействия.

Третья, и, возможно, самая важная с точки зрения практического применения, причина — это кардинальное улучшение интерпретируемости. Исходная шкала IC₅₀ имеет обратную интуицию: низкое значение IC₅₀ означает высокую активность, а высокое значение — низкую. Это может приводить к ошибкам в рассуждениях и визуализации. Шкала pIC₅₀ решает эту проблему элегантно. Поскольку pIC₅₀ — это отрицательный логарифм IC₅₀, она работает в прямом порядке: высокое значение **pIC₅₀** всегда означает высокую потенцию соединения ^{19 106}. Например, соединение с pIC₅₀ = 8 (соответствует IC₅₀ = 10 нМ) считается значительно более активным, чем соединение с pIC₅₀ = 7 (IC₅₀ = 100 нМ). Эта прямая интуиция делает анализ результатов, сравнение соединений и визуализацию данных (например, в виде гистограмм) гораздо более простыми и понятными ¹⁹. В одном из исследований были созданы QSAR-модели для предсказания pIC₅₀ значений для 12 из 15 раковых клеточных линий, что подчеркивает распространенность этой практики ⁵.

Формально, связь между pIC₅₀ и IC₅₀ определяется как $pIC_{50} = -\log_{10}(IC_{50})$ ^{3 156}. Из этой формулы следует, что каждое увеличение pIC₅₀ на единицу соответствует десятикратному уменьшению IC₅₀, то есть десятикратному увеличению потенции. Это позволяет легко классифицировать соединения по уровням активности: например, pIC₅₀ ≥ 8 может соответствовать очень высокой активности (IC₅₀ ≤ 10 нМ), 8 > pIC₅₀ ≥ 7 — высокой активности (10 нМ < IC₅₀ ≤ 100 нМ) и так далее ¹⁹. Аналогичная логика применяется и к CC₅₀, создавая шкалу pCC₅₀, где высокое значение соответствует низкой цитотоксичности.

Показатель	Шкала IC50	Шкала pIC50 (-log10)	Интерпретация
Активность	Низкое значение (например, 10 нМ)	Высокое значение (например, 8.0)	Соединение высокоактивно.
Активность	Высокое значение (например, 100 нМ)	Низкое значение (например, 7.0)	Соединение низкоактивно.
Цитотоксичность	Низкое значение (например, 1 мкМ)	Высокое значение (например, 6.0)	Соединение мало токсично.
Цитотоксичность	Высокое значение (например, 10 мкМ)	Низкое значение (например, 5.0)	Соединение высоко токсично.

Таким образом, логарифмическая трансформация — это не просто математическая формальность, а обязательный шаг в современном QSAR-моделировании. Она решает фундаментальные проблемы, связанные с распределением и масштабом данных, повышает численную стабильность моделей и, что самое главное, предоставляет исследователю интуитивно понятную и прямую меру биологической активности. Весьма вероятно, что любая современная работа по предсказанию биологической активности с использованием машинного обучения будет использовать pIC50 в качестве целевой переменной вместо IC50. Инструменты, такие как PIC50, специально разработаны для легкой интерконвертации между этими двумя шкалами, что подтверждает их взаимосвязь и равноправие в анализе [3](#) [84](#). Следовательно, любой исследовательский пайплайн, направленный на предсказание IC50 и CC50, должен начинаться с их преобразования в pIC50 и pCC50 соответственно.

Анализ влияния трансформации на производительность и стабильность моделей

Выбор целевой переменной (IC50 или pIC50) и ее трансформация оказывают существенное влияние на производительность, стабильность и общий успех моделей машинного обучения. Хотя логарифмическая трансформация является общепринятой практикой, ее конкретное воздействие различается для разных типов моделей, в первую очередь для линейных моделей и ансамблей деревьев решений. Анализ предоставленных материалов позволяет сделать вывод, что, несмотря на разные механизмы действия, трансформация в большинстве случаев положительно сказывается на качестве предсказаний как для одного, так и для другого класса моделей.

Для линейных моделей, таких как Ridge, Lasso, Elastic Net и Bayesian Ridge, логарифмическая трансформация целевой переменной является практически обязательной. Линейные регрессионные модели строятся на основе статистических предположений, одно из ключевых из которых — нормальное распределение остатков (ошибок) модели. Когда целевая переменная y (в данном случае, IC50) имеет сильно смещенное распределение, как это часто бывает с концентрациями, предположение о нормальности ошибок нарушается. Это приводит к тому, что модель может давать смещенные оценки коэффициентов, некорректные доверительные интервалы и p -значения, а также может быть чувствительна к выбросам. Трансформация целевой переменной y в $y' = T(y)$ меняет саму задачу, которую модель должна решить. Например, в работе [54](#) показано, что преобразование целевой переменной перед обучением линейной регрессии может значительно улучшить ее производительность. Переход к $pIC50$ ($y' = -\log_{10}(y)$) эффективно "выпрямляет" распределение данных, делая его более симметричным и близким к нормальному. Это позволяет модели лучше аппроксимировать реальную зависимость и приводит к более надежным и стабильным результатам. Исследование по предсказанию антиоксидантной активности прямо указывает на использование $pIC50$ для улучшения качества моделирования, что подразумевает работу с более благоприятными данными [24](#). Таким образом, для линейных моделей логарифмирование — это не просто улучшение, а необходимое условие для выполнения базовых статистических допущений и получения корректных результатов. Модели, основанные на линейной регрессии, считаются более простыми в интерпретации, хотя и могут уступать в точности нелинейным моделям [143](#).

Влияние трансформации на ансамбли деревьев решений, такие как Random Forest, Gradient Boosting Machines (GBM), XGBoost и CatBoost, менее очевидно, но также в большинстве случаев положительно. В отличие от линейных моделей, деревья решений не делают строгих предположений о распределении данных или о форме зависимости. Они работают путем рекурсивного деления пространства признаков на ящики и предсказания среднего значения целевой переменной в каждом ящике. Тем не менее, трансформация целевой переменной все равно оказывает на них значительное влияние, хотя и по другим причинам. Во-первых, она улучшает качество самой целевой переменной, которую пытаются предсказать. Сжатый диапазон значений $pIC50$ (например, от 4 до 10) может сделать градиентный спуск в моделях типа градиентного бустинга более стабильным и быстрым [24](#). Во-вторых, многие метрики качества, используемые для оценки моделей, такие как

среднеквадратичная ошибка (RMSE) или средняя абсолютная ошибка (MAE), чувствительны к масштабу целевой переменной. Трансформация может сделать ошибку более однородной по всему диапазону предсказаний. Вопрос о целесообразности логарифмирования целевой переменной для деревьев решений обсуждается в источнике [9](#), где подтверждается, что это приемлемая и часто используемая практика. Многочисленные успешные применения моделей машинного обучения для предсказания pIC50 в литературе служат эмпирическим подтверждением пользы этой трансформации. Например, в исследовании, сравнивающем шесть различных алгоритмов машинного обучения для предсказания pIC50, были успешно применены Random Forest, CatBoost и XGBoost [25](#). Другое исследование также подчеркивает важность предсказания pIC50 с помощью машинного обучения [4](#). В статье, описывающей AI-усиленный дизайн ингибиторов, также упоминается переход от IC50 к pIC50 [26](#). Все эти примеры указывают на то, что сообщество исследователей считает логарифмирование целесообразным и эффективным шагом для повышения качества моделей, включая ансамбли деревьев.

Что касается стабильности, то трансформация помогает справиться с экстремальными значениями. В наборе данных по IC50 может встречаться одно соединение с чрезвычайно низкой активностью (например, $IC_{50} = 100 \text{ мкМ} = 1 \times 10^{-4} \text{ М}$), которое будет представлять собой выброс по сравнению со средними значениями в диапазоне наномолярных концентраций. В модели, обученной на IC50, этот один выброс может "потянуть" предсказания в сторону больших значений, искажая картину. Логарифмирование превращает это значение в $pIC_{50} = 4$, что является обычным значением в распределении и не будет являться выбросом. Это делает модель более устойчивой к таким экстремальным случаям.

В таблице ниже представлено сравнение влияния трансформации на два класса моделей.

Аспект	Линейные модели (Ridge, Lasso)	Ансамбли деревьев (RF, XGBoost)
Основное влияние	Обеспечение выполнения статистических предположений (нормальность ошибок), что критично для корректности модели.	Улучшение численной стабильности, сглаживание распределения и устойчивость к выбросам.
Производительность	Значительное улучшение производительности и надежности оценок.	Улучшение производительности (RMSE, MAE) и стабильности обучения.
Стабильность	Повышение устойчивости к нарушению предположений о данных.	Повышение устойчивости к выбросам в целевой переменной.
Обоснование	Теоретическое (статистические предпосылки).	Эмпирическое и теоретическое (улучшение численных свойств).

Таким образом, несмотря на разные внутренние механизмы, логарифмическая трансформация целевых переменных IC50 и CC50 в pIC50 и pCC50 является настоятельно рекомендуемой практикой для широкого круга моделей машинного обучения. Для линейных моделей она является необходимостью для соблюдения статистических допущений. Для ансамблей деревьев она является мощным инструментом для улучшения численной стабильности, повышения устойчивости к выбросам и, как следствие, улучшения итоговой производительности. Отказ от этой трансформации может привести к менее надежным и менее точным моделям, что особенно критично на ранних стадиях разработки лекарств, где каждый процент точности имеет значение.

Влияние трансформации на интерпретируемость моделей и важность признаков

Вопрос о влиянии трансформации целевой переменной (IC50 → pIC50) на интерпретируемость моделей и оценку важности признаков является одним из наиболее сложных и нетривиальных. С первого взгляда может показаться, что изменение шкалы ответа должно влиять на то, какие признаки модель считает "важными". Однако глубокий анализ показывает, что это влияние не является автоматическим недостатком и требует более тонкого подхода к интерпретации. Современные методы объяснимого ИИ, такие как SHAP, предоставляют инструменты для всестороннего анализа этого влияния.

Теоретически, любая монотонная трансформация целевой переменной y в $y' = T(y)$ будет влиять на оценку важности признаков, поскольку она меняет характер зависимости, которую модель должна аппроксимировать. Многие

методы оценки важности признаков, особенно для деревьев решений, основаны на частных производных или изменениях в показателе качества модели. Например, важность признака по Gini, используемая в деревьях решений, зависит от того, насколько хорошо данный признак разделяет данные для минимизации нечистоты в узлах, и эта нечистота напрямую зависит от распределения целевой переменной y . Аналогично, перестановочная важность признака измеряет, насколько ухудшается производительность модели, когда значения одного признака "случайным образом перемешиваются", и величина этого ухудшения зависит от шкалы y .

Рассмотрим конкретно логарифмическую трансформацию $y' = pIC50 = -\log_{10}(IC50) = -\log_{10}(y)$. Производная этой трансформации по исходной переменной y равна $dy'/dy = -1/(y \ln(10))$. Это означает, что важность признака x_i , оцениваемая моделью, будет пропорциональна частной производной $\partial y'/\partial x_i$. По правилу сложной производной, $\partial y'/\partial x_i = (\partial y'/\partial y) (\partial y/\partial x_i)$. Таким образом, $\partial y'/\partial x_i$ обратно пропорциональна исходному значению y (IC50). Это имеет важные следствия: 1. Взвешивание по активности: Признаки, которые оказывают сильное влияние на IC50 в области очень низких значений (высокая активность, наномолярный диапазон), будут иметь больший вклад в производную $\partial y'/\partial x_i$ после трансформации, чем те же самые признаки, влияющие на IC50 в области высоких значений (низкая активность, микромолярный диапазон). 2. Изменение ранжирования: Это может привести к изменению абсолютных значений и даже к перестановке мест в ранжировании важности признаков. Признак, который был второстепенным для предсказания высоких значений IC50, может стать доминирующим при предсказании низких значений.

Это изменение не обязательно является плохим. $pIC50$ является более естественной и интуитивно понятной целевой переменной для оценки активности. Поэтому важно, чтобы модель уделяла больше внимания признакам, определяющим высокую активность (низкий IC50), поскольку именно их понимание является главной целью в ранней разработке лекарств. Однако это изменение делает прямое сравнение ранжирований важности, полученных для моделей на IC50 и $pIC50$, некорректным.

Здесь на помощь приходят методы объяснимого ИИ, в частности SHAP (SHapley Additive exPlanations) [17](#). SHAP предлагает фундаментально новый подход к интерпретации моделей. В отличие от методов, дающих один "взвешенный" показатель важности для каждого признака, SHAP вычисляет вклад каждого

признака в конкретное индивидуальное предсказание. Этот вклад, называемый SHAP-значением, показывает, насколько каждое значение признака увеличило или уменьшило предсказанное значение по сравнению с базовым значением (средним предсказанием по фоновому набору данных) [69](#) [108](#).

Этот подход позволяет провести глубокий сравнительный анализ влияния трансформации: 1. Обучение двух моделей: Можно обучить две модели на одном и том же наборе данных: одну для предсказания IC50, другую для pIC50. 2. Вычисление SHAP-значений: Для набора тестовых данных можно вычислить SHAP-значения как для первой модели, так и для второй. 3. Сравнительный анализ: Теперь можно визуализировать и сравнивать SHAP-значения для обеих моделей. Например, можно построить "диаграмму рассеяния SHAP" для ключевого признака x_i . На одном графике будут показаны SHAP-значения x_i в зависимости от самого x_i для модели, обученной на IC50. На другом — для модели, обученной на pIC50. Сравнивая эти два графика, можно увидеть, как вклад признака x_i в предсказание активности меняется при переходе к логарифмической шкале. Это позволит ответить на конкретные вопросы: "Как именно мое новое химическое свойство влияет на IC50 в наномолярном диапазоне?" и "Как оно влияет на pIC50?". Это дает гораздо более богатую и детализированную картину, чем простое ранжирование.

SHAP также позволяет анализировать взаимодействия между признаками и выявлять нелинейные зависимости, что особенно ценно для сложных моделей, таких как ансамбли деревьев [15](#) [18](#). Например, можно увидеть, как вклад одного признака зависит от значения другого, и как эта зависимость меняется при переходе от IC50 к pIC50. Исследования показывают, что SHAP-значения и перестановочная важность часто дают сильно согласующиеся ранжировки, что повышает доверие к полученным выводам [45](#) [86](#).

Таким образом, хотя трансформация целевой переменной и изменяет оценку важности признаков, это не является препятствием, а скорее приглашением к более глубокому анализу. Простое игнорирование этого эффекта и сравнение ранжирований "в лоб" было бы ошибкой. Правильный подход заключается в принятии трансформации как части задачи и использовании продвинутых инструментов интерпретации, таких как SHAP, для анализа того, как модель "думает" в новой, более естественной шкале pIC50. Это позволяет получить надежные и интерпретируемые выводы о химических факторах, определяющих биологическую активность, что является конечной целью любого QSAR-проекта.

Итоговый синтез и практические рекомендации по построению моделей

Проведенное глубокое исследование ключевых фармакологических показателей IC50, CC50 и SI и их роли в моделях машинного обучения позволяет сформулировать ряд строгих выводов и практических рекомендаций, которые должны лежать в основе любого качественного QSAR-проекта. Комплексный подход, объединяющий правильное понимание метрик, выбор оптимальной архитектуры модели и применение адекватных методов трансформации и интерпретации, является залогом создания надежных и интерпретируемых предсказательных систем.

Итоговые выводы:

1. Биологический смысл и математическая связь: IC50 (потенция), CC50 (цитотоксичность) и SI (селективность) — это три взаимосвязанных, но фундаментально разных фармакологических параметра. Их правильное понимание критично для корректной постановки задачи. Ключевой является математическая связь $SI = CC50 / IC50$, которая является неявной, но фундаментальной.
2. Архитектура моделей: Подход, предполагающий обучение трех независимых моделей, включая модель для прямого предсказания SI, является методологически несостоятельным. Прямое обучение на SI заставляет модель работать с уже выведенной, сильно сжатой и нелинейной характеристикой, что значительно усложняет задачу и снижает точность. Наиболее предпочтительным подходом является совместное (многоцелевое) моделирование IC50 и CC50. Это может быть реализовано либо через одну MTL-модель с двумя выходами, либо через обучение двух связанных моделей. SI в этом случае должен рассматриваться как производная величина, вычисляемая на этапе постобработки.
3. Логарифмическая трансформация: Переход от IC50/CC50 к pIC50/pCC50 ($pX = -\log_{10}(X)$) является не просто рекомендацией, а обязательной практикой. Эта трансформация решает три фундаментальные проблемы: она нормализует распределение целевых переменных, повышает численную стабильность вычислений и, что самое важное, делает шкалу активности интуитивно понятной, где высокое значение всегда

соответствует высокой активности. Это улучшает производительность и стабильность как линейных моделей, так и ансамблей деревьев решений.

4. **Интерпретируемость и важность признаков:** Трансформация целевой переменной изменяет оценку важности признаков. Это изменение не является автоматическим недостатком, поскольку pIC_{50} является более естественной метрикой для оценки активности. Для адекватного анализа и сравнения влияния признаков в исходном и трансформированном пространстве следует использовать современные методы объяснимого ИИ, в первую очередь SHAP. SHAP позволяет проводить глубокий сравнительный анализ вклада признаков в индивидуальных предсказаниях, предоставляя богатую и надежную информацию о химических факторах, определяющих биологическую активность.

Практические рекомендации по построению модели:

На основе проведенного анализа можно предложить следующий стандартизированный рабочий процесс для построения предсказательной модели биологической активности:

1. **Шаг 1:** Определение целевых переменных и сбор данных. Собрать максимально полный набор данных, содержащий молекулярные описатели (признаки) и экспериментальные значения IC_{50} и CC_{50} для соответствующих клеточных линий или целевых белков. Важно отметить, что качество данных имеет первостепенное значение. Даже после максимальной очистки значительный уровень шума остается в данных, что подчеркивает важность качественной предварительной обработки [20](#).
2. **Шаг 2:** Предварительная обработка и трансформация. Привести все значения IC_{50} и CC_{50} к единой системе единиц (например, молярность). Затем выполнить логарифмическую трансформацию: вычислить $pIC_{50} = -\log_{10}(IC_{50})$ и $pCC_{50} = -\log_{10}(CC_{50})$. Именно на этих двух новых переменных будут обучаться модели. Также на этом этапе следует удалить дубликаты и обработать пропущенные значения.

3. Шаг 3: Выбор и обучение модели. Рекомендуется использовать архитектуру совместного (многоцелевого) обучения. В качестве модели можно выбрать:

- Ансамбли деревьев решений: XGBoost, LightGBM или CatBoost часто показывают высокую производительность в QSAR-задачах 25 47.
- Модели на основе ядерных методов: Например, гребневая регрессия с ядром, которая хорошо подходит для работы с химическими дистанционными матрицами.
- Нейронные сети: Глубокие нейронные сети также могут быть эффективны, особенно при наличии больших объемов данных 58.

Важно использовать кросс-валидацию для надежной оценки производительности

1. Шаг 4: Оценка производительности. Оценить качество обученной модели на отложенной тестовой выборке с использованием стандартных метрик регрессии, таких как коэффициент детерминации (R^2), среднеквадратичная ошибка (RMSE) и средняя абсолютная ошибка (MAE) для обеих целевых переменных (pIC50 и pCC50).

2. Шаг 5: Интерпретация и анализ важности признаков. После обучения модели необходимо провести ее интерпретацию. Здесь ключевую роль играет метод SHAP. Необходимо:

- Вычислить SHAP-значения для тестового набора данных.
- Построить глобальные диаграммы, такие как "waterfall plot" или "dot plot", чтобы понять средний вклад каждого признака в предсказание pIC50 и pCC50.
- Использовать локальные диаграммы "force plot" для анализа индивидуальных предсказаний.
- Провести сравнительный анализ, чтобы понять, какие химические свойства ведут к увеличению активности (росту pIC50) и одновременно снижению токсичности (росту pCC50).

1. Шаг 6: Расчет SI и дальнейшие шаги. Получив предсказания pIC50_pred и pCC50_pred, можно вычислить предсказанный SI как

$$SI_{pred} = CC50_{pred} / IC50_{pred} = 10^{-pCC50_{pred}} / 10^{-pIC50_{pred}} = 10^{(pIC50_{pred} - pCC50_{pred})}$$

Этот показатель можно использовать для фильтрации и ранжирования соединений по их селективности.

Следование этому комплексному подходу позволит не только построить модель с высокой предсказательной точностью, но и получить глубокое понимание химических принципов, лежащих в основе биологической активности и токсичности, что является конечной целью в современной хемоинформатике и разработке лекарств.

Справка

1. Frequency distribution of estimated pIC50 values. The IC50 values of... https://www.researchgate.net/figure/Frequency-distribution-of-estimated-pIC50-values-The-IC50-values-of-novel-potent-type-112_fig5_340921184
2. Benchmarking deep learning models for predicting anticancer drug ... <https://www.nature.com/articles/s42004-026-01916-9>
3. PIC50: An open source tool for interconversion of PIC50values and ... https://www.academia.edu/104587591/PIC50_An_open_source_tool_for_interconversion_of_PIC50values_and_IC50for_efficient_data_representation_and_analysis
4. Enhancing cancer drug discovery: QSAR modeling with machine ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12994839/>
5. QSAR Modeling for Predicting IC50 and GI50 Values for Human Cell ... <https://www.mdpi.com/1422-0067/26/24/12063>
6. IC50 value calculated by QSAR model in MOE? - ECHEMI https://www.echemi.com/community/ic50-value-calculated-by-qsar-model-in-moe_mjart2204011800_189.html
7. Feature ranking for multi-target regression | Machine Learning <https://link.springer.com/article/10.1007/s10994-019-05829-8>
8. 1.11. Ensembles: Gradient boosting, random forests, bagging, voting ... <https://scikit-learn.org/stable/modules/ensemble.html>
9. Log transform dependent variable for regression tree - Stack Overflow <https://stackoverflow.com/questions/28239980/log-transform-dependent-variable-for-regression-tree>
10. Using single- and multi-target regression trees and ensembles to ... https://www.researchgate.net/publication/252285513_Using_single-_and_multi-target_regression_trees_and_ensembles_to_model_a_compound_index_of_vegetation_condition

11. Effects of data transformation and model selection on feature ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC11699698/>
12. Relational tree ensembles and feature rankings - ScienceDirect.com <https://www.sciencedirect.com/science/article/pii/S0950705122006244>
13. CC50 - an overview | ScienceDirect Topics <https://www.sciencedirect.com/topics/biochemistry-genetics-and-molecular-biology/cc50>
14. Relation between prognostics predictor evaluation metrics and local ... <https://www.sciencedirect.com/science/article/pii/S0004370222000078>
15. SHAP Value Analysis of a Random Forest Atmospheric Neutral ... <https://arxiv.org/html/2509.26299v1>
16. Overview of SHAP values for random forest model ... - ResearchGate https://www.researchgate.net/figure/Overview-of-SHAP-values-for-random-forest-model-SHAP-values-of-the-clearance-a-and_fig1_361548256
17. Interpreting Machine Learning Models with SHAP Values - MDPI <https://www.mdpi.com/2073-4395/15/12/2780>
18. Application of SHAP values for inferring the optimal functional form ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9381890/>
19. Best Practices for Constructing Reproducible QSAR Models https://www.researchgate.net/publication/338639486_Best_Practices_for_Constructing_Reproducible_QSAR_Models
20. Combining IC50 or Ki Values from Different Sources Is a Source of ... <https://pubs.acs.org/doi/10.1021/acs.jcim.4c00049>
21. Antiviral and Molecular Docking Studies | ACS Omega <https://pubs.acs.org/doi/10.1021/acsomega.3c08407>
22. Pharmaceuticals, Volume 19, Issue 4 (April 2026) – 130 articles <https://www.mdpi.com/1424-8247/19/4>
23. Which halogen to choose? Comparing the effects of chlorine and ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12814216/>
24. QSAR Models for Predicting the Antioxidant Potential of Chemical ... <https://www.mdpi.com/2039-4713/15/3/80>
25. Application of Machine Learning Models for Predicting pIC50 Values ... <https://www.mdpi.com/2624-8549/8/5/68>
26. AI-powered IC50 prediction for p53 inhibitors drug-target interaction ... <https://link.springer.com/article/10.1007/s10822-025-00723-z>
27. Articles | Journal of Cheminformatics | Springer Nature Link <https://jcheminf.biomedcentral.com/articles?tab=keyword&searchType=journalSearch&sort=PubDate&volume=13&page=2>

28. A High-Performance and Interpretable pKa Prediction Framework ... <https://www.mdpi.com/1420-3049/31/6/961>
29. Recent Advances of DprE1 Inhibitors against Mycobacterium ... <https://pubs.acs.org/doi/10.1021/acsomega.2c05307>
30. Comparison and Interpretability Analysis of Deep Learning Models ... <https://www.mdpi.com/2076-3417/15/7/3476>
31. Advancing Identification of Transformation Products and Predicting ... <https://www.mdpi.com/2076-3417/16/1/267>
32. Precision Enhanced Bioactivity Prediction of Tyrosine Kinase ... - MDPI <https://www.mdpi.com/1424-8247/18/7/975>
33. Comparison of Drug Inhibitory Effects (IC₅₀) in Monolayer ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC9773863/>
34. Assessment of Cell Viability in Drug Therapy: IC₅₀ and Other New ... <https://www.mdpi.com/1999-4923/17/2/247>
35. Transfer and Multi-task Learning in QSAR Modeling - Frontiers <https://www.frontiersin.org/journals/pharmacology/articles/10.3389/fphar.2018.00074/full>
36. Transfer and Multi-task Learning in QSAR Modeling - PMC - NIH <https://pmc.ncbi.nlm.nih.gov/articles/PMC5807924/>
37. Meta-QSAR: a large-scale application of meta-learning to drug ... <https://link.springer.com/article/10.1007/s10994-017-5685-x>
38. MELLODDY: cross pharma federated learning at unprecedented ... https://www.researchgate.net/publication/364560561_MELLODDY_cross_pharma_federated_learning_at_unprecedented_scale_unlocks_benefits_in_QSAR_without_compromising_proprietary_information
39. AI-Integrated QSAR Modeling for Enhanced Drug Discovery - MDPI <https://www.mdpi.com/1422-0067/26/19/9384>
40. The Bigger Fish: A Comparison of Meta-Learning QSAR Models on ... <https://pubs.acs.org/doi/10.1021/acs.est.3c00334>
41. ToxACoL: an endpoint-aware and task-focused compound ... - Nature <https://www.nature.com/articles/s41467-025-60989-7>
42. Multi-Task Learning Models for Predicting Active Compounds https://www.researchgate.net/publication/342557101_Multi-Task_Learning_Models_for_Predicting_Active_Compounds
43. Relationship Between Scoring Function and the IC₅₀ Inhibitory of ... https://www.academia.edu/71409523/Relationship_Between_Scoring_Function_and_the_IC_50_Inhibitory_of_PI3K_Inhibitors

44. Interpretable machine learning with tree-based shapley additive ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC10159207/>
45. (PDF) A Unified Approach to Interpreting Model Predictions https://www.researchgate.net/publication/317062430_A_Unified_Approach_to_Interpreting_Model_Predictions
46. Interpretable Machine Learning for CBR Prediction - MDPI <https://www.mdpi.com/2075-5309/16/9/1826>
47. An interpretable XGBoost-SHAP machine learning model for reliable ... <https://www.sciencedirect.com/science/article/pii/S2590123025003883>
48. Inherently Interpretable Tree Ensemble Learning - arXiv <https://arxiv.org/html/2410.19098v1>
49. application to compound potency and multi-target activity predictions <https://link.springer.com/article/10.1007/s10822-020-00314-0>
50. Comparison of Quantitative and Qualitative (Q)SAR Models Created ... <https://www.frontiersin.org/journals/pharmacology/articles/10.3389/fphar.2018.01136/full>
51. Comparability of Mixed IC50 Data – A Statistical Analysis - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC3628986/>
52. Correlation based feature importance analysis for improving ... <https://www.nature.com/articles/s41598-026-37270-y>
53. An empirical comparison on multi-target regression learning https://www.researchgate.net/publication/327362690_An_empirical_comparison_on_multi-target_regression_learning
54. Effect of transforming the targets in regression model - Scikit-learn https://scikit-learn.org/stable/auto_examples/compose/plot_transformed_target.html
55. Comparative Analysis and Optimisation of Machine Learning ... - MDPI <https://www.mdpi.com/2227-7390/14/3/473>
56. Enhancing Feature Selection and Interpretability in AI Regression ... <https://arxiv.org/html/2409.16787v1>
57. Inferring multi-target QSAR models with taxonomy-based multi-task ... https://www.researchgate.net/publication/248396465_Inferring_multi-target_QSAR_models_with_taxonomy-based_multi-task_learning
58. Comparative study between deep learning and QSAR classifications ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC7545175/>
59. QSAR-Co: An Open Source Software for Developing Robust ... <https://pubs.acs.org/doi/10.1021/acs.jcim.9b00295>
60. Do Larger Models Really Win in Drug Discovery? A Benchmark ... <https://arxiv.org/html/2604.26498v2>

61. Comparison of Quantitative and Qualitative (Q)SAR Models Created ... <https://www.semanticscholar.org/paper/a1f01e7c89883d4942288867f822910cabcc9737>
62. Physics-Constrained Machine Learning for Chemical Engineering <https://arxiv.org/html/2508.20649v1>
63. (PDF) Physics-informed Deep Learning for simultaneous Surrogate ... https://www.researchgate.net/publication/363137360_Physics-informed_Deep_Learning_for_simultaneous_Surrogate_Modelling_and_PDE-constrained_Optimization
64. Multi-Output Probabilistic Prediction of Drug Side Effects Using ... <https://www.mdpi.com/1424-8247/19/4/595>
65. AVP-IC50 Pred: Multiple machine learning techniques-based ... <https://pubmed.ncbi.nlm.nih.gov/26213387/>
66. [PDF] Physics-Informed Representation and Learning: Control and Risk ... <https://ojs.aaai.org/index.php/AAAI/article/view/30169/32075>
67. Physics-informed machine learning enabled virtual experimentation ... <https://pubs.rsc.org/en/content/articlelanding/2024/mh/d4mh01022a>
68. C-SHAP: A Hybrid Method for Fast and Efficient Interpretability - MDPI <https://www.mdpi.com/2076-3417/15/2/672>
69. Model Interpretability - Feature Importance using SHAP & LIME <https://www.kaggle.com/getting-started/288193>
70. Practical guide to SHAP analysis: Explaining supervised machine ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC11513550/>
71. Provably Stable Rankings with SHAP and LIME - arXiv <https://arxiv.org/html/2401.15800v2>
72. (PDF) Interpretable Using Feature Importance, SHAP and LIME for ... https://www.researchgate.net/publication/400458843_Interpretable_Using_Feature_Importance_SHAP_and_LIME_for_Caesar's_Prediction
73. Towards a More Reliable Interpretation of Machine Learning ... - MDPI <https://www.mdpi.com/2076-3417/11/24/11854>
74. A Perspective on Explainable Artificial Intelligence Methods: SHAP ... <https://arxiv.org/html/2305.02012v3>
75. Additive-feature-attribution methods: a review on explainable ... - arXiv <https://arxiv.org/html/2409.11992v1>
76. 5.2. Permutation feature importance - Scikit-learn https://scikit-learn.org/stable/modules/permutation_importance.html
77. Top-k Feature Importance Ranking - arXiv <https://arxiv.org/html/2509.15420v1>

78. SHAP Value-Based Feature Importance Analysis for Short-Term ... https://www.researchgate.net/publication/361997133_SHAP_Value-Based_Feature_Importance_Analysis_for_Short-Term_Load_Forecasting
79. Grouped feature importance and combined features effect plot <https://link.springer.com/article/10.1007/s10618-022-00840-5>
80. (a) decision tree; (b) neural network; (c) generalized additive model ... <http://ijmmm.ustb.edu.cn/supplement/94a26959-8fa3-4ed3-a8be-b0f348d5d916>
81. A Target Permutation Test for Statistical Significance of Feature ... <https://www.mdpi.com/2079-9292/14/3/571>
82. Debunking the Idea that Ligand Efficiency Indices Are Superior to ... <https://pubs.acs.org/doi/10.1021/acs.jcim.6b00431>
83. [PDF] QSAR Modeling and Drug-Likeness Screening for Antioxidant ... <https://www.sciencedirect.com/science/article/am/pii/S002228601930393X>
84. Tool development for Prediction of pIC50 values from the IC50 values <https://www.semanticscholar.org/paper/Tool-development-for-Prediction-of-pIC50-values-the-Selvaraj-Tripathi/1e679814fffa1a71fadbed952305db1528cdec21>
85. Validity of Feature Importance in Low-Performing Machine Learning ... <https://arxiv.org/html/2409.13342v1>
86. Machine learning prediction model for medical environment comfort ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12603039/>
87. Statistical stability indices for LIME: obtaining reliable explanations ... https://www.researchgate.net/publication/338989396_Statistical_stability_indices_for_LIME_obtaining_reliable_explanations_for_Machine_Learning_models
88. A small-molecule TNIK inhibitor targets fibrosis in preclinical and ... <https://www.nature.com/articles/s41587-024-02143-0>
89. Antiviral drug discovery and development: challenges and future ... <https://www.nature.com/articles/s41392-025-02539-7>
90. AI designed, mutation resistant broad neutralizing antibodies ... <https://www.nature.com/articles/s41598-025-98979-w>
91. From nicotine to SARS-CoV-2 antivirals with potent in vivo efficacy ... https://www.nature.com/articles/s41467-026-69527-5_reference.pdf
92. AI-driven discovery of antiretroviral drug bictegravir and etravirine as ... <https://www.nature.com/articles/s42003-025-09129-x>
93. Identification of acrylamide-based covalent inhibitors of SARS-CoV ... <https://pubs.rsc.org/en/content/articlehtml/2025/ra/d4ra06955b>

94. Navigating the complexities of drug development for metallo- β ... <https://pubs.rsc.org/en/content/articlehtml/2025/md/d5md00035a>
95. From nicotine to SARS-CoV-2 antivirals with potent in vivo efficacy ... <https://www.nature.com/articles/s41467-026-69527-5>
96. Identification of acrylamide-based covalent inhibitors of SARS-CoV ... <https://pubs.rsc.org/en/content/articlepdf/2025/ra/d4ra06955b>
97. Multiscale-Aware Graph Embedding Approach Uncovers LC-61, a ... <https://pubs.acs.org/doi/10.1021/acs.jcim.5c02947>
98. Clustering Protein Binding Pockets and Identifying Potential Drug ... <https://pubs.acs.org/doi/10.1021/acs.jcim.3c00722>
99. SAR-Guided Scoring Function and Mutational Validation Reveal the ... <https://pubs.acs.org/doi/10.1021/acs.jcim.8b00199>
100. Search for New Controlling Agents against *Spodoptera frugiperda* ... <https://pubs.acs.org/doi/10.1021/acs.jafc.9b01067>
101. Identification of Promising Sulfonamide Chalcones as Inhibitors of ... <https://pubs.acs.org/doi/10.1021/acs.jcim.3c00663>
102. Overview of Recent Strategic Advances in Medicinal Chemistry <https://pubs.acs.org/doi/10.1021/acs.jmedchem.9b00359>
103. Mechanisms of Biological Effects of Ionic Liquids: From Single Cells ... <https://pubs.acs.org/doi/10.1021/acs.chemrev.3c00420>
104. Abstracts of the papers presented in the international conference of ... <https://link.springer.com/article/10.1007/s13337-025-00913-1>
105. Abstracts of the papers presented in the international conference of ... <https://link.springer.com/article/10.1007/s13337-024-00867-w>
106. Tool development for Prediction of pIC50 values from the IC50 ... https://www.researchgate.net/publication/239186832_Tool_development_for_Prediction_of_pIC50_values_from_the_IC50_value_s-A_pIC50_value_calculator
107. Interpretation of machine learning models using shapley values - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC7449951/>
108. An introduction to explainable AI with Shapley values — SHAP latest ... https://shap.readthedocs.io/en/latest/example_notebooks/overviews/An%20introduction%20to%20explainable%20AI%20with%20Shapley%20values.html
109. Process Variable Importance Analysis by Use of Random Forests in ... <https://www.mdpi.com/2075-163X/10/5/420>
110. ShapG: new feature importance method based on the Shapley value <https://arxiv.org/html/2407.00506v2>

111. Machine Learning Models Identify Inhibitors of SARS-CoV-2 <https://pubs.acs.org/doi/10.1021/acs.jcim.1c00683>
112. Benchmarking open-source tools for in silico antiviral drug discovery <https://arxiv.org/html/2605.04265v1>
113. Benchmarking open-source tools for in silico antiviral drug discovery https://www.researchgate.net/publication/404542629_Benchmarking_open-source_tools_for_in_silico_antiviral_drug_discovery
114. (PDF) Unveiling the antiviral capabilities of targeting Human ... https://www.researchgate.net/publication/374479748_Unveiling_the_antiviral_capabilities_of_targeting_Human_Dihydroorotate_Dehydrogenase_against_SARS-CoV-2
115. Chemical probes and drug leads from advances in synthetic ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC6707071/>
116. 2015 Philip S. Portoghese Medicinal Chemistry Lectureship. Curing ... <https://pubs.acs.org/doi/10.1021/acs.jmedchem.6b00915>
117. (PDF) Mal-Predict: Machine learning-guided rapid virtual screening ... https://www.researchgate.net/publication/403940591_Mal-Predict_Machine_learning-guided_rapid_virtual_screening_of_compounds_against_selected_targets_of_Plasmodium_falciparum_validated_using_molecular_dynamics_simulation
118. A Clinical-Stage Cysteine Protease Inhibitor blocks SARS-CoV-2 ... <https://pubs.acs.org/doi/10.1021/acscchembio.0c00875>
119. Screening for Potential Antiviral Compounds from Cyanobacterial ... https://www.researchgate.net/publication/385554625_Screening_for_Potential_Antiviral_Compounds_from_Cyanobacterial_Secondary_Metabolites_Using_Machine_Learning
120. Nonpeptidic Ligands for Peptide-Activated G Protein-Coupled ... <https://pubs.acs.org/doi/10.1021/cr050984g>
121. Interpretable machine learning-driven QSAR modeling for ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC12827418/>
122. MolFoundry: A Structure-Aware Generative Framework for De Novo ... <https://pubs.acs.org/doi/10.1021/acsomega.6c00951>
123. AI-Accelerated Design of Targeted Covalent Inhibitors for SARS ... <https://pubs.acs.org/doi/10.1021/acs.jcim.2c01377>
124. From Local Explanations to Global Understanding with Explainable ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC7326367/>
125. Consistent feature attribution for tree ensembles - Semantic Scholar <https://www.semanticscholar.org/paper/Consistent-feature-attribution-for-tree-ensembles-Lundberg-Lee/77b097d3c2332bc9e401d71671d1877f6a04054d>

126. Determination of half-maximal inhibitory concentration using ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC4955526/>
127. (PDF) A Target Permutation Test for Statistical Significance of ... https://www.researchgate.net/publication/388592653_A_Target_Permutation_Test_for_Statistical_Significance_of_Feature_Importance_in_Differentiable_Models
128. SHAP is not all you need (or why you should always use ... - LinkedIn <https://www.linkedin.com/pulse/shap-all-you-need-why-should-always-use-permutation-alastair-olunc>
129. Overview and Practical Recommendations on Using Shapley ... <https://onlinelibrary.wiley.com/doi/10.1002/sim.70375>
130. [PDF] Structure-property modeling with advanced machine learning ... https://theses.hal.science/tel-04116204v1/file/ZANKOV_Dmitry_2023_ED222.pdf
131. Feature importance based on (a) Gini (b) Permutation, and (c) SHAP ... https://www.researchgate.net/figure/Feature-importance-based-on-a-Gini-b-Permutation-and-c-SHAP-values_fig1_399425389
132. Quantum Machine Learning Algorithms for Drug Discovery ... <https://pubs.acs.org/doi/10.1021/acs.jcim.1c00166>
133. Ultralarge Virtual Screening Identifies SARS-CoV-2 Main Protease ... <https://pubs.acs.org/doi/10.1021/jacs.1c08402>
134. QSAR Modeling for Predicting IC50 and GI50 Values for Human Cell ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC12733303/>
135. QSAR Modeling and Biological Testing of Some 15-LOX Inhibitors in ... <https://www.mdpi.com/1420-3049/29/23/5540>
136. A visual comparison of Gini importance and permutation importance ... https://www.researchgate.net/figure/A-visual-comparison-of-Gini-importance-and-permutation-importance-for-a-set-of_fig1_392608955
137. A comparison of methods for interpreting random forest models of ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC7847145/>
138. UbiQTree: Uncertainty quantification in XAI with tree ensembles <https://www.sciencedirect.com/science/article/pii/S2666389925003022>
139. Flowr.root – A flow matching based foundation model for joint multi ... <https://arxiv.org/html/2510.02578v5>
140. Extracting spatial effects from machine learning model using local ... <https://www.sciencedirect.com/science/article/pii/S0198971522000898>
141. [PDF] Variance-based importance measures for machine learning ... - HAL <https://hal.science/hal-03741384/document>

142. Developing a Hybrid Model to Enhance the Robustness of ... - MDPI <https://www.mdpi.com/2220-9964/14/7/277>
143. Graphs of experimental (x – axis) versus predicted (y – axis) pIC50 ... https://www.researchgate.net/figure/Graphs-of-experimental-x-axis-versus-predicted-y-axis-pIC50-values-for-CYP3A4_fig8_355011055
144. Prediction and Screening Model for Products Based on Fusion ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9357736/>
145. On Approximating the pIC50 Value of COVID-19 Medicines In Silico ... <https://www.mdpi.com/2227-9059/11/2/284>
146. Machine Learning-Based QSAR Screening of Colombian Medicinal ... <https://www.mdpi.com/1424-8247/18/12/1906>
147. Interpretable QSAR and Complementary Docking for PARP1 ... - MDPI <https://www.mdpi.com/1424-8247/19/4/584>
148. Why are the concentrations in log form when calculating IC50 from a ... https://www.researchgate.net/post/Why_are_the_concentrations_in_log_form_when_calculating_IC50_from_a_dose_response_curve2
149. Consistent Individualized Feature Attribution for Tree Ensembles <https://arxiv.org/abs/1802.03888>
150. Interventional SHAP Values and Interaction Values for Piecewise ... <https://ojs.aaai.org/index.php/AAAI/article/view/26322>
151. Frequency distribution of estimated pIC50 values. The IC50 values of... https://www.researchgate.net/figure/Frequency-distribution-of-estimated-pIC50-values-The-IC50-values-of-novel-potent-type-112_fig1_341444030
152. Consensus versus Individual QSARs in Classification - PMC - NIH <https://pmc.ncbi.nlm.nih.gov/articles/PMC7997107/>
153. Graph Neural Networks vs. Traditional QSAR - MDPI <https://www.mdpi.com/1420-3049/30/23/4605>
154. Predicted and simulated pIC50 versus experimental pIC50 for best... https://www.researchgate.net/figure/Predicted-and-simulated-pIC50-versus-experimental-pIC50-for-best-generated-model_fig3_320920524
155. QSAR Modeling for Predicting IC50 and GI50 Values for Human Cell ... <https://pubmed.ncbi.nlm.nih.gov/41465489/>
156. (PDF) Dose–Response Curves and the Determination of IC 50 and ... https://www.researchgate.net/publication/384548188_Dose-Response_Curves_and_the_Determination_of_IC_50_and_EC_50_Values
157. Machine Learning and Deep Learning Application in Cholinesterase ... <https://www.mdpi.com/2624-8549/8/5/67>

158. Artificial Neural Networks - Springer Nature <https://link.springer.com/content/pdf/10.1007/978-1-60327-101-1.pdf>
159. [PDF] Explanation of Machine Learning Models Using Shapley Additive ... <https://arxiv.org/pdf/2112.11071>